

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université Abderrahmane MIRA de Béjaïa
Faculté des Sciences Exactes
Département de Recherche Opérationnelle



Mémoire présenté pour l'obtention du diplôme de Master
en Mathématiques Appliquées

Spécialité : Sciences de Données et Aide à la Décision

Modélisation et optimisation intelligente de la gestion des stocks de produits sanguins

Présenté par :

DAHMANI MAHDI
CHAMEN RAYANE

Sous la direction de :

Pr. Mme Ouiza Lekadir
Mr. Ramzi Sahli

Devant le jury composé de :

Mme Bernine Nassima	MCB	Président	UAMB
Mme Hassaini Katia	MCB	Examineur	UAMB
Melle Mousli Sabrina	DR	Examineur	UAMB

Année Universitaire 2025 – 2026

Remerciements

Chamen Rayane

« *La gratitude est la mémoire du cœur.* »

Au terme de ce travail, il m'est agréable d'exprimer ma profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à l'accomplissement de ce mémoire.

Mes premiers remerciements vont naturellement à mes **parents**, dont le soutien indéfectible, les sacrifices consentis et l'amour inconditionnel ont été le socle sur lequel j'ai pu construire chaque étape de mon parcours. Aucun mot ne saurait exprimer la reconnaissance que je vous dois.

À mes **deux frères**, **Yanice** mon grand frère, **Youcef** mon petit frère et à ma **petite sœur** — ma sœur unique — **Inès**, merci d'avoir été là, dans les moments de doute comme dans ceux de joie. Votre présence et vos encouragements m'ont porté bien au-delà de ce que vous imaginez.

Je tiens également à exprimer ma sincère affection à toute ma **famille**, grands-parents, oncles et tantes, maternels comme paternels, qui ont accompagné ce parcours avec bienveillance et fierté. Votre soutien moral a toujours été une source d'énergie précieuse.

À mes **amis proches** — **Yanis**, **Mabrouk**, **Salah**, **Houcine**, **Bilal** et tous les autres —, ceux qui ont partagé avec moi des moments inoubliables, qui ont su m'écouter, me relever et m'encourager jusqu'au bout : merci. Ces années n'auraient pas eu la même saveur sans vous.

Une mention toute spéciale à mon **ami et binôme Mahdi Dahmani**, avec qui j'ai partagé chaque étape de ce travail, les difficultés comme les satisfactions. Ta détermination, ton sérieux et ton soutien constant ont été indispensables à l'aboutissement de ce mémoire.

Enfin, j'adresse mes sincères remerciements à mon **encadrant, Mr. Ramzi Sahli**, pour sa disponibilité, sa rigueur et ses précieux conseils qui ont guidé chacune de nos réflexions, ainsi qu'à **Mme Ouiza Lekadir**, pour son accompagnement bienveillant et son aide précieuse tout au long de ce travail. Votre engagement a été une lumière à chaque étape de ce mémoire.

J'adresse également mes remerciements à l'ensemble des **enseignants et responsables** qui ont jalonné mon cursus et contribué à ma réussite académique. Votre encadrement, votre pédagogie et votre dévouement ont façonné le chercheur que je suis aujourd'hui.

À tous, merci.

Dahmani Mahdi

« La gratitude est la mémoire du cœur. »

Au terme de ce travail, il m'est agréable d'exprimer ma profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à l'accomplissement de ce mémoire.

Mes premiers remerciements vont naturellement à mes **parents**, dont le soutien indéfectible, les sacrifices consentis et l'amour inconditionnel ont été le socle sur lequel j'ai pu construire chaque étape de mon parcours. Aucun mot ne saurait exprimer la reconnaissance que je vous dois.

À mes **deux sœurs, Alicia**, ma grande sœur, et **Lina**, ma petite sœur, merci d'avoir été là, dans les moments de doute comme dans ceux de joie. Votre présence et vos encouragements m'ont porté bien au-delà de ce que vous imaginez.

Je tiens également à exprimer ma sincère affection à toute ma **famille**, grands-parents, oncles et tantes, maternels comme paternels, qui ont accompagné ce parcours avec bienveillance et fierté. Une pensée toute particulière à mes **cousins et cousines — Massi, Hanane, Rozina, Amine, Zoubir, Mounir, Sabine et Houssam** — dont la complicité et les encouragements ont été une source d'énergie précieuse tout au long de ce chemin.

À mes **amis proches — Mohamed Islam Tiro, Hassen, Saïd, Akram, Mokhtari Badro** et tous les autres —, ceux qui ont partagé avec moi des moments inoubliables, qui ont su m'écouter, me relever et m'encourager jusqu'au bout : merci. Ces années n'auraient pas eu la même saveur sans vous.

Une mention toute spéciale à mon **ami et binôme Rayane Chamen**, avec qui j'ai partagé chaque étape de ce travail, les difficultés comme les satisfactions. Ta rigueur, ta bonne humeur et ta confiance ont été indispensables à l'aboutissement de ce mémoire.

Enfin, j'adresse mes sincères remerciements à mon **encadrant, Mr. Ramzi Sahli**, pour sa disponibilité, sa rigueur et ses précieux conseils qui ont guidé chacune de nos réflexions, ainsi qu'à **Mme Ouiza Lekadir**, pour son accompagnement bienveillant et son aide précieuse tout au long de ce travail. Votre engagement a été une lumière à chaque étape de ce mémoire.

J'adresse également mes remerciements à l'ensemble des **enseignants et responsables** qui ont jalonné mon cursus et contribué à ma réussite académique. Votre encadrement, votre pédagogie et votre dévouement ont façonné le chercheur que je suis aujourd'hui.

À tous, merci.

Dédicace

Nous dédions ce modeste travail...

À tous ceux qui nous ont soutenus et encouragés tout au long de ce parcours.

À notre encadrant, **Monsieur Ramzi Sahli**, pour sa disponibilité, sa rigueur et ses précieux conseils qui ont guidé chacune de nos réflexions. Votre engagement a été une lumière tout au long de ce travail.

À **Madame Ouiza Lekadir**, pour son accompagnement bienveillant et son aide précieuse.

À l'établissement du **Centre de Wilaya de Transfusion Sanguine de Béjaïa**, et à sa tête **Monsieur Lekhdari Salim**, pour nous avoir ouvert les portes de leur institution, mis à notre disposition les données nécessaires et accordé leur confiance. Ce travail est aussi le vôtre.

À tous ceux qui, de près ou de loin, ont contribué à notre réussite.

Table des matières

Remerciements	i
Dédicace	iv
Liste des figures	xi
Liste des tables	xii
Liste des algorithmes	xiii
Liste des abréviations et notations	xiv
Introduction générale	3
1 Présentation du centre de transfusion sanguine et données récoltées	5
1.1 Présentation de l'établissement	5
1.1.1 Historique de la transfusion sanguine en Algérie	6
1.1.2 Le Centre de Wilaya de Transfusion Sanguine de Béjaïa	7
1.1.3 Le Laboratoire du Sang	10
1.2 Collecte et description des données	12
1.2.1 Source des données	12
1.2.2 Description et Nettoyage des données	13
1.2.3 Objectif de l'étude	15
2 Gestion des stocks et produits périssables	17
2.1 Le stock	18
2.2 Gestion des stocks	18
2.3 Système de gestion des stocks	18
2.4 Avantages et inconvénients du stockage	19
2.5 Les coûts de gestion des stocks	19
2.5.1 Coût de commande	19
2.5.2 Coût de possession	20

2.5.3	Coût de rupture	20
2.6	Classification des stocks	20
2.7	Analyse ABC	20
2.7.1	Classes de l'analyse ABC	21
2.7.2	Méthodologie de mise en œuvre de L'ABC	21
2.7.3	Intérêt de l'analyse ABC	21
2.7.4	Application de l'analyse ABC aux produits sanguins	22
2.7.5	Exemple d'application	22
2.8	Politique de gestion de stock	23
2.9	Règles de sortie des stocks : FIFO, LIFO et FEFO	23
2.9.1	Règle FIFO (First In, First Out)	23
2.9.2	Règle LIFO (Last In, First Out)	24
2.9.3	Règle FEFO (First Expired, First Out)	24
2.10	Modèles déterministes de gestion des stocks	24
2.10.1	Hypothèses générales des modèles déterministes	24
2.10.2	Modèle de la quantité économique de commande (EOQ)	25
2.10.3	Modèle de réapprovisionnement avec point de commande	27
2.10.4	Modèle de production économique (EPQ)	28
2.10.5	Discussion des modèles déterministes	30
2.11	Produits périssables	31
2.12	Gestion des produits sanguins	31
2.12.1	Variabilité de l'offre et de la demande en produits sanguins	32
2.12.2	Causes de gaspillage et politiques de gestion adaptées	34
3	Réseau De Petri	37
3.1	Introduction	37
3.2	Définition d'un réseau de Petri	38
3.2.1	Illustration générale d'un réseau de Petri	38
3.2.2	Règles de sensibilisation et de franchissement	39
3.2.3	Exemple de RDP appliqué à un stock borné de produits sanguins	39
3.3	Notations matricielles	40
3.3.1	Vecteur de marquage	40
3.3.2	Matrices d'incidence avant et matrice d'incidence arrière	41
3.3.3	Matrice d'incidence	41
3.3.4	Équation d'état	41
3.3.5	Exemple d'application	42
3.4	Évaluation d'un réseau de Pétri : sensibilisation, franchissement et accessi- bilité	42
3.4.1	Sensibilisation et franchissement des transitions	42

3.4.2	Séquences de franchissements	43
3.4.3	Marquage accessible	44
3.4.4	Ensemble des marquages accessibles	44
3.4.5	Graphe des marquages accessibles	44
3.4.6	Graphe de recouvrabilité	45
3.5	Conflit et parallélisme	45
3.5.1	Conflit	45
3.5.2	Parallélisme	45
3.6	Propriétés d'un réseau de Petri	46
3.6.1	Bornitude	46
3.6.2	Invariant de places	46
3.6.3	Blocage et réseau sans blocage	47
3.6.4	Vivacité	47
3.6.5	État d'accueil	48
3.7	Extensions des réseaux de Petri	48
3.7.1	Réseaux de Petri colorés	49
3.7.2	Réseaux de Petri à arcs spéciaux	49
3.7.3	Schéma des différents arcs spéciaux	50
3.7.4	Réseaux de Petri stochastiques	50
3.8	Conclusion	53
4	Machine Learning et Deep Learning	54
4.1	Définition du Machine Learning	55
4.2	Préparation des données	56
4.2.1	Division des données	56
4.2.2	Normalisation et standardisation	56
4.2.3	Validation croisée	56
4.3	Métriques d'évaluation	57
4.3.1	Métriques pour la régression	57
4.3.2	Métriques pour la classification	57
4.4	Types de Machine Learning	58
4.5	Algorithmes de l'apprentissage supervisé	59
4.5.1	Régression	59
4.5.2	Algorithme des k plus proches voisins (KNN)	61
4.5.3	Support Vector Machine (SVM)	63
4.5.4	Arbre de décision	65
4.6	Apprentissage non supervisé	71
4.6.1	Algorithme K-means	71
4.6.2	Clustering hiérarchique	73

4.7	Apprentissage par renforcement	74
4.7.1	Principe général	74
4.7.2	Fonction de valeur	75
4.7.3	Algorithme Q-learning	75
4.8	Deep Learning	77
4.8.1	Réseaux de neurones artificiels (RNA)	77
4.8.2	Réseaux de neurones convolutifs (CNN)	79
4.8.3	Réseaux de neurones récurrents (RNN)	80
4.8.4	Réseaux LSTM et GRU	81
5	Analyse d'un système de gestion de stock des produits sanguins via les RdPSG et machine learning	83
5.1	Modèle RdPSG associé au système étudié	84
5.1.1	Description des places	84
5.1.2	Description des transitions	85
5.2	Analyse qualitative et quantitative du RdPSG établi	86
5.2.1	Graphe de marquage accessible du RdPSG établi	86
5.2.2	Détermination des états tangibles	87
5.2.3	Construction de la matrice de transition Q	88
5.2.4	Distribution stationnaire π	89
5.2.5	Calcul des indicateurs de performance	90
5.2.6	Analyse de sensibilité et interprétation des résultats	91
5.3	Machine learning	93
5.4	Prédiction de la Demande des Concentrés Érythrocytaires (CE)	93
5.4.1	Source et Préparation des Données	93
5.4.2	Variable Cible et Variables Explicatives	94
5.4.3	Résultats et Métriques de Performance	95
5.4.4	Analyse des Résultats Visuels	95
5.4.5	Prévisions Futures	98
5.5	Prédiction de la Demande des Concentrés Plaquettaires Standard (CPS)	98
5.5.1	Source et Préparation des Données	99
5.5.2	Variable Cible et Variables Explicatives	99
5.5.3	Résultats et Métriques de Performance	100
5.5.4	Analyse des Résultats Visuels	100
5.5.5	Prévisions Futures	103
5.6	Prédiction de la Demande du Plasma Fraîchement Congelé (PFC)	104
5.6.1	Source et Préparation des Données	104
5.6.2	Variable Cible et Variables Explicatives	104

5.6.3	Résultats et Métriques de Performance	105
5.6.4	Analyse des Résultats Visuels	105
5.6.5	Prévisions Futures	108
Conclusion générale		110
Bibliographie		112
A Présentation de l'outil GreatSPN		116
Annexe A : Présentation de l'outil GreatSPN		116
A.1	Présentation de l'outil GreatSPN	116
B Language Python		117
Annexe B : Language Python		117
B.1	Python	117
B.2	Visual Studio Code	117
B.3	Bibliothèques utilisées en apprentissage automatique	117
Résumé		119

Table des figures

1.1	Chronologie de la transfusion sanguine en Algérie	6
1.2	Façade du Centre de Wilaya de Transfusion Sanguine — CHU de Béjaïa . .	7
1.3	Les six bonnes raisons de donner son sang régulièrement	8
1.4	Schéma organisationnel du Laboratoire du Sang de l'ANS	11
1.5	Registre de séparation utilisé au niveau du CWTS de Béjaïa.	13
1.6	Extrait du registre des sorties utilisé au niveau du CWTS de Béjaïa. . . .	14
1.7	Données de stock – PFC	15
1.8	Données de stock – CE	15
1.9	Données de stock – CPS	15
2.1	Évolution du niveau de stock dans le modèle EOQ.	25
2.2	Décomposition des coûts dans le modèle EOQ et localisation de Q^*	26
2.3	Modèle de gestion avec point de commande et stock de sécurité.	27
2.4	Évolution du niveau de stock dans le modèle EPQ.	29
2.5	Schéma simplifié de la chaîne d'approvisionnement des produits sanguins. .	32
2.6	Schéma de fonctionnement de la politique FIFO modifiée, adaptée d'Abbasi et Hosseinifard [10].	35
3.1	Éléments généraux d'un réseau de Petri : places, transition, arc et jetons. .	38
3.2	Réseau de Petri simplifié d'un stock borné de produits sanguins. Le mar- quage initial est $M_0 = (2, 1)$, où p_S représente le stock disponible et p_C la capacité libre.	40
3.3	Graphe d'accessibilité du RDP de l'exemple 3.2.3.	45
3.4	Illustration simplifiée des principaux arcs spéciaux dans les réseaux de Pétri.	50
3.5	Illustration simplifiée d'un réseau de Petri stochastique pour une lampe. . .	52
4.1	Les trois grandes familles d'apprentissage automatique.	59
4.2	Régression linéaire : ajustement d'une droite à un nuage de points.	60
4.3	Principe du SVM : hyperplan séparateur à marge maximale.	63
4.4	Arbre de décision construit à partir des données médicales.	66
4.5	Résultat du K-means avec deux clusters et leurs centroïdes.	72

4.6	Boucle d'interaction agent-environnement en apprentissage par renforcement.	75
4.7	Architecture d'un réseau de neurones multicouche.	77
4.8	Structure interne d'un neurone artificiel.	78
4.9	Illustration de l'opération de convolution appliquée à une image 2×2	79
4.10	Déroulement temporel d'un réseau de neurones récurrent (RNN).	80
5.1	Modèle RdPSG du système de gestion de stock des produits sanguins. . . .	84
5.2	Graphe des marquages accessibles du RdPSG	87
5.3	Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026).	96
5.4	Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest).	97
5.5	Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026). Zone bleue : phase d'entraînement; zone orange : phase de test. Les lignes pointillées indiquent les prédictions sur le jeu de test, les tirets les prévisions pour les six mois à venir.	100
5.6	Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest). Les valeurs sont exprimées en pourcentage de contribution à la réduction d'erreur globale du modèle. . .	102
5.7	Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026). Zone bleue : phase d'entraînement; zone orange : phase de test. Les lignes pointillées indiquent les prédictions sur le jeu de test, les tirets les prévisions pour les six mois à venir.	106
5.8	Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest). Les valeurs sont exprimées en pourcentage de contribution à la réduction d'erreur globale du modèle. . .	107
A.1	Interface graphique de l'outil GreatSPN avec indication du bouton RG. . .	116

Liste des tableaux

2.1	Caractéristiques de conservation des principaux produits sanguins labiles. .	31
2.2	Sources de variabilité dans la chaîne d’approvisionnement en produits sanguins.	33
2.3	Comparaison des politiques de sortie appliquées aux produits sanguins. . .	35
4.1	Matrice de confusion pour la classification binaire.	58
5.1	États tangibles du RdPSG avec $N = 4$, $S = S' = S'' = 2$	88
5.2	Distribution stationnaire π du RdPSG	90
5.3	Récapitulatif des indicateurs de performance	91
5.4	Analyse de sensibilité — impact des taux sur les indicateurs	92
5.5	Répartition chronologique des données — CE	94
5.6	Description des variables explicatives utilisées — CE	94
5.7	Métriques de performance des trois modèles — CE (ensemble de test) . . .	95
5.8	Prévisions de la demande mensuelle en CE — Février à Juillet 2026	98
5.9	Répartition chronologique des données — CPS	99
5.10	Métriques de performance des trois modèles — CPS (ensemble de test) . .	100
5.11	Prévisions de la demande mensuelle en CPS — Janvier à Juin 2026	103
5.12	Répartition chronologique des données — PFC	104
5.13	Métriques de performance des trois modèles — PFC (ensemble de test) . .	105
5.14	Prévisions de la demande mensuelle en PFC — Janvier à Juin 2026	108
B.1	Bibliothèques Python utilisées et leurs rôles.	118

Liste des algorithmes

1	Principe de la régression	60
2	Algorithme des K-plus proches voisins (KNN)	62
3	Algorithme des SVM	64
4	Construction d'un Arbre de Décision	65
5	Algorithme Random Forest	67
6	Algorithme XGBoost	69
7	Algorithme CatBoost (Ordered Boosting)	70
8	Algorithme des K-means	72
9	Clustering Hiérarchique (Classification Ascendante)	74
10	Algorithme de Q-Learning	76

Liste des abréviations et notations

Abréviations générales

Sigle	Signification
ANS	Agence Nationale du Sang
CHU	Centre Hospitalo-Universitaire
CWTS	Centre de Wilaya de Transfusion Sanguine
PSL	Produits Sanguins Labiles
OCR	<i>Optical Character Recognition</i> (reconnaissance optique de caractères)

Produits sanguins

Sigle	Signification
CE	Concentré d'Érythrocytes
PFC	Plasma Frais Congelé
CPS	Concentré Plaquettaire Standard

Machine Learning et statistiques

Sigle	Signification
ML	Machine Learning
DL	Deep Learning
KNN	K-Nearest Neighbors
SVM	Support Vector Machine
RNA	Réseau de Neurones Artificiels
RNN	Recurrent Neural Network
CNN	Convolutional Neural Network
LSTM	<i>Long Short-Term Memory</i>
GRU	<i>Gated Recurrent Unit</i>
MAE	<i>Mean Absolute Error</i> (erreur absolue moyenne)
RMSE	<i>Root Mean Squared Error</i> (racine de l'erreur quadratique moyenne)
MAPE	<i>Mean Absolute Percentage Error</i> (erreur absolue moyenne en pourcentage)
EOQ	<i>Economic Order Quantity</i> (quantité économique de commande)
EPQ	<i>Economic Production Quantity</i> (quantité économique de production)

Notations mathématiques

Symbole	Signification
$\mathbb{R}$	Ensemble des nombres réels
$\mathbb{R}^n$	Espace euclidien de dimension n
$\mathbb{N}$	Ensemble des entiers naturels
$\mathbb{E}[X]$	Espérance mathématique de la variable X
$\text{Var}(X)$	Variance de X
$\ x\ $	Norme euclidienne du vecteur x
$x \sim \mathcal{N}(\mu, \sigma^2)$	x suit une loi normale d'espérance μ et de variance σ^2

Réseaux de Petri et chaînes de Markov

Sigle / Symbole	Signification
RdP	Réseau de Petri
RdPSG	Réseau de Petri Stochastique Généralisé
GSPN	<i>Generalized Stochastic Petri Net</i>
SPN	<i>Stochastic Petri Net</i> (Réseau de Petri stochastique)
DSPN	<i>Deterministic and Stochastic Petri Net</i>
ESPN	<i>Extended Stochastic Petri Net</i>
CMTC	Chaîne de Markov à Temps Continu
M, M_0	Marquage courant, marquage initial
P_i	Place i du réseau
T_i	Transition i du réseau
π	Distribution stationnaire de la CMTC
Q	Matrice de transition infinitésimale (générateur)
$\mathcal{E}_i$	État tangible i
N	Capacité maximale de la file d'attente des donneurs P_{fatt}
S, S', S''	Niveaux de stock initiaux des places P_{CE}, P_{PFC}, P_{CPS}
λ_{arr}	Taux d'arrivée des donneurs
λ_{acc}	Taux d'acceptation (donneur apte)
λ_{ina}	Taux d'inaptitude du donneur
λ_{liv}	Taux de livraison des produits sanguins
λ_{per}	Taux de péremption des produits sanguins

Introduction générale

Contexte et motivation

La gestion des stocks de produits sanguins représente l'un des défis logistiques les plus critiques du système de santé. Ces produits, indispensables à la survie des patients en situation d'urgence transfusionnelle, sont soumis à une double contrainte : une durée de conservation très limitée allant de quelques jours pour les concentrés plaquettaires à plusieurs semaines pour les concentrés érythrocytaires et une demande hautement variable, difficile à anticiper. Toute rupture de stock expose directement les patients à un risque vital, tandis qu'un excès de stock entraîne des pertes irréversibles par péremption, avec des conséquences humaines, éthiques et économiques considérables.

Dans ce contexte, le Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa, rattaché au CHU de Béjaïa, fait face quotidiennement à ces enjeux. La gestion de ses stocks repose encore largement sur des pratiques empiriques et des registres papier, sans modèle quantitatif permettant d'évaluer objectivement les performances du système ni d'anticiper les besoins futurs. Ce constat motive la présente étude, qui s'inscrit dans une démarche scientifique visant à apporter des outils d'aide à la décision adaptés à ce contexte opérationnel réel.

Problématique

Comment modéliser de manière rigoureuse la dynamique du flux des produits sanguins au sein d'un centre de transfusion, en évaluer les performances en régime permanent, et prédire la demande future afin d'optimiser les décisions de gestion des stocks et de réduire simultanément les risques de rupture et de péremption ?

Objectifs

Ce travail poursuit trois objectifs complémentaires :

1. **Modéliser** le système de gestion des stocks de produits sanguins à l'aide d'un

Réseau de Petri Stochastique Généralisé (RdPSG), afin de représenter formellement les flux depuis l'arrivée des donneurs jusqu'à la distribution ou la péremption des poches.

2. **Analyser** quantitativement les performances du système en régime permanent — probabilité de rupture de stock, taux de service, niveau moyen de stock, débit de livraison — et identifier les leviers d'amélioration par une analyse de sensibilité.
3. **Prédire** la demande mensuelle en produits sanguins (Concentrés Érythrocytaires, Concentrés Plaquettaires Standard et Plasma Frais Congelé) à l'aide d'algorithmes de machine learning (CatBoost, XGBoost, Random Forest), appliqués aux données historiques réelles du CWTS de Béjaïa.

Organisation du mémoire

Ce mémoire est structuré en cinq chapitres :

- Le **chapitre 1** présente le Centre de Wilaya de Transfusion Sanguine de Béjaïa, son organisation, ses activités et les données collectées dans le cadre de cette étude.
- Le **chapitre 2** expose les fondements théoriques de la gestion des stocks et des produits périssables, en insistant sur les spécificités des produits sanguins.
- Le **chapitre 3** introduit les réseaux de Petri, leurs propriétés, leurs notations matricielles et les extensions stochastiques utilisées pour la modélisation des systèmes à événements discrets.
- Le **chapitre 4** présente les notions fondamentales du Machine Learning et du Deep Learning, en détaillant les algorithmes supervisés, non supervisés et ensemblistes mobilisés dans ce travail.
- Le **chapitre 5** constitue le cœur applicatif du mémoire : il présente le modèle RdPSG construit pour le système étudié, son analyse quantitative par résolution de la chaîne de Markov associée, ainsi que les modèles de prédiction de la demande développés et évalués sur les données réelles du centre.

Le mémoire se conclut par une synthèse des résultats obtenus et leur discussion.

CHAPITRE 1

Présentation du centre de transfusion sanguine et données récoltées

Introduction

La transfusion sanguine constitue un pilier fondamental de la médecine moderne. Elle intervient dans de nombreuses situations cliniques critiques : chirurgie lourde, traumatismes graves, maladies hématologiques et oncologiques, ou encore hémorragies obstétricales. Garantir un approvisionnement continu, sécurisé et de qualité en produits sanguins représente dès lors un enjeu majeur de santé publique.

En Algérie, cette mission est confiée à un réseau de centres de transfusion sanguine coordonnés par l'Agence Nationale du Sang (ANS). Notre étude porte plus particulièrement sur le Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa, rattaché au CHU de Béjaïa. Ce premier chapitre est structuré en deux parties complémentaires.

La première partie est consacrée à la présentation de l'établissement : son historique dans le contexte algérien, son implantation, ses structures fonctionnelles, ses activités, ainsi que le rôle du Laboratoire du Sang de l'ANS comme structure de référence nationale.

La seconde partie décrit la démarche de collecte et de traitement des données issues des registres physiques du CWTS. Nous y présentons les différentes étapes ayant permis de constituer des datasets numériques fiables portant sur les trois produits sanguins étudiés les Concentrés Érythrocytaires (CE), le Plasma Frais Congelé (PFC) et les Concentrés Plaquettaires Standards (CPS) ainsi que l'objectif principal de l'étude, à savoir la prédiction de la demande en produits sanguins par des techniques de machine learning.

1.1 Présentation de l'établissement


Cette section retrace l'évolution historique de la transfusion sanguine en Algérie, avant de présenter en détail le Centre de Wilaya de Transfusion Sanguine de Béjaïa son implan-

tation, son organisation interne, ses activités ainsi que le rôle du Laboratoire du Sang de l'ANS comme structure de référence nationale.

1.1.1 Historique de la transfusion sanguine en Algérie

L'organisation de la transfusion sanguine en Algérie a connu plusieurs étapes importantes depuis la création des premières structures spécialisées jusqu'à la mise en place d'un cadre réglementaire et institutionnel moderne. La figure 1.1 présente les principales dates qui ont marqué l'évolution du système transfusionnel algérien[1].

FIGURE 1.1 : Chronologie de la transfusion sanguine en Algérie



1.1.2 Le Centre de Wilaya de Transfusion Sanguine de Béjaïa

Présentation générale

Le Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa est l'une des unités constitutives du Centre Hospitalo-Universitaire (CHU) de Béjaïa. Il a été inauguré le **4 juillet 2000** avec la participation de l'Agence Nationale du Sang, de la Direction de la Santé et du Secteur Sanitaire de Béjaïa.

Le centre est situé en plein centre-ville, ce qui lui confère un **accès facile et stratégique** pour les donneurs de sang venant effectuer un don de sang total. La figure 1.2 présente la façade du bâtiment abritant le CWTS de Béjaïa.



FIGURE 1.2 : Façade du Centre de Wilaya de Transfusion Sanguine — CHU de Béjaïa

Le don de sang : enjeux et motivations

Le don de sang constitue l'acte fondateur de toute activité transfusionnelle. Il repose sur la participation volontaire et bénévole de citoyens conscients de l'importance vitale de leur geste. La figure 1.3 illustre les six principales raisons qui motivent le don de sang régulier.




FIGURE 1.3 : Les six bonnes raisons de donner son sang régulièrement

Parmi ces motivations, on retient notamment la nécessité de répondre à la demande croissante des hôpitaux, la contribution à la diversité des réserves sanguines, ainsi que l'impact direct d'un seul don sur plusieurs vies. Le CWTS de Béjaïa s'inscrit pleinement dans cette démarche de sensibilisation et de mobilisation de la population de la wilaya.

Périmètre de distribution

Le CWTS de Béjaïa assure la distribution des **produits sanguins labiles (PSL)** à l'ensemble des structures de soins publiques et privées de la wilaya, notamment :

- les trois hôpitaux du CHU : hôpital Khellil Amrane, hôpital Frantz Fanon et EHS mère-enfant ;
- la banque de sang de l'EPH d'Aokas ;
- les postes de transfusion sanguine d'Akbou, Sidi-Aïch et Kherrata ;
- la banque de sang d'Amizour ;
- sept cliniques privées de la wilaya.

Locaux et organisation interne

Le CWTS comprend **quatre unités fonctionnelles** :

- **Unité de collecte de sang** : dotée d'une salle d'attente, d'un secrétariat, d'une salle d'entretien médical, d'une salle de prélèvement et d'une salle de collation et de repos post-don ;
- **Unité de préparation des PSL** : assurant la production des concentrés érythrocytaires (CE), du plasma frais congelé (PFC) et des concentrés de plaquettes standard (CPS) ;
- **Unité de qualification biologique des PSL** : comprenant deux sous-unités, l'une de sérologie infectieuse et l'autre d'immuno-hématologie ;
- **Unité de stockage et de distribution des PSL** : garantissant la disponibilité et la traçabilité des produits à destination des structures de soins.

Activités et démarche qualité

Le CWTS assure la distribution des PSL de jour comme de nuit à l'ensemble des utilisateurs de sang de la wilaya. En **2004**, une démarche qualité a été mise en place, couvrant les processus de prélèvement, de préparation, de qualification et de distribution. Deux audits ont été réalisés cette même année par l'ANS et l'expert OMS Dr Chassaigne.

Parmi les actions structurantes menées :

- mise à disposition de deux véhicules de collecte mobile pour l'ensemble des structures transfusionnelles de la wilaya ;
- mise en place en 2004 de la traçabilité de l'utilisation des PSL dans les services hospitaliers publics ;
- organisation de cinq séminaires en collaboration avec l'ANS et la DSP, visant à promouvoir une prescription de qualité selon les bonnes pratiques transfusionnelles ;
- réalisation de deux inspections coordonnées par la DSP (2001 et 2008) afin de renforcer la sécurité transfusionnelle à l'échelle de la wilaya.

Objectifs et perspectives du CWTS

La stratégie de développement du CWTS, établie en cohérence avec les orientations de l'ANS, vise à :

- développer la collecte mobile afin d'atteindre **60 %** de la collecte totale ;
- porter le taux de **dons bénévoles à 80 %** ;
- atteindre **100 %** de séparation du sang total en composants ;

- rénover les locaux afin de centraliser les activités de préparation et de qualification au niveau du CWTS ;
- développer la **cytaphérèse** pour les malades d'hématologie et d'oncologie ;
- améliorer de manière continue la sécurité transfusionnelle.

1.1.3 Le Laboratoire du Sang

Création et rôle

Le Laboratoire du Sang de l'ANS a été créé par arrêté ministériel n° 92 du 15 juillet 2014, qui en définit l'objet, l'organisation et les missions [2].

Son rôle principal est d'assurer le **soutien technique** de l'Agence Nationale du Sang et de servir de **structure de référence** pour l'ensemble des centres et banques de sang du territoire national, afin de garantir une sécurité optimale des produits sanguins labiles.

Missions du Laboratoire du Sang

Les missions du Laboratoire du Sang couvrent plusieurs domaines complémentaires :

- élaborer, mettre en œuvre et coordonner le programme national de contrôle de qualité des produits sanguins ;
- confirmer les résultats positifs ou indéterminés lors du dépistage des infections hémotransmissibles chez les donneurs de sang ;
- résoudre les difficultés d'ordre immuno-hématologique rencontrées au niveau des centres de sang de wilaya et des banques de sang ;
- fabriquer, contrôler et distribuer le panel d'hématies tests pour la recherche des agglutinines irrégulières ;
- expertiser les réactifs utilisés dans les centres de sang de wilayas et les banques de sang ;
- participer aux enquêtes d'hémovigilance ;
- organiser et gérer une sérothèque nationale ;
- organiser et gérer une biothèque (don de cellules souches et de moelle osseuse, typage HLA) ;
- assurer le contrôle de qualité des pools de plasma destinés au fractionnement.

Organisation du Laboratoire du Sang

Le Laboratoire du Sang est structuré en quatre unités spécialisées dont les rôles sont présentés dans la figure 1.4 ci-dessous.




FIGURE 1.4 : Schéma organisationnel du Laboratoire du Sang de l'ANS

Unité de sérologie infectieuse Le dépistage des infections virales transmissibles par voie sanguine — notamment le VIH 1 et 2, les hépatites B et C, ainsi que la syphilis — est rendu obligatoire par l'arrêté du 24 mai 1998. Les analyses portent sur la détection des anticorps anti-VIH 1 et 2, de l'antigène HBs, des anticorps anti-VHC et des anticorps antisyphilis.

Tout résultat reproductible positif doit faire l'objet d'un test de confirmation sur un second prélèvement, au moyen des techniques suivantes :

- *Western Blot* et *Immuno Blot* pour le VIH ;
- *Immuno Blot* pour l'hépatite C ;
- séro-neutralisation de l'antigène HBs pour l'hépatite B.

Unité d'immuno-hématologie Le groupage ABO et Rh D est réalisé lors de chaque don, conformément à l'arrêté du 24 mai 1998 fixant les règles de bonnes pratiques pour la qualification biologique du don de sang. Le groupe sanguin n'est réputé définitif qu'après deux déterminations indépendantes, effectuées à partir de deux prélèvements distincts par deux techniciens différents. Cette unité est également chargée de résoudre les discordances de groupage, de fabriquer les panels d'hématies tests et de participer aux enquêtes d'hémovigilance.

Unité de contrôle de qualité Cette unité est responsable de l'élaboration et de la coordination du programme national de contrôle de qualité des produits sanguins, de l'expertise des réactifs utilisés dans les centres de sang de wilayas, et du contrôle de qualité des pools de plasma destinés au fractionnement.

Unité d'approvisionnement et de logistique Cette unité assure un rôle de soutien logistique et technique au laboratoire du sang, en garantissant la disponibilité des ressources matérielles nécessaires au bon fonctionnement de l'ensemble des activités analytiques.

1.2 Collecte et description des données

Cette section présente les données utilisées dans le cadre de cette étude, en décrivant leur origine, les modalités de leur collecte ainsi que les étapes de traitement ayant permis leur exploitation.

1.2.1 Source des données

Les données utilisées dans cette étude proviennent des registres physiques du Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa. Afin de constituer une base de données exploitable pour l'analyse et la modélisation, une démarche structurée a été suivie.

1. Identification des sources de données

Trois registres principaux ont été retenus pour la collecte des données :

- le registre de séparation ;
- le registre des sorties ;
- le registre des demandes non satisfaites.

2. **Collecte des données** Les informations contenues dans ces registres ont été recueillies sur une période de quatre années afin d'obtenir un historique suffisamment représentatif de l'activité du centre.
3. **Numérisation des registres** Les registres papier ont été photographiés puis numérisés à l'aide d'un scanner afin d'obtenir des copies numériques de bonne qualité.
4. **Extraction automatique des données** Les documents numérisés ont été traités à l'aide de la technologie OCR (*Optical Character Recognition*) permettant d'extraire automatiquement les informations textuelles contenues dans les images.
5. **Vérification et correction des données** Une étape de contrôle manuel a été réalisée afin de détecter et corriger les éventuelles erreurs générées lors de la reconnaissance automatique des caractères.
6. **Organisation des données** Les données validées ont ensuite été saisies et structurées dans des fichiers Excel afin de constituer une base de données exploitable pour les traitements ultérieurs.
7. **Constitution des datasets** Les bases de données obtenues ont servi à la création des différents datasets utilisés dans les phases d'analyse, de modélisation par réseaux de Petri stochastiques généralisés et de prédiction par machine learning.

Cette démarche a permis de transformer des archives papier en datasets numériques fiables et adaptés aux différentes analyses réalisées dans ce travail.

1.2.2 Description et Nettoyage des données

Le dataset principal regroupe plusieurs variables décrivant les caractéristiques des produits sanguins ainsi que leur gestion au sein du centre de transfusion sanguine. Parmi les variables collectées, on retrouve notamment :

- le numéro d'enregistrement représentant le numéro unique de la pochette sanguine ;
- la quantité de CE (*Concentré d'Érythrocytes*) ;
- la quantité de PFC (*Plasma Frais Congelé*) ;
- la quantité de CPS (*Concentré Plaquettaire Standard*) ;
- la date d'entrée qui représente la date de prélèvement de la pochette.

NUMÉRO D'ENREGIST.	C.E	P.F.C.	C.P.S	S.T.	OBSERVATION
180	300		90	535	
181	300		90	510	
182	300		90	545	
183	325		90	560	
184	305		80	540	
185	320		85	520	
186	410		90	510	
187	315		95	565	
188	380		90	520	
189	360	255	90	525	
190					OK
191	385		90	500	
192	325	210	90	510	
193	385	260	90	585	
194	360	210	90	500	
195	325	210	80	510	
196	345			505	ppp Afrique
197	385		90	510	
198				510	ST ou prélèvement
199	380	205	90	510	
200	400		90	530	

FIGURE 1.5 : Registre de séparation utilisé au niveau du CWTS de Béjaïa.

À partir des produits conformes obtenus après séparation, trois datasets distincts ont été élaborés, chacun représentant le stock d'un produit sanguin spécifique :

- le stock des CE;
- le stock des PFC;
- le stock des CPS.

Chaque dataset de stock contient plusieurs informations importantes, notamment :

- la date d'entrée du produit ;
- la date de sortie ;
- l'établissement de sortie ;
- les informations relatives à la gestion et au suivi du stock.

Ces données qui contiennent ces informations ont été élaborées à l'aide de registres des sorties présentés dans la figure 1.6 où on s'intéresse au nombre de pochettes distribuées à chaque établissement et à la date de sortie pour avoir au final nos 3 datasets des stocks présentés dans les figures ci-dessous 1.7, 1.8, 1.9. Ces données permettent de suivre le cycle de vie des produits sanguins depuis leur préparation jusqu'à leur distribution ou leur éventuelle péremption.

Date de Sortie	N°	Nom et Prénom du receveur	Dénomination du produit	Q.S.N.	Q.S.	Q.S.	N°o Flacon des P.S.L.	T.C.	N°	N°	N° de la Boîte de Médicament	Nom du Distributeur	Nom du Receveur	Montant des P.S.L.	Nom et Signature du Porteur
330	330	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
331	331	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
332	332	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
333	333	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
334	334	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
335	335	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
336	336	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
337	337	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
338	338	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
339	339	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
340	340	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
341	341	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
342	342	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
343	343	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
344	344	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
345	345	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
346	346	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
347	347	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira
348	348	Seuche Mohamed Said	UTIC	8	1		002450				P	aid chell	Chell	14/10	dentman
349	349	Straus Anne	EDV	8	1		10010				Albini	Chell	14/10	14/10	Tekira
350	350	Touche	Albini	8	1		10010				Albini	Chell	14/10	14/10	Tekira

FIGURE 1.6 : Extrait du registre des sorties utilisé au niveau du CWTS de Béjaïa.

Numéro d'enregistrement	P.F.C	annee	mois	jour	date	statut	Etablissement de sortie	date de sortie
1	240	2022	janvier	1	01/01/2022	distribué	EPH public	14/01/2022
2	265	2022	janvier	1	01/01/2022	jeté		06/01/2022
4	210	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	15/01/2022
5	210	2022	janvier	1	01/01/2022	distribué	EPH public	18/01/2022
7	215	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	19/01/2022
9	220	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	08/01/2022
10	240	2022	janvier	1	01/01/2022	distribué	EPH public	17/01/2022
12	240	2022	janvier	1	01/01/2022	distribué	clinique privée	14/01/2022
13	215	2022	janvier	1	01/01/2022	distribué	EPH public	07/01/2022
16	215	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	23/01/2022
17	235	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	06/01/2022
18	220	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022

FIGURE 1.7 : Données de stock – PFC

Numéro d'enregistrement	C.E	annee	mois	jour	date	statut	Etablissement de sortie	date de sortie
1	375	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	09/01/2022
2	355	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	16/01/2022
3	325	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	16/01/2022
4	380	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	09/01/2022
5	380	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	22/01/2022
6	355	2022	janvier	1	01/01/2022	distribué	Clinique privée	06/01/2022
7	365	2022	janvier	1	01/01/2022	distribué	EPH public	20/01/2022
8	350	2022	janvier	1	01/01/2022	distribué	Clinique privée	14/01/2022
9	340	2022	janvier	1	01/01/2022	jeté		19/01/2022
10	375	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	12/01/2022
11	385	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	12/01/2022
12	365	2022	janvier	1	01/01/2022	distribué	EPH public	25/01/2022
13	335	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	06/01/2022
14	375	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	10/01/2022
15	365	2022	janvier	1	01/01/2022	jeté		16/01/2022
16	355	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	25/01/2022
17	335	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022
18	365	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	12/01/2022

FIGURE 1.8 : Données de stock – CE

Numéro d'enregistrement	C.P.S	annee	mois	jour	date	statut	Etablissement de sortie	date de sortie
1	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
2	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022
3	90	2022	janvier	1	01/01/2022	distribué	EPH public	04/01/2022
4	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022
5	85	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	05/01/2022
6	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022
7	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	03/01/2022
8	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
9	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	06/01/2022
10	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	04/01/2022
11	85	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	05/01/2022
12	85	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
13	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
14	85	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	03/01/2022
15	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
16	95	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	02/01/2022
17	90	2022	janvier	1	01/01/2022	jeté		09/01/2022
18	90	2022	janvier	1	01/01/2022	distribué	Hopital Khellil Amrane	06/01/2022

FIGURE 1.9 : Données de stock – CPS

1.2.3 Objectif de l'étude

L'objectif principal de cette étude est la prédiction de la demande en produits sanguins, notamment :

- les Concentrés d'Érythrocytes (CE) ;
- le Plasma Frais Congelé (PFC) ;
- les Concentrés Plaquettaires Standards (CPS).

Cette prédiction vise à améliorer la gestion des stocks sanguins, réduire les pertes liées à la péremption des produits et optimiser la disponibilité des produits sanguins au sein des établissements de santé. Pour atteindre cet objectif, des techniques de machine learning seront appliquées aux données historiques afin de construire des modèles prédictifs capables d'anticiper les besoins futurs en produits sanguins.

Conclusion

Ce chapitre a posé les bases de notre travail en présentant le cadre institutionnel et opérationnel dans lequel s'inscrit cette étude. Le Centre de Wilaya de Transfusion Sanguine de Béjaïa, unité du CHU de Béjaïa opérationnelle depuis 2000, assure un approvisionnement continu et sécurisé en produits sanguins labiles pour l'ensemble des structures de soins de la wilaya. Son organisation en quatre unités fonctionnelles, sa démarche qualité et son ancrage dans le dispositif transfusionnel algérien coordonné par l'Agence Nationale du Sang en font un établissement de référence.

Nous avons également décrit la démarche de collecte et de traitement des données issues des registres physiques du CWTS, qui a permis de constituer des datasets numériques fiables portant sur les trois produits sanguins étudiés : les Concentrés Érythro-

cytaires(CE), le Plasma Frais Congelé (PFC) et les Concentrés Plaquettaires Standards (CPS). Ces données couvrant une période de quatre années constituent le socle empirique sur lequel reposent les analyses et modélisations développées dans les chapitres suivants.

Dans le chapitre suivant, nous aborderons les fondements théoriques de la gestion des stocks, en mettant un accent particulier sur les spécificités des produits périssables tels que les produits sanguins.

CHAPITRE 2

Gestion des stocks et produits périssables

Introduction

La gestion des stocks constitue un domaine fondamental de la gestion des opérations et de la logistique. Elle concerne l'ensemble des méthodes et techniques permettant de planifier, organiser et contrôler les flux de produits au sein d'une organisation. L'objectif principal de la gestion des stocks est d'assurer la disponibilité des produits nécessaires tout en minimisant les coûts liés au stockage et à l'approvisionnement.

Dans le domaine de la santé, la gestion des stocks devient encore plus critique, notamment pour les produits médicaux sensibles tels que les médicaments et les produits sanguins. Ces produits présentent des contraintes spécifiques liées à leur durée de conservation limitée et aux conditions strictes de stockage. Une gestion optimale est donc nécessaire afin d'assurer la disponibilité des produits tout en réduisant les pertes liées à leur péremption.

Dans ce chapitre, nous présentons les notions fondamentales relatives à la gestion des stocks. Nous introduisons les concepts de base du stockage, les systèmes de gestion, les coûts associés ainsi que les modèles utilisés pour optimiser les décisions d'approvisionnement. Une attention particulière est également portée aux produits périssables et à la gestion des produits sanguins.

2.1 Le stock

Le stock peut être défini comme l'ensemble des biens détenus par une organisation en vue d'une utilisation future. Il constitue une réserve permettant de répondre aux fluctuations de la demande et aux incertitudes liées aux délais d'approvisionnement [3].

Dans les systèmes de production et de distribution, les stocks jouent plusieurs rôles importants :

- assurer la continuité des activités en cas de variations de la demande,
- compenser les délais d'approvisionnement,
- stabiliser les flux de production,
- améliorer le niveau de service offert aux utilisateurs.

Cependant, la présence de stocks entraîne également des coûts importants. Les organisations doivent donc déterminer un niveau de stock optimal permettant de garantir la disponibilité des produits tout en minimisant les coûts associés.

2.2 Gestion des stocks

La gestion des stocks regroupe l'ensemble des méthodes permettant de contrôler et d'optimiser les niveaux de produits disponibles dans un système logistique. Elle vise principalement à répondre aux questions suivantes :

- quelle quantité de produit doit être commandée ?
- quand faut-il passer une commande ?
- quel niveau de stock doit être maintenu pour éviter les ruptures ?

La gestion des stocks cherche à trouver un équilibre entre le coût de stockage et le niveau de service offert aux utilisateurs [4].

Une bonne gestion des stocks permet notamment :

- de réduire les coûts de stockage,
- d'éviter les ruptures de stock,
- d'améliorer la disponibilité des produits,
- d'optimiser l'utilisation des ressources.

2.3 Système de gestion des stocks

Un système de gestion des stocks correspond à l'ensemble des procédures et outils permettant de suivre les mouvements de produits dans un système logistique. Il permet

de contrôler les entrées et les sorties de produits ainsi que les quantités disponibles.

Les principales fonctions d'un système de gestion des stocks sont :

- l'enregistrement des entrées de produits,
- le suivi des sorties de produits,
- la surveillance des niveaux de stock,
- la planification des approvisionnements.

Avec le développement des technologies de l'information, les organisations utilisent aujourd'hui des systèmes informatisés permettant de suivre les stocks en temps réel et d'améliorer la précision des données.

2.4 Avantages et inconvénients du stockage

La constitution d'un stock présente plusieurs avantages. Elle permet notamment d'assurer la disponibilité des produits et de répondre rapidement aux besoins des utilisateurs.

Parmi les principaux avantages du stockage, on peut citer :

- la réduction des risques de rupture,
- l'amélioration du niveau de service,
- la possibilité de répondre rapidement à la demande.

Cependant, le stockage comporte également certains inconvénients tels que :

- les risques de détérioration des produits,
- les pertes dues à la péremption.

Ainsi, la gestion des stocks consiste à trouver un compromis entre la disponibilité des produits et la minimisation des coûts.

2.5 Les coûts de gestion des stocks

La gestion des stocks implique différents types de coûts qui doivent être pris en compte lors des décisions d'approvisionnement [5], à savoir :

2.5.1 Coût de commande

Le coût de commande correspond aux dépenses associées à la passation d'une commande. Il comprend les frais administratifs, les coûts de transport et les coûts liés à la réception des marchandises.

2.5.2 Coût de possession

Le coût de possession correspond aux dépenses liées au maintien des produits en stock. Il inclut notamment les frais d'entreposage, les coûts d'assurance et les pertes liées à la détérioration des produits.

2.5.3 Coût de rupture

Le coût de rupture correspond aux pertes associées à l'absence d'un produit en stock lorsque celui-ci est demandé.

2.6 Classification des stocks

La classification des stocks consiste à regrouper les produits en différentes catégories afin de faciliter leur gestion et leur contrôle. Cette classification permet d'identifier les produits les plus importants et d'adapter les méthodes de gestion en fonction de leur importance économique ou opérationnelle.

On distingue généralement les types de stocks suivants :

- **Stock de matières premières** : il s'agit des produits destinés à être transformés dans un processus de production.
- **Stock de produits en cours de fabrication** : ce type de stock correspond aux produits qui se trouvent à différentes étapes du processus de production.
- **Stock de produits finis** : il s'agit des produits prêts à être vendus ou distribués aux utilisateurs.
- **Stock de sécurité** : ce stock est maintenu afin de faire face aux fluctuations de la demande ou aux retards d'approvisionnement.
- **Stock de spéculation** : il est constitué lorsque l'organisation anticipe une augmentation future des prix ou une pénurie de produits.

La classification des stocks permet donc d'améliorer l'efficacité de la gestion en concentrant les efforts sur les produits les plus critiques pour l'organisation.

2.7 Analyse ABC

L'analyse ABC est une méthode de classification des stocks fondée sur le principe de Pareto, selon lequel une faible proportion des articles concentre l'essentiel de la valeur totale du stock [4]. Elle consiste à calculer, pour chaque article, sa valeur annuelle de consommation (quantité consommée $\times$ coût unitaire), puis à classer les articles par ordre décroissant de valeur afin de les répartir en trois classes. Cette hiérarchisation permet

d'adapter les efforts de gestion à l'importance économique de chaque groupe, le principe de l'analyse ABC est montré ci-dessous :

Soit un article i caractérisé par :

- Q_i : la quantité consommée sur une période donnée ;
- C_i : le coût unitaire de l'article.

La valeur annuelle de consommation de cet article est donnée par :

$$V_i = Q_i \times C_i$$

Une fois cette valeur calculée pour tous les articles, on classe les produits par ordre décroissant de V_i , puis on calcule les pourcentages cumulés.

2.7.1 Classes de l'analyse ABC

L'analyse ABC répartit généralement les articles en trois groupes :

- **Classe A** : elle regroupe un nombre réduit d'articles, souvent compris entre 10 % et 20 % du total, mais représentant environ 70 % à 80 % de la valeur totale du stock.
- **Classe B** : elle correspond à des articles d'importance intermédiaire, représentant souvent 20 % à 30 % des références et environ 15 % à 25 % de la valeur totale.
- **Classe C** : elle regroupe la majorité des articles, souvent 50 % à 70 % des références, mais ne représentant qu'une faible part de la valeur totale, généralement entre 5 % et 10 %.

Cette classification montre que tous les articles n'ont pas le même impact économique. Il n'est donc pas rationnel de consacrer le même niveau de contrôle à tous les produits [4].

2.7.2 Méthodologie de mise en œuvre de L'ABC

La mise en œuvre de l'analyse ABC suit généralement les étapes suivantes :

1. recenser l'ensemble des articles en stock ;
2. calculer la valeur de consommation de chaque article ;
3. classer les articles par ordre décroissant de valeur ;
4. calculer les pourcentages cumulés ;
5. affecter chaque article à la classe A, B ou C.

2.7.3 Intérêt de l'analyse ABC

L'analyse ABC présente plusieurs avantages :

- elle permet de concentrer les efforts de gestion sur les articles les plus importants ;
- elle facilite le contrôle des stocks et la planification des approvisionnements ;
- elle contribue à réduire les coûts de gestion ;

Dans les systèmes logistiques complexes, cette méthode constitue un outil simple mais efficace pour améliorer la performance du système de stockage.

2.7.4 Application de l'analyse ABC aux produits sanguins

Dans le contexte des produits sanguins, l'analyse ABC peut être utilisée pour identifier les groupes sanguins ou les types de produits les plus sollicités. Elle permet notamment de distinguer les produits à forte rotation ou à forte valeur d'usage, afin d'adapter les politiques d'approvisionnement et de stockage.

Toutefois, dans ce domaine, la simple valeur économique ne suffit pas. Il est souvent nécessaire de compléter l'analyse ABC par des critères liés à la péremption, à la criticité médicale et à la fréquence des demandes urgentes. Cela est particulièrement important dans les banques de sang, où l'objectif n'est pas uniquement économique, mais aussi sanitaire et humain.

2.7.5 Exemple d'application

Considérons la pharmacie d'un hôpital qui gère cinq produits médicaux. Pour chacun, on calcule la valeur annuelle de consommation $V_i = Q_i \times C_i$, puis on classe les articles par ordre décroissant de valeur.

Article	Quantité	Coût unit.	Valeur	% cumulé	Classe
Antibiotique injectable	140	500	70 000	70 %	A
Anticoagulant	200	100	20 000	90 %	B
Solution de perfusion	300	20	6 000	96 %	C
Compressees stériles	400	5	2 000	98 %	C
Seringues	500	4	2 000	100 %	C
Total			100 000		

On obtient ainsi trois classes :

- **Classe A** : l'antibiotique injectable, soit 20 % des articles mais 70 % de la valeur totale ;
- **Classe B** : l'anticoagulant, soit 20 % des articles et 20 % de la valeur ;
- **Classe C** : les trois articles restants, soit 60 % des articles mais seulement 10 % de la valeur.

Cet exemple illustre le principe de Pareto : l'effort de suivi doit être concentré en priorité sur l'article de classe A, qui représente à lui seul l'essentiel de la valeur du stock.

2.8 Politique de gestion de stock

Une politique de gestion de stock correspond à l'ensemble des règles et stratégies mises en place par une organisation afin de déterminer les quantités à commander ainsi que le moment approprié pour effectuer ces commandes [3].

L'objectif principal de ces politiques est de maintenir un niveau de stock suffisant pour répondre à la demande tout en minimisant les coûts liés au stockage et à l'approvisionnement.

Plusieurs politiques de gestion de stock peuvent être utilisées, parmi lesquelles :

- **La politique de réapprovisionnement périodique** : dans ce cas, les commandes sont passées à des intervalles de temps réguliers, indépendamment du niveau de stock.
- **La politique de point de commande** : une nouvelle commande est déclenchée lorsque le niveau de stock atteint un seuil prédéfini appelé point de commande.
- **La politique de stock de sécurité** : un niveau minimum de stock est maintenu afin de faire face aux incertitudes liées à la demande ou aux délais d'approvisionnement.

Le choix d'une politique de gestion dépend de plusieurs facteurs, notamment la variabilité de la demande, les délais d'approvisionnement et la nature des produits stockés.

Dans le cas des produits périssables, comme les produits sanguins, la politique de gestion doit également tenir compte de la durée de conservation des produits afin d'éviter les pertes liées à la péremption.

2.9 Règles de sortie des stocks : FIFO, LIFO et FEFO

Au-delà de la décision concernant la quantité et le moment d'approvisionnement, la gestion des stocks repose également sur des règles de sortie qui déterminent l'ordre dans lequel les unités sont prélevées. Ces règles ont un impact direct sur le taux de péremption, particulièrement dans le cas des produits périssables [10].

2.9.1 Règle FIFO (First In, First Out)

Selon la règle FIFO, les unités les plus anciennement entrées en stock sont les premières à être consommées. Cette règle est largement utilisée dans la gestion des produits périssables car elle minimise les pertes par péremption en assurant une rotation régulière du stock.

2.9.2 Règle LIFO (Last In, First Out)

À l'inverse, la règle LIFO consiste à consommer en priorité les unités les plus récemment entrées. Cette règle est rarement adaptée aux produits périssables car elle augmente le risque de péremption des unités anciennes restées en stock.

2.9.3 Règle FEFO (First Expired, First Out)

La règle FEFO consiste à prélever en priorité les unités dont la date de péremption est la plus proche. Contrairement à FIFO, qui se fonde sur la date d'entrée en stock, FEFO se fonde sur la date de péremption. Elle est particulièrement adaptée aux produits sanguins, dont les unités peuvent avoir des dates de péremption différentes selon leur date de prélèvement et leurs conditions de préparation. Son respect minimise les pertes par péremption tout en réservant les unités les plus fraîches aux usages où cela est critique [10].

Toutefois, certaines situations cliniques peuvent imposer des unités plus jeunes que prévu par le FEFO, par exemple pour les transfusions néonatales [13].

2.10 Modèles déterministes de gestion des stocks

Les modèles déterministes de gestion des stocks sont des modèles mathématiques dans lesquels les paramètres du système sont supposés connus avec certitude. En particulier, la demande, les délais d'approvisionnement, les coûts de commande et les coûts de possession sont considérés comme constants sur l'horizon d'étude [6].

Ces modèles sont largement utilisés en recherche opérationnelle pour analyser et optimiser les systèmes de gestion des stocks, car ils permettent d'obtenir des solutions analytiques simples et interprétables [6].

2.10.1 Hypothèses générales des modèles déterministes

Les modèles déterministes reposent généralement sur les hypothèses suivantes :

- la demande est connue et constante ;
- le délai d'approvisionnement est connu ;
- les coûts de commande et de stockage sont constants ;
- les ruptures de stock sont soit interdites ;
- le produit étudié est homogène.

Ces hypothèses permettent de simplifier le problème et d'obtenir des règles de décision optimales. Toutefois, elles ne reflètent pas toujours la réalité, en particulier dans le cas

des produits périssables ou dans les environnements soumis à une forte incertitude [5].

2.10.2 Modèle de la quantité économique de commande (EOQ)

Le modèle de la quantité économique de commande, également appelé modèle de Wilson ou EOQ (*Economic Order Quantity*), est l'un des modèles les plus classiques de gestion des stocks. Il permet de déterminer la quantité optimale à commander de manière à minimiser le coût total de gestion du stock [5].

Principe de EOQ

Le modèle EOQ cherche un compromis entre les deux coûts suivants :

- le coût de commande, qui diminue lorsque l'on commande de grandes quantités moins fréquemment ;
- le coût de possession, qui augmente lorsque la quantité stockée est importante.

L'idée est donc de déterminer une quantité de commande Q^* qui équilibre ces deux types de coûts.

L'évolution du niveau de stock dans ce modèle suit une forme caractéristique en dents de scie, illustrée par la figure 2.1.




FIGURE 2.1 : Évolution du niveau de stock dans le modèle EOQ.

Soient :

- D : la demande annuelle ;
- S : le coût fixe de commande ;
- H : le coût annuel de possession d'une unité ;
- Q : la quantité commandée.

Le coût total annuel est donné par :

$$CT(Q) = \frac{D}{Q}S + \frac{Q}{2}H \quad (2.1)$$

où :

- $\frac{D}{Q}S$ représente le coût annuel de commande ;
- $\frac{Q}{2}H$ représente le coût annuel de possession.

La quantité économique de commande est donnée par :

$$Q^* = \sqrt{\frac{2DS}{H}}$$

La figure 2.2 illustre la décomposition du coût total en fonction de la quantité commandée. La quantité optimale Q^* correspond au minimum de la courbe du coût total, point où le coût de commande et le coût de possession s'équilibrent.




FIGURE 2.2 : Décomposition des coûts dans le modèle EOQ et localisation de Q^* .

Interprétation

Cette formule montre que :

- plus la demande D est élevée, plus la quantité optimale augmente ;
- plus le coût de commande S est élevé, plus il est rentable de commander en grandes quantités ;
- plus le coût de possession H est élevé, plus la quantité optimale diminue.

Exemple

Considérons une pharmacie hospitalière qui s'approvisionne en seringues à usage unique. La consommation est régulière tout au long de l'année et le produit ne se périme pas, ce qui correspond bien aux hypothèses du modèle EOQ. On dispose des données suivantes :

- demande annuelle : $D = 1000$ unités/an ;
- coût de passation d'une commande : $S = 50$ u.m. ;
- coût de possession d'une unité : $H = 2$ u.m./an.

La quantité économique de commande est alors :

$$Q^* = \sqrt{\frac{2DS}{H}} = \sqrt{\frac{2 \times 1000 \times 50}{2}} = \sqrt{50000} \approx 223,6 \quad (2.2)$$

La pharmacie a donc intérêt à commander environ 224 seringues à chaque réapprovisionnement, ce qui minimise le coût total de gestion du stock.

2.10.3 Modèle de réapprovisionnement avec point de commande

Le modèle de réapprovisionnement avec point de commande repose sur l'idée qu'une nouvelle commande doit être déclenchée lorsque le niveau de stock atteint un certain seuil critique appelé point de commande [3].

Principe

Dans ce modèle, on ne commande pas à des dates fixes, mais dès que le stock disponible atteint un niveau déterminé à l'avance. Cette méthode est particulièrement utile lorsque les sorties de stock sont continues.

La figure 2.3 illustre le fonctionnement de cette politique. Lorsque le niveau de stock atteint le seuil R , une commande est déclenchée. Le stock continue à diminuer pendant le délai d'approvisionnement L , puis remonte à la réception de la commande.




FIGURE 2.3 : Modèle de gestion avec point de commande et stock de sécurité.

Soient :

- d : la demande moyenne par unité de temps ;
- L : le délai d'approvisionnement ;
- SS : le stock de sécurité.

Le point de commande R est généralement donné par :

$$R = dL + SS \quad (2.3)$$

où :

- dL représente la demande pendant le délai d'approvisionnement ;
- SS représente le stock de sécurité destiné à couvrir les incertitudes.

Interprétation

Lorsque le stock atteint le niveau R , une commande est déclenchée. Ainsi, le stock disponible est supposé suffire à couvrir la demande pendant toute la durée du délai d'approvisionnement.

Exemple

Reprenons le cas d'une pharmacie hospitalière qui gère ses poches de soluté physiologique. Le service en consomme régulièrement et le réapprovisionnement n'est pas instantané ; un stock de sécurité est donc maintenu pour absorber les variations de la demande. On dispose des données suivantes :

- demande moyenne journalière : $d = 10$ unités/jour ;
- délai d'approvisionnement : $L = 5$ jours ;
- stock de sécurité : $SS = 20$ unités.

Le point de commande est alors :

$$R = dL + SS = 10 \times 5 + 20 = 70 \text{ unités.} \quad (2.4)$$

Une nouvelle commande doit donc être déclenchée dès que le stock atteint 70 poches : les 50 unités correspondant à la demande pendant le délai de livraison, augmentées des 20 unités de sécurité couvrant les imprévus.

2.10.4 Modèle de production économique (EPQ)

Le modèle de production économique, ou EPQ (*Economic Production Quantity*), est une extension du modèle EOQ adaptée aux situations dans lesquelles le stock est ré-

approvisionné progressivement par une production interne plutôt que par une livraison instantanée [5].

Principe

Contrairement au modèle EOQ, dans lequel la commande arrive en une seule fois, le modèle EPQ suppose que les unités sont produites à un certain rythme P , tandis que la demande se poursuit à un rythme D , avec $P > D$.

Le niveau de stock augmente donc progressivement pendant la production, puis diminue sous l'effet de la consommation, comme illustré par la figure 2.4.




FIGURE 2.4 : Évolution du niveau de stock dans le modèle EPQ.

Formulation

La quantité économique de production est donnée par :

$$Q^* = \sqrt{\frac{2DS}{H \left(1 - \frac{D}{P}\right)}} \quad (2.5)$$

où :

- D : demande annuelle ;
- S : coût de lancement de production ;
- H : coût de possession unitaire ;
- P : taux de production.

Interprétation

Le terme $(1 - \frac{D}{P})$ traduit le fait que la production n'est pas instantanée. Plus le taux de production P est grand devant la demande D , plus le modèle se rapproche du modèle EOQ.

Exemple

Considérons une pharmacie hospitalière qui prépare elle-même des poches de nutrition parentérale. Ces poches ne sont pas commandées à un fournisseur mais produites en interne, par lots, à un rythme supérieur à celui de leur consommation. Le modèle EPQ s'applique alors avec les données suivantes :

- demande annuelle : $D = 1000$ unités/an ;
- coût de lancement d'un lot de production : $S = 40$ u.m. ;
- coût de possession d'une unité : $H = 2$ u.m./an ;
- taux de production : $P = 5000$ unités/an.

La quantité économique de production est alors :

$$Q^* = \sqrt{\frac{2DS}{H(1 - \frac{D}{P})}} = \sqrt{\frac{2 \times 1000 \times 40}{2(1 - \frac{1000}{5000})}} = \sqrt{\frac{80000}{1,6}} = \sqrt{50000} \approx 223,6 \quad (2.6)$$

La pharmacie a donc intérêt à lancer des lots d'environ 224 poches. Comme le taux de production (5000/an) est nettement supérieur à la demande (1000/an), le stock se reconstitue rapidement à chaque campagne de préparation.

2.10.5 Discussion des modèles déterministes

Les modèles déterministes constituent une base théorique importante en gestion des stocks. Leur principal intérêt réside dans leur simplicité, leur lisibilité et leur capacité à fournir rapidement des règles de décision.

Cependant, leurs hypothèses sont souvent restrictives. Dans le cas des produits périssables, et plus encore dans celui des produits sanguins, la demande n'est pas toujours stable, les durées de conservation sont limitées, et les décisions doivent intégrer des contraintes médicales et logistiques supplémentaires.

Par conséquent, ces modèles restent utiles comme point de départ théorique, mais doivent souvent être complétés par des approches plus réalistes, intégrant l'incertitude, la péremption et la dynamique temporelle.

2.11 Produits périssables

Les produits périssables sont des produits dont la durée de vie est limitée et qui peuvent se détériorer après une certaine période. Contrairement aux produits classiques, ces produits doivent être consommés ou utilisés avant une date limite afin d'éviter leur détérioration.

La gestion des stocks de produits périssables est particulièrement complexe en raison de plusieurs facteurs [13] :

- la durée de conservation limitée,
- la nécessité de respecter des conditions de stockage spécifiques,
- les pertes liées à la péremption des produits.

Dans ce contexte, les méthodes de gestion des stocks doivent prendre en compte la durée de vie des produits et les stratégies de rotation des stocks telles que les règles FIFO et FEFO présentées précédemment.

2.12 Gestion des produits sanguins

Les produits sanguins représentent un exemple typique de produits périssables. Ils sont essentiels pour le traitement de nombreuses pathologies et interventions médicales. Cependant, leur durée de conservation est limitée et ils doivent être stockés dans des conditions strictes afin de préserver leur qualité.

La gestion des stocks de produits sanguins présente plusieurs défis importants [13] :

- la variabilité de la demande,
- la durée de conservation limitée des produits,
- la nécessité de garantir la disponibilité pour les urgences médicales.

Les principaux produits sanguins labiles ainsi que leurs caractéristiques de conservation sont présentés dans le tableau 2.1.

TABLE 2.1 : Caractéristiques de conservation des principaux produits sanguins labiles.

Produit sanguin	Durée de conservation	Température de stockage
Concentré de globules rouges (CGR)	42 jours	2 – 6 °C
Concentré plaquettaire (CP)	5 – 7 jours	20 – 24 °C (sous agitation)
Plasma frais congelé (PFC)	1 an	≤ -25 °C
Sang total	35 jours	2 – 6 °C
Cryoprécipité	1 an	≤ -25 °C

Comme le montre le tableau 2.1, les durées de conservation varient considérablement d'un produit à l'autre [7]. Les concentrés plaquettaires constituent les produits les plus critiques en raison de leur très courte durée de vie, ce qui rend leur gestion particulièrement complexe. À l'inverse, le plasma frais congelé peut être stocké pendant une longue période, ce qui offre davantage de souplesse dans la gestion des stocks.

La chaîne d'approvisionnement des produits sanguins, illustrée par la figure 2.5, comporte plusieurs étapes successives, depuis la collecte auprès du donneur jusqu'à la transfusion au patient [14]. Chaque étape introduit des contraintes spécifiques : la qualification biologique impose un délai incompressible avant la libération des produits, la préparation génère plusieurs composants à partir d'un même don, et le stockage doit respecter des conditions de température strictes.




FIGURE 2.5 : Schéma simplifié de la chaîne d'approvisionnement des produits sanguins.

La complexité de cette chaîne, combinée à la péremption rapide des produits, justifie le recours à des outils de gestion adaptés. Une gestion efficace des stocks de produits sanguins est donc essentielle afin de réduire les pertes dues à la péremption tout en garantissant la disponibilité des produits pour les patients.

2.12.1 Variabilité de l'offre et de la demande en produits sanguins

La gestion des stocks de produits sanguins est rendue particulièrement difficile par une double incertitude : celle de la demande et celle de l'offre, qui évoluent souvent de manière non corrélée et parfois contradictoire [13].

Variabilité de la demande

La demande en produits sanguins se compose de deux parties distinctes. D'une part, une demande *prévisible*, associée aux interventions chirurgicales programmées et aux patients suivant un traitement régulier (par exemple, les patients atteints de pathologies hématologiques chroniques). D'autre part, une demande *aléatoire*, liée aux urgences vitales,

aux accidents et aux catastrophes, qui peut générer des pics de consommation difficiles à anticiper.

À cette variabilité s'ajoute une demande hospitalière qui peut être fortement influencée par un seul patient. En effet, certaines pathologies nécessitent des transfusions répétées, ce qui peut provoquer une augmentation significative de la demande annuelle d'un établissement [9].

Pour faire face à cette incertitude, des **modèles de prévision statistique** sont utilisés. Parmi les plus répandus figurent les modèles paramétriques de type Box-Jenkins, qui exploitent les séries temporelles historiques de distribution pour estimer la demande future [12]. Ces modèles permettent de réduire les erreurs d'estimation, d'améliorer l'équilibre des stocks entre les différents composés sanguins et, par conséquent, de diminuer à la fois les coûts et les pertes par péremption.

Variabilité de l'offre (les dons)

Du côté de l'offre, la variabilité est tout aussi marquée. Selon l'Organisation Mondiale de la Santé, environ 118,5 millions de dons de sang sont collectés chaque année dans le monde, mais leur répartition est très inégale : les pays à revenus élevés, qui représentent moins de 20 % de la population mondiale, concentrent près de 40 % des dons [8].

Au sein d'un même pays, l'évolution des dons dépend de plusieurs facteurs : campagnes de sensibilisation, politiques de recrutement, critères d'éligibilité et événements ponctuels (épidémies, voyages à l'étranger, etc.). Plusieurs études récentes mettent en évidence une tendance préoccupante : alors que la demande en produits sanguins augmente avec le vieillissement de la population, le nombre de *nouveaux donneurs* stagne ou diminue dans plusieurs pays européens [9].

TABLE 2.2 : Sources de variabilité dans la chaîne d'approvisionnement en produits sanguins.

Côté offre (dons)	Côté demande (transfusions)
Disponibilité des donneurs	Urgences vitales et accidents
Critères d'exclusion (santé, voyages)	Interventions chirurgicales programmées
Saisonnalité (été, fêtes)	Patients chroniques (hématologie)
Refus aux tests biologiques	Variabilité selon les groupes sanguins
Type de don (sang total, plasma, plaquettes)	Compatibilité ABO et Rhésus

Cette double variabilité justifie le recours à des outils de prévision sophistiqués et à des stratégies de gestion adaptées, capables d'absorber les fluctuations sans générer ni rupture ni gaspillage.

2.12.2 Causes de gaspillage et politiques de gestion adaptées

Le gaspillage des produits sanguins constitue une problématique majeure dans les banques de sang. Étant donné que le sang est un produit irremplaçable et issu de dons volontaires, toute unité perdue représente non seulement un coût économique, mais également une perte éthique et sanitaire.

Principales causes de gaspillage

Les travaux de Kurup et al. [15] identifient quatre causes principales de pertes :

- **Poches défectueuses** : défauts d'étanchéité, de fabrication ou d'étiquetage rendant l'unité inutilisable ;
- **Rupture de la chaîne du froid** : tout dépassement des plages de température autorisées entraîne le rejet du produit ;
- **Coagulation du sang** : prélèvements mal mélangés ou conservés dans des conditions inadéquates ;
- **Dépassement de la durée de conservation** (péremption) : cause majeure de pertes, en particulier pour les concentrés plaquettaires [7].

Parmi ces causes, la péremption est la plus difficile à maîtriser car elle dépend simultanément de la dynamique de l'offre, de la demande et des règles de sortie de stock. Selon Shokouhifar et al. [11], en moyenne **20 % des concentrés plaquettaires** sont jetés en raison de leur péremption, ce qui s'explique par leur très courte durée de vie (5 à 7 jours).

La règle FIFO classique et ses limites

Comme indiqué précédemment (section sur les règles de sortie), la politique *First In, First Out* (FIFO) est largement utilisée pour les produits périssables. Elle permet de minimiser les pertes par péremption en prélevant en priorité les unités les plus anciennes.

Cependant, certaines études cliniques suggèrent que l'utilisation d'unités plus jeunes (politique LIFO – *Last In, First Out*) pourrait améliorer l'état de santé du patient dans des situations particulières [10]. Le compromis entre FIFO et LIFO se résume comme suit : la méthode FIFO minimise les ruptures et les pénuries, mais augmente l'âge moyen de sortie ; la méthode LIFO minimise cet âge moyen, mais peut accroître les ruptures.

La méthode FIFO modifiée

Pour concilier ces deux objectifs antagonistes, Abbasi et Hosseiniard [10] ont proposé la méthode **FIFO modifiée**, dont le principe est illustré par la figure 2.6. Le stock est divisé en deux parties : un *stock récent* et un *stock ancien*. La règle FIFO est d'abord

appliquée au stock récent (afin de fournir des unités jeunes), puis au stock ancien une fois le premier épuisé.




FIGURE 2.6 : Schéma de fonctionnement de la politique FIFO modifiée, adaptée d’Abbasi et Hosseinifard [10].

Cette approche présente plusieurs avantages par rapport à la FIFO classique [10] :

- réduction de l’âge moyen de sortie des produits sanguins ;
- diminution du délai moyen avant péremption ;
- réduction des pénuries successives ;
- meilleure adéquation aux exigences cliniques (transfusion d’unités plus fraîches).

Synthèse comparative

Le tableau 2.3 résume les caractéristiques des trois principales politiques de sortie pour les produits sanguins.

TABLE 2.3 : Comparaison des politiques de sortie appliquées aux produits sanguins.

Critère	FIFO	LIFO	FIFO modifiée
Pertes par péremption	Faibles	Élevées	Faibles
Âge moyen de sortie	Élevé	Faible	Intermédiaire
Risque de rupture	Faible	Élevé	Faible
Adéquation clinique	Moyenne	Bonne	Bonne
Complexité de mise en œuvre	Simple	Simple	Modérée

Ces différentes politiques de sortie illustrent la nécessité, dans le cas des produits sanguins, d’aller au-delà des règles classiques de gestion des stocks. La péremption rapide, la variabilité de la demande et les exigences médicales spécifiques imposent en effet de combiner plusieurs approches afin d’atteindre simultanément les objectifs de disponibilité, de qualité et de minimisation des pertes.

Conclusion

Dans ce chapitre, nous avons présenté les notions fondamentales liées à la gestion des stocks. Nous avons introduit les concepts de base du stockage, les différents coûts associés ainsi que les modèles utilisés pour optimiser les décisions d'approvisionnement.

Nous avons également mis en évidence les particularités de la gestion des produits périssables, en particulier dans le contexte des produits sanguins. Ces produits présentent des contraintes spécifiques qui rendent leur gestion particulièrement complexe.

Ces concepts théoriques constituent une base importante pour l'étude de la gestion des stocks dans les banques de sang, qui sera abordée dans les chapitres suivants.

CHAPITRE 3

Réseau De Petri

3.1 Introduction

Les systèmes dynamiques à événements discrets occupent une place centrale dans la modélisation de nombreux systèmes artificiels et organisationnels, notamment dans les domaines industriels, logistiques, informatiques et hospitaliers [27, 17]. Leur évolution ne s'effectue pas de manière continue, mais à travers l'occurrence d'événements discrets tels qu'une arrivée, une demande, un transfert, une mise en attente ou une libération de ressource [17, 16].

Dans ce contexte, les réseaux de Pétri constituent un formalisme graphique et mathématique particulièrement adapté à la représentation et à l'analyse de tels systèmes [27, 19]. Ils permettent de décrire explicitement les états d'un système, les événements qui modifient ces états, ainsi que les relations de causalité, de concurrence, de synchronisation et de conflit qui existent entre ces événements [17].

L'intérêt des réseaux de Petri est renforcé lorsqu'il s'agit d'étudier des systèmes comportant :

- plusieurs processus pouvant évoluer simultanément ;
- des ressources partagées et limitées ;
- des décisions conditionnelles ;
- des comportements non déterministes ;
- des contraintes opérationnelles fortes.

Dans le cadre de notre travail, les réseaux de Pétri apparaissent comme un outil pertinent pour modéliser de manière rigoureuse la dynamique des stocks . Ils permettent non seulement de représenter le comportement du système, mais aussi d'en analyser plusieurs de ces propriétés structurelles et comportementales, telles que la bornitude, l'absence de blocage, la vivacité, les marquages accessibles ou encore l'existence d'états d'accueil [27, 17].

Ce chapitre présente ainsi les fondements des réseaux de Petri, leurs notations matricielles, leurs mécanismes d'évolution, leurs principales propriétés associées, ainsi que certaines extensions particulièrement utiles dans le cadre de la gestion intelligente des stocks de produits sanguins.

3.2 Définition d'un réseau de Petri

Un réseau de Petri est un graphe biparti orienté composé de deux types de nœuds : les places et les transitions. Formellement, un réseau de Pétri marqué est défini par le 5-uplet :

$$PN = (P, T, F, W, M_0)$$

où :

- $P = \{p_1, p_2, \dots, p_m\}$ est un ensemble fini de **places** ;
- $T = \{t_1, t_2, \dots, t_n\}$ est un ensemble fini de **transitions** ;
- F est l'ensemble des **arcs** ;
- $W : F \rightarrow \mathbb{N}^*$ est une fonction de **pondération** associant à chaque arc un poids strictement positif ;
- $M_0 : P \rightarrow \mathbb{N}$ est le **marquage initial**, c'est-à-dire la répartition initiale des jetons dans les places [17, 18].

Dans un réseau de Pétri, les places représentent généralement des états, des conditions ou des ressources, tandis que les transitions modélisent les événements ou actions susceptibles de modifier l'état du système. Les arcs expriment les relations de précédence ou de conséquence entre places et transitions. Enfin, les jetons traduisent la présence d'une condition ou la disponibilité d'une ressource [27, 17].

3.2.1 Illustration générale d'un réseau de Petri

La Figure 3.1 présente les principaux éléments constitutifs d'un réseau de Pétri : une place, une transition, un arc orienté et un jeton.




FIGURE 3.1 : Éléments généraux d'un réseau de Petri : places, transition, arc et jetons.

3.2.2 Règles de sensibilisation et de franchissement

On note $\bullet t$ l'ensemble des places d'entrée d'une transition t et $t^\bullet$ l'ensemble de ses places de sortie.

Définition 3.1. Sensibilisation : Une transition $t \in T$ est dite **sensibilisée** au marquage M si chaque place d'entrée de t contient un nombre de jetons au moins égal au poids de l'arc correspondant. Formellement :

$$\forall p \in P, \quad M(p) \geq W(p, t)$$

où $W(p, t)$ représente le poids de l'arc allant de la place p vers la transition t . Par convention, si l'arc $p \rightarrow t$ n'existe pas, on considère que $W(p, t) = 0$ [27].

Définition 3.2. Franchissement : Si une transition t est sensibilisée au marquage M , alors son franchissement conduit à un nouveau marquage M' défini, pour toute place $p \in P$, par :

$$M'(p) = M(p) - W(p, t) + W(t, p).$$

Autrement dit, le franchissement retire des jetons dans les places d'entrée et ajoute des jetons dans les places de sortie selon les poids des arcs [27, 17].

Ainsi, la dynamique d'un réseau de Petri repose sur l'alternance entre l'identification des transitions sensibilisées et le franchissement de l'une d'entre elles.

3.2.3 Exemple de RDP appliqué à un stock borné de produits sanguins

Afin d'illustrer les notions fondamentales exposées précédemment, nous considérons un modèle simple de gestion d'un stock de produits sanguins.

Description

On modélise un stock de produits sanguins disposant d'une capacité maximale égale à 3 poches. Le système comprend :

- une place p_S représentant le *stock disponible* ;
- une place p_C représentant la *capacité libre*.

Trois transitions sont considérées :

- t_R : *réception* d'une unité de produit sanguin ;
- t_D : *délivrance* d'une unité pour satisfaire une demande ;
- t_E : *expiration* d'une unité arrivée à péremption.

Le marquage initial est donné par :

$$M_0(p_S) = 2, \quad M_0(p_C) = 1$$

ce qui signifie qu'au départ, le stock contient 2 unités et qu'il reste 1 emplacement libre. Tous les arcs sont supposés de poids égal à 1.

RDP correspondant




FIGURE 3.2 : Réseau de Petri simplifié d'un stock borné de produits sanguins. Le marquage initial est $M_0 = (2, 1)$, où p_S représente le stock disponible et p_C la capacité libre.

Ce modèle simple permet d'illustrer plusieurs notions fondamentales :

- la **bornitude**, grâce à la contrainte de capacité ;
- le **conflit**, entre délivrance et péremption ;
- l'**accessibilité** des différents marquages du stock ;
- le **graphe d'accessibilité**.

3.3 Notations matricielles

Les réseaux de Petri peuvent être représentés de manière algébrique à l'aide de notations matricielles. Cette représentation permet de formaliser l'évolution du marquage, d'écrire l'équation d'état et d'étudier certaines propriétés structurales du réseau [18].

3.3.1 Vecteur de marquage

En numérotant les places selon l'ordre (p_S, p_C) , le marquage du réseau s'écrit sous la forme d'un vecteur colonne :

$$\mathbf{M} = \begin{bmatrix} M(p_S) \\ M(p_C) \end{bmatrix} \in \mathbb{N}^2.$$

Le marquage initial vaut alors :

$$\mathbf{M}_0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

3.3.2 Matrices d'incidence avant et matrice d'incidence arrière

En numérotant les transitions selon l'ordre (t_R, t_D, t_E) , on définit :

$$Pre(i, j) = W(p_i, t_j), \quad Post(i, j) = W(t_j, p_i).$$

La matrice Pre indique le nombre de jetons retirés des places lors du franchissement d'une transition, tandis que la matrice $Post$ indique le nombre de jetons ajoutés [27].

Pour le réseau de la Figure 3.2, on obtient :

$$Pre = \begin{bmatrix} 0 & 1 & 1 \\ 1 & 0 & 0 \end{bmatrix}, \quad Post = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 1 \end{bmatrix}.$$

3.3.3 Matrice d'incidence

La matrice d'incidence globale est définie par :

$$C = Post - Pre.$$

Dans notre exemple :

$$C = \begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & 1 \end{bmatrix}.$$

Cette matrice traduit la variation du marquage après le franchissement de chaque transition [27, 17].

3.3.4 Équation d'état

Si la transition t_j est franchie, le nouveau marquage s'écrit :

$$\mathbf{M}' = \mathbf{M} + C_{.j},$$

où $C_{.j}$ désigne la j -ième colonne de la matrice d'incidence.

De manière plus générale, si $\sigma \in \mathbb{N}^3$ désigne le vecteur d'occurrence d'une séquence de franchissements, l'équation fondamentale s'écrit :

$$\mathbf{M} = \mathbf{M}_0 + C\sigma.$$

Cette équation permet de calculer, sans parcourir explicitement tout le réseau, le marquage obtenu après une séquence complète de franchissements [27, 18].

3.3.5 Exemple d'application

Considérons la séquence :

$$\sigma = t_R t_D.$$

Son vecteur d'occurrence est :

$$\boldsymbol{\sigma} = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix},$$

car t_R est franchie une fois, t_D est franchie une fois, et t_E n'est pas franchie.

On calcule alors :

$$C\boldsymbol{\sigma} = \begin{bmatrix} 1 & -1 & -1 \\ -1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Ainsi :

$$\mathbf{M} = \mathbf{M}_0 + C\boldsymbol{\sigma} = \begin{bmatrix} 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Cela signifie qu'après une réception suivie d'une sortie, le système revient au marquage initial. Cet exemple montre l'intérêt de l'approche matricielle pour modéliser et analyser rapidement l'évolution du stock.

3.4 Évaluation d'un réseau de Pétri : sensibilisation, franchissement et accessibilité

3.4.1 Sensibilisation et franchissement des transitions

L'évolution d'un réseau de Petri repose sur deux notions fondamentales : la **sensibilisation** et le **franchissement** des transitions, déjà introduit dans la section 3.2.2 Une transition est dite **sensibilisée** lorsqu'elle peut être franchie à partir du marquage courant. Cette condition est satisfaite lorsque chaque place d'entrée de la transition contient un nombre de jetons suffisant pour autoriser son exécution. Autrement dit, pour qu'une transition soit sensibilisée, toutes les ressources ou conditions qu'elle requiert doivent être disponibles.

D'un point de vue formel, une transition $t \in T$ est sensibilisée au marquage M si :

$$\forall p \in P, \quad M(p) \geq W(p, t),$$

où $W(p, t)$ désigne le poids de l'arc reliant la place p à la transition t [27, 17].

Lorsque cette condition est vérifiée, la transition peut alors être **franchie**. Le franchissement correspond à l'occurrence effective de l'événement modélisé par la transition. Il entraîne une modification du marquage du réseau :

- des jetons sont retirés des places d'entrée, selon les poids des arcs entrants ;
- des jetons sont ajoutés aux places de sortie, selon les poids des arcs sortants.

Ainsi, le franchissement d'une transition traduit le passage d'un état du système à un autre. Il représente donc le mécanisme dynamique fondamental des réseaux de Pétri.

Mathématiquement, si une transition t est sensibilisée au marquage M , son franchissement conduit à un nouveau marquage M' défini par :

$$M'(p) = M(p) - W(p, t) + W(t, p), \quad \forall p \in P.$$

La sensibilisation et le franchissement permettent ainsi de décrire l'évolution séquentielle du réseau. À chaque instant, seules les transitions sensibilisées sont susceptibles d'être franchies, ce qui garantit que le comportement du modèle respecte les contraintes structurelles et logiques du système représenté [27, 17].

3.4.2 Séquences de franchissements

Définition 3.3. Séquence de franchissements : Une séquence de franchissements est une suite ordonnée de transitions :

$$\sigma = t_{i_1} t_{i_2} \dots t_{i_k}.$$

On note :

$$M_0[\sigma]M$$

pour signifier que le marquage M est atteignable à partir du marquage initial M_0 par l'exécution de la séquence σ [17].

Exemple 3.1. À partir du marquage initial

$$\mathbf{M}_0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix},$$

on observe que :

- t_R est sensibilisée, et son franchissement donne

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} [t_R] \begin{bmatrix} 3 \\ 0 \end{bmatrix};$$

— t_D est sensibilisée, et son franchissement donne

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} [t_D] \begin{bmatrix} 1 \\ 2 \end{bmatrix} ;$$

— t_E est également sensibilisée, et son franchissement donne

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix} [t_E] \begin{bmatrix} 1 \\ 2 \end{bmatrix} .$$

3.4.3 Marquage accessible

Définition 3.4. Marquage accessible : Un marquage M est dit **accessible** à partir de M_0 s'il existe une séquence de franchissements σ telle que :

$$M_0[\sigma]M.$$

3.4.4 Ensemble des marquages accessibles

Définition 3.5. Ensemble des marquages accessibles : L'ensemble de tous les marquages accessibles à partir de M_0 est noté :

$$R(M_0) = \{M \mid \exists \sigma, M_0[\sigma]M\}.$$

Dans notre exemple illustratif 3.2.3, la capacité totale étant égale à 3 pochettes, les marquages accessibles sont :

$$R(M_0) = \left\{ \begin{bmatrix} 0 \\ 3 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 \\ 0 \end{bmatrix} \right\}.$$

3.4.5 Graphe des marquages accessibles

Définition 3.6. Graphe d'accessibilité : Le graphe d'accessibilité est un graphe orienté dont :

- les sommets représentent les marquages accessibles ;
- les arcs représentent les transitions franchissables permettant de passer d'un marquage à un autre.

Autrement dit, il existe un arc étiqueté par t de M vers M' si et seulement si $M[t]M'$ [27, 17].

Le graphe d'accessibilité constitue un outil central d'analyse. Il permet :




FIGURE 3.3 : Graphe d'accessibilité du RDP de l'exemple 3.2.3.

- de recenser tous les états atteignables du système ;
- d'identifier d'éventuels états terminaux ;
- de vérifier si certaines situations indésirables sont accessibles ;
- d'étudier la vivacité, la bornitude ou l'absence de blocage.

3.4.6 Graphe de recouvrabilité

Lorsque le réseau n'est pas borné, l'ensemble des marquages accessibles peut être infini. Dans ce cas, on a recours au **graphe de recouvrabilité**, qui introduit un symbole ω afin de représenter une croissance non bornée du nombre de jetons dans certaines places [17].

Dans le cadre de la gestion des stocks, une telle situation peut apparaître si l'on autorise des arrivées illimitées sans contrainte de capacité. D'un point de vue opérationnel, un tel modèle serait peu réaliste ; c'est pourquoi l'introduction explicite d'une capacité maximale joue un rôle essentiel dans la modélisation.

3.5 Conflit et parallélisme

3.5.1 Conflit

Définition 3.7. Deux transitions t_1 et t_2 sont en **conflit** au marquage M si elles sont toutes les deux sensibilisées en M mais qu'elles ne peuvent pas être franchies simultanément, en raison d'une compétition pour un ou plusieurs jetons communs [27, 17].

Exemple 3.2. Considérons une place p contenant un seul jeton et deux transitions t_1 et t_2 partageant cette même place en entrée. Les deux transitions sont alors sensibilisées tant que le jeton est présent dans p . Cependant, le franchissement de t_1 consomme ce jeton et empêche immédiatement le franchissement de t_2 , et inversement. Les transitions t_1 et t_2 sont donc en conflit.

3.5.2 Parallélisme

Définition 3.8 (Parallélisme / concurrence). Deux transitions sont dites **concurrentes** si elles peuvent être sensibilisées et franchies sans interférer l'une avec l'autre, c'est-à-dire sans compétition sur les mêmes jetons [27, 17].

Exemple 3.3. Considérons deux places distinctes p_1 et p_2 , chacune contenant un jeton, ainsi que deux transitions t_1 et t_2 telles que t_1 consomme uniquement le jeton de p_1 et t_2 consomme uniquement le jeton de p_2 . Les deux transitions peuvent alors être sensibilisées et franchies indépendamment l'une de l'autre, sans compétition sur une ressource commune. Elles sont donc parallèles.

3.6 Propriétés d'un réseau de Petri

Les propriétés structurelles et comportementales des réseaux de Petri jouent un rôle fondamental dans l'analyse de la sûreté et du bon fonctionnement du système modélisé [21].

3.6.1 Bornitude

Définition 3.9. Un réseau de Petri est dit k -**borné** si, pour tout marquage accessible M et toute place p , on a :

$$M(p) \leq k.$$

Il est dit **borné** s'il existe un entier fini k satisfaisant cette propriété [17].

Dans le cas du réseau de la Figure 3.2, on a :

$$M(p_S) \in \{0, 1, 2, 3\},$$

ce qui montre que la place représentant le stock est bornée. Plus précisément, le réseau est 3-borné.

Exemple 3.4 (Exemple simple de bornitude). Considérons une place représentant une capacité maximale de stockage égale à 3. Si, dans tous les marquages accessibles, le nombre de jetons de cette place reste inférieur ou égal à 3, alors cette place est 3-bornée. Dans notre exemple 3.2.3, le stock disponible ne peut jamais dépasser la capacité totale du système, ce qui garantit la bornitude du réseau.

3.6.2 Invariant de places

Les invariants de places constituent un outil classique pour démontrer la bornitude d'un réseau [17].

Un vecteur $\mathbf{y} \in \mathbb{N}^m$ est un P -invariant si :

$$\mathbf{y}^T C = 0.$$

Dans notre exemple 3.2.3, en prenant :

$$\mathbf{y} = \begin{bmatrix} 1 \\ 1 \end{bmatrix},$$

on vérifie que :

$$\mathbf{y}^T C = 0.$$

Il en résulte que :

$$M(p_S) + M(p_C) = \text{constante} = 3.$$

Cette relation exprime que la somme entre le stock disponible et la capacité libre reste constante au cours du temps. Elle formalise le fait que la capacité totale du système est conservée.

3.6.3 Blocage et réseau sans blocage

Définition 3.10. Blocage : Un marquage M est avec **blocage** s'il n'existe aucune transition sensibilisée en M .

Définition 3.11. Réseau sans blocage : Un réseau est dit **sans blocage** si aucun marquage accessible n'est pas avec blocage [27, 17].

Dans notre exemple 3.2.3 :

- si $M(p_S) = 0$, alors $M(p_C) = 3$ et la transition t_R est sensibilisée ;
- si $M(p_C) = 0$, alors $M(p_S) = 3$ et les transitions t_D et t_E sont sensibilisées ;
- pour les autres marquages, au moins une transition reste franchissable.

Le réseau est donc sans blocage.

3.6.4 Vivacité

Définition 3.12. Un réseau est dit **vivant** si, quelle que soit l'évolution réalisée, il reste toujours possible, après éventuellement d'autres franchissements, de faire franchir n'importe quelle transition du réseau [27, 17].

Dans le modèle de l'exemple 3.2.3, aucune transition ne devient définitivement impossible. On peut toujours alterner des opérations de réception avec des opérations de sortie, ce qui garantit que les transitions t_R , t_D et t_E restent potentiellement franchissables au cours de l'évolution. Le réseau est donc vivant.

Exemple 3.5 (Exemple simple de vivacité). Supposons un système cyclique où une transition de réception alimente le stock, puis une transition de délivrance retire une unité,

avant qu'une nouvelle réception puisse de nouveau avoir lieu. Si, depuis n'importe quel état accessible, il existe toujours une séquence permettant de rendre chaque transition franchissable à nouveau, alors le réseau est vivant. Dans notre exemple, réception, délivrance et expiration peuvent réapparaître au cours de l'évolution, ce qui traduit la vivacité du modèle.

3.6.5 État d'accueil

Définition 3.13. Un marquage M_h est appelé **état d'accueil** si, depuis tout marquage accessible M , il existe une séquence de franchissements permettant d'atteindre M_h [27, 17].

Dans notre exemple 3.2.3, le marquage

$$M_0 = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

peut être considéré comme un état d'accueil. En effet :

— depuis

$$\begin{bmatrix} 0 \\ 3 \end{bmatrix},$$

deux franchissements successifs de t_R permettent de revenir à M_0 ;

— depuis

$$\begin{bmatrix} 3 \\ 0 \end{bmatrix},$$

un franchissement de t_D ou de t_E permet de revenir à

$$\begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

Cette propriété traduit que ce marquage est réinitialisable.

3.7 Extensions des réseaux de Petri

Les réseaux de Petri ordinaires sont puissants, mais ils peuvent devenir insuffisants lorsque le système étudié comporte des données complexes, des règles métier élaborées, des contraintes logiques particulières ou des durées aléatoires. Plusieurs extensions ont ainsi été proposées [27, 17, 21].

3.7.1 Réseaux de Petri colorés

Principe général. Dans un réseau de Petri coloré, les jetons ne sont plus indiscernables. Chaque jeton transporte une *valeur typée*, appelée *couleur*. Cette extension permet de représenter plusieurs catégories d’objets dans un même réseau sans multiplier inutilement les places et les transitions [20].

Les réseaux de petri colorés sont particulièrement intéressants lorsque les entités manipulées possèdent des attributs propres.

Exemple 3.6 (Exemple inspiré du domaine hospitalier). Dans un contexte hospitalier, un jeton peut représenter un patient ou une entité contenant plusieurs informations, telles qu’un identifiant, un nom, une date de naissance ou un service d’affectation [27].

Dans le cadre de la gestion des stocks de produits sanguins, un jeton coloré peut représenter une unité de produit enrichie par plusieurs attributs :

`Produit = (id, type, groupe, dateExp, site).`

Exemple 3.7 (ColoredPetriNet pour produits sanguins). Une place p_S peut contenir un multiensemble de jetons représentant plusieurs produits sanguins. Une transition *Délivrer* peut alors sélectionner uniquement les jetons compatibles avec une demande donnée, par exemple selon le groupe sanguin ou la date de péremption. Une garde logique peut être associée à la transition :

`compatible(demande.groupe, produit.groupe).`

Les réseaux colorés offrent ainsi une représentation plus compacte et plus fidèle des ces systèmes réels.

3.7.2 Réseaux de Petri à arcs spéciaux

Principe général. Certaines extensions reposent sur l’introduction d’arcs particuliers permettant d’exprimer des conditions de contrôle qu’un réseau ordinaire ne peut représenter aisément. On distingue notamment [27] :

- les **arcs inhibiteurs** ;
- les **arcs de lecture** ;
- les **arcs de vidange**.

Arcs inhibiteurs. Un arc inhibiteur relie une place à une transition en imposant une condition d’absence de jetons. La transition n’est franchissable que si la place concernée est vide.

Exemple 3.8 (Alerte de rupture). Soit une place p_S représentant le stock disponible. En reliant p_S à une transition t_A par un arc inhibiteur, on peut modéliser le déclenchement automatique d’une alerte lorsque le stock devient nul. La transition t_A n’est alors franchissable que si $M(p_S) = 0$.

Arcs de lecture. Un arc de lecture permet de tester la présence de jetons dans une place sans les consommer. Il est utile lorsqu’une décision dépend d’une information disponible sans pour autant modifier la ressource correspondante [27].

Arcs de vidange. Un arc de vidange permet de retirer en une seule fois tous les jetons présents dans une place. Un tel mécanisme peut servir à modéliser une opération de purge, de retrait complet ou d’annulation massive [27].

Ces arcs spéciaux sont utiles pour représenter des règles de gestion avancées, par exemple :

- l’interdiction de lancer une opération si une ressource est déjà occupée ;
- le déclenchement d’une alerte de rupture ;
- le contrôle d’un seuil ou d’une condition logique sans consommer la ressource testée.

3.7.3 Schéma des différents arcs spéciaux




FIGURE 3.4 : Illustration simplifiée des principaux arcs spéciaux dans les réseaux de Pétri.

3.7.4 Réseaux de Petri stochastiques

Principe général. Les réseaux de Petri stochastiques (SPN) constituent une extension des réseaux de Petri classiques dans laquelle les transitions sont associées à des délais aléatoires. Cette extension a été introduite pour modéliser des systèmes faisant intervenir des

phénomènes incertains et pour permettre l'évaluation quantitative de leurs performances [22].

Dans un SPN, une transition ne se franchit plus instantanément dès qu'elle est sensibilisée. Elle est tirée après un délai probabiliste décrit par une variable aléatoire. Lorsque plusieurs transitions sont simultanément sensibilisées, le choix de la transition effectivement franchie dépend alors des délais stochastiques associés [27].

Intérêt des SPN. Les SPN sont particulièrement utiles lorsque l'on souhaite répondre à des questions quantitatives telles que :

- à quel moment un état sera atteint ;
- combien de temps le système reste dans un état donné ;
- avec quelle probabilité une situation critique survient ;
- quel est le niveau moyen d'occupation d'une ressource ;
- quelle est la probabilité de rupture ou de perte.

Ils sont ainsi largement utilisés pour l'évaluation des performances, souvent en lien avec les chaînes de Markov lorsque les délais suivent une loi exponentielle [22, 23].

Exemple classique : lampe. Un exemple classique de réseau de Petri stochastique est celui d'une lampe pouvant se trouver dans trois états :

- *Off* : lampe éteinte ;
- *On* : lampe allumée ;
- *Failed* : lampe en panne.

Le comportement du système peut être décrit comme suit :

- lorsque la lampe est éteinte, elle peut être allumée ;
- lorsque la lampe est allumée, elle peut soit être éteinte, soit tomber en panne ;
- lorsqu'elle tombe en panne, elle est remplacée après extinction.

Dans cet exemple, les délais associés aux transitions peuvent être modélisés par des lois exponentielles de paramètres α , β , μ et λ selon qu'il s'agit respectivement d'allumage, d'extinction, de panne ou de réparation [27].

Classes de SPN. On distingue plusieurs classes de réseaux de Petri stochastiques [27] :

- les **GSPN** (*Generalized Stochastic Petri Nets*), qui combinent transitions immédiates et transitions stochastiques exponentielles [22, 23] ;
- les **DSPN** (*Deterministic and Stochastic Petri Nets*), qui ajoutent des transitions déterministes ;




FIGURE 3.5 : Illustration simplifiée d'un réseau de Petri stochastique pour une lampe.

- les **ESPN** (*Extended Stochastic Petri Nets*), dans lesquels les temporisations peuvent suivre des lois de probabilité plus générales [23].

Application des SPN à la gestion des stocks de produits sanguins. Dans le cadre de la gestion intelligente des stocks de produits sanguins, les SPN permettent de représenter des phénomènes aléatoires très importants :

- l'arrivée des demandes hospitalières ;
- les délais variables de réapprovisionnement ;
- les temps de qualification ou de traitement ;
- la péremption des produits [25] ;
- les variations de consommation selon les périodes.

On peut, par exemple, associer :

- à la transition t_D un taux λ représentant l'arrivée des demandes ;
- à la transition t_R un taux μ représentant le réapprovisionnement ;
- à la transition t_E un taux θ représentant la péremption.

Le modèle permet alors d'estimer des indicateurs de performance tels que :

- la probabilité de rupture de stock ;
- le taux de gaspillage dû aux péremptions ;
- le taux de service rendu aux patients ;
- le niveau moyen du stock ;
- le temps moyen passé par le système dans un état critique.

Apport des SPN pour ce mémoire. L'intérêt des SPN dans ce travail réside dans la modélisation et l'analyse à savoir le fait qu'ils permettent de dépasser une simple analyse qualitative du comportement du stock. Ils rendent possible une analyse quantitative de la performance du système étudié, ce qui est essentiel lorsqu'il s'agit d'optimiser la disponibilité des produits sanguins tout en limitant les pertes.

3.8 Conclusion

Dans ce chapitre, nous avons présenté les réseaux de Petri comme un formalisme rigoureux et particulièrement adapté à la modélisation des systèmes dynamiques à événements discrets. Après avoir introduit leur définition formelle, nous avons précisé les notions fondamentales de place, transition, jeton et marquage, puis détaillé les mécanismes de sensibilisation et de franchissement.

Nous avons ensuite étudié les notations matricielles, qui permettent une représentation algébrique du comportement du réseau, ainsi que les notions de séquence de franchissements, de marquage accessible, d'ensemble des marquages accessibles et de graphe d'accessibilité. L'exemple d'un stock borné de produits sanguins a permis d'illustrer de manière concrète ces différents concepts.

Par ailleurs, nous avons examiné plusieurs propriétés essentielles des réseaux de Petri, notamment la bornitude, l'absence de blocage, la vivacité et l'existence d'un état d'accueil. Ces propriétés jouent un rôle fondamental dans l'analyse de la sûreté et du bon fonctionnement du système modélisé.

Enfin, nous avons présenté plusieurs extensions des réseaux de Petri, à savoir les réseaux colorés, les réseaux à arcs spéciaux et les réseaux stochastiques. Ces extensions apparaissent particulièrement utiles dans le cadre de la gestion intelligente des stocks de produits sanguins, car elles permettent d'intégrer à la fois la diversité des données manipulées, les règles de décision complexes et l'incertitude inhérente aux demandes, aux délais et aux péremptions.

Ainsi, les réseaux de Petri constituent une base solide pour la modélisation et l'analyse du système étudié dans ce mémoire, et ouvrent la voie à une représentation plus fine des mécanismes de gestion, d'optimisation et d'aide à la décision dans les chapitres suivants.

CHAPITRE 4

Machine Learning et Deep Learning

Introduction

Le Machine Learning, ou apprentissage automatique, est une branche de l'intelligence artificielle qui vise à concevoir des systèmes capables d'apprendre automatiquement à partir des données. Contrairement à la programmation classique, où les règles sont explicitement définies par le programmeur, le Machine Learning permet à la machine d'identifier des structures, des régularités et des relations à partir d'exemples afin de produire des prédictions ou de prendre des décisions sur de nouvelles données [39].

L'essor du Machine Learning est étroitement lié à l'augmentation de la quantité de données disponibles, à l'amélioration des capacités de calcul et au développement d'algorithmes plus performants. Aujourd'hui, ces méthodes sont utilisées dans de nombreux domaines, tels que la santé, la finance, l'industrie, la cybersécurité, la reconnaissance d'images et la prévision de séries temporelles [47].

Dans le domaine de la santé, le Machine Learning est mobilisé pour assister les médecins dans le diagnostic de maladies, analyser les dossiers médicaux ou encore détecter des anomalies dans des images radiologiques. En logistique et en gestion, il permet de prévoir la demande, optimiser les stocks et améliorer l'aide à la décision. Dans le cadre de ce mémoire, ces techniques occupent une place importante, car elles permettent d'exploiter les données historiques afin d'anticiper les besoins futurs et d'améliorer la gestion des ressources.

Le présent chapitre a pour objectif de présenter les notions fondamentales du Machine Learning et du Deep Learning. Nous introduirons d'abord une définition générale du Machine Learning, puis les principaux types d'apprentissage. Ensuite, nous détaillerons les algorithmes supervisés et non supervisés les plus utilisés dans la littérature, avant de terminer par une introduction au Deep Learning.

4.1 Définition du Machine Learning

Le Machine Learning peut être défini comme un ensemble de méthodes mathématiques et algorithmiques permettant à un système informatique d'apprendre à partir des données afin d'améliorer progressivement ses performances sur une tâche donnée [39].

De manière formelle, l'objectif est de construire une fonction f capable d'associer une entrée x à une sortie y , comme indiqué ci-dessous :

$$f(x) = y \quad (4.1)$$

où x représente les données d'entrée et y la sortie attendue.

Dans cette approche, l'algorithme n'est pas programmé pour résoudre explicitement chaque situation. Il apprend à partir d'un ensemble d'exemples et tente de généraliser les connaissances acquises à de nouvelles observations. Cette propriété constitue l'un des principaux intérêts du Machine Learning, notamment dans les problèmes complexes pour lesquels il est difficile d'écrire des règles fixes [40].

Le processus général d'apprentissage automatique comporte généralement trois étapes principales :

- **la phase d'apprentissage** : le modèle est construit à partir des données d'entraînement ;
- **la phase de validation** : les performances du modèle sont ajustées afin d'éviter le surapprentissage ;
- **la phase de test** : le modèle est évalué sur des données non vues afin de mesurer sa capacité de généralisation.

La capacité d'un modèle à bien performer sur des données nouvelles, non vues lors de l'apprentissage, est appelée **généralisation**. C'est l'objectif central de tout algorithme d'apprentissage automatique. En pratique, deux phénomènes indésirables peuvent compromettre cette capacité :

- **Le surapprentissage (*overfitting*)** : le modèle apprend trop fidèlement les données d'entraînement, y compris leur bruit et leurs particularités, au point de perdre toute capacité de généralisation. L'erreur sur les données d'entraînement est alors très faible, tandis que l'erreur sur les données de test est élevée.
- **Le sous-apprentissage (*underfitting*)** : le modèle est trop simple pour capturer les relations réelles présentes dans les données. L'erreur reste élevée aussi bien sur les données d'entraînement que sur les données de test.

L'objectif est donc de trouver un équilibre entre ces deux extrêmes, ce que l'on appelle

le **compromis biais-variance**. C'est précisément le rôle de la phase de validation : ajuster la complexité du modèle afin d'obtenir la meilleure généralisation possible sur des données inédites.

4.2 Préparation des données

Avant tout apprentissage, les données doivent être préparées afin d'assurer la qualité et la fiabilité du modèle. Cette étape, souvent appelée *prétraitement*, conditionne fortement la performance des algorithmes [39].

4.2.1 Division des données

L'ensemble des données est généralement divisé en trois sous-ensembles :

- **ensemble d'entraînement** (typiquement 60 à 80%) : utilisé pour ajuster les paramètres du modèle ;
- **ensemble de validation** (typiquement 10 à 20%) : utilisé pour ajuster les hyperparamètres ;
- **ensemble de test** (typiquement 10 à 20%) : utilisé uniquement pour l'évaluation finale.

4.2.2 Normalisation et standardisation

Les variables peuvent présenter des échelles très différentes, ce qui perturbe la convergence de nombreux algorithmes. Deux techniques sont couramment utilisées :

Normalisation min-max : ramène les valeurs dans l'intervalle $[0, 1]$:

$$x' = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \quad (4.2)$$

Standardisation (Z-score) : centre les valeurs sur zéro avec un écart-type unitaire :

$$x' = \frac{x - \mu}{\sigma} \quad (4.3)$$

où μ et σ sont respectivement la moyenne et l'écart-type de la variable.

4.2.3 Validation croisée

La validation croisée, ou *k-fold cross-validation*, consiste à diviser les données en k sous-ensembles. Le modèle est entraîné k fois, chaque fois en utilisant $k - 1$ sous-ensembles pour

l'entraînement et le sous-ensemble restant pour la validation. La performance globale est alors la moyenne des k performances obtenues. Cette technique permet une évaluation plus fiable du modèle, particulièrement lorsque la quantité de données est limitée.

4.3 Métriques d'évaluation

L'évaluation d'un modèle de Machine Learning repose sur des indicateurs adaptés au type de tâche. Deux familles principales sont utilisées : les métriques de régression et les métriques de classification [40].

4.3.1 Métriques pour la régression

Pour les problèmes de régression, où la sortie est une valeur continue, les principales métriques sont :

Erreur absolue moyenne (MAE) :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (4.4)$$

Erreur quadratique moyenne (MSE) :

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad (4.5)$$

Racine de l'erreur quadratique moyenne (RMSE) :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (4.6)$$

Erreur absolue moyenne en pourcentage (MAPE) :

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{y_i - \hat{y}_i}{y_i} \right| \times 100 \quad (4.7)$$

4.3.2 Métriques pour la classification

Pour les problèmes de classification, l'évaluation repose sur la matrice de confusion, qui croise les prédictions du modèle avec la réalité [40] :

TABLE 4.1 : Matrice de confusion pour la classification binaire.

	Prédit positif	Prédit négatif
Réel positif	VP (vrai positif)	FN (faux négatif)
Réel négatif	FP (faux positif)	VN (vrai négatif)

À partir de cette matrice, on définit :

Exactitude (Accuracy) :

$$Accuracy = \frac{VP + VN}{VP + VN + FP + FN} \quad (4.8)$$

Précision :

$$Précision = \frac{VP}{VP + FP} \quad (4.9)$$

Rappel (Recall) :

$$Rappel = \frac{VP}{VP + FN} \quad (4.10)$$

F1-Score :

$$F1 = 2 \times \frac{Précision \times Rappel}{Précision + Rappel} \quad (4.11)$$

Le choix de la métrique dépend du contexte applicatif : dans le domaine médical, le rappel est souvent privilégié car il mesure la capacité à détecter les cas positifs (par exemple, ne pas manquer un patient nécessitant une transfusion urgente).

4.4 Types de Machine Learning

Le Machine Learning se divise généralement en trois grandes catégories selon la nature des données disponibles et l'objectif poursuivi [39]. L'apprentissage supervisé repose sur des données étiquetées, c'est-à-dire des données pour lesquelles la sortie attendue est connue. L'apprentissage non supervisé opère quant à lui sur des données non étiquetées, et vise à découvrir des structures cachées. Enfin, l'apprentissage par renforcement repose sur un mécanisme d'interaction entre un agent et son environnement, guidé par un système de récompenses.

La figure 4.1 illustre schématiquement ces trois grandes familles.




FIGURE 4.1 : Les trois grandes familles d'apprentissage automatique.

Chacune de ces catégories, ainsi que les principaux algorithmes qui s'y rattachent, est présentée en détail dans les sections suivantes.

4.5 Algorithmes de l'apprentissage supervisé

L'apprentissage supervisé consiste à entraîner un modèle à partir de données étiquetées, c'est-à-dire des données pour lesquelles la sortie correcte est connue. Chaque observation est représentée par un couple (x_i, y_i) , où x_i représente les variables d'entrée et y_i la sortie attendue.

L'objectif est d'apprendre une fonction telle que :

$$f(x) \approx y \quad (4.12)$$

Cette approche est particulièrement adaptée aux problèmes où l'on dispose d'un historique de données annotées. On distingue deux grands types de tâches en apprentissage supervisé [40] :

- **la classification**, lorsque la variable cible est qualitative ;
- **la régression**, lorsque la variable cible est quantitative.

4.5.1 Régression

Définition

La régression est une méthode d'apprentissage supervisé utilisée pour prédire une variable quantitative continue. Elle vise à modéliser la relation entre une variable dépendante et une ou plusieurs variables explicatives [40].

Principe

Dans le cas simple de la régression linéaire, la relation entre la variable d'entrée x et la variable de sortie y est donnée par l'équation suivante :

$$y = ax + b \quad (4.13)$$

où :

- a représente la pente de la droite ;
- b représente l'ordonnée à l'origine.

L'objectif de l'apprentissage est de déterminer les valeurs optimales des paramètres a et b afin de minimiser l'erreur entre les valeurs prédites et les valeurs réelles. Cette idée est illustrée par la figure 4.2.




FIGURE 4.2 : Régression linéaire : ajustement d'une droite à un nuage de points.

Le principe de cette méthode d'apprentissage peut être résumé comme suit :

Algorithme 1 : Principe de la régression

```

1 Initialisation : Initialiser les paramètres  $a$  et  $b$ ;
2 repeat
3   // Étape 1 : Prédiction;
4   Calculer les prédictions;
5   // Étape 2 : Évaluation;
6   Mesurer l'erreur entre les valeurs prédites et observées;
7   // Étape 3 : Optimisation;
8   Mettre à jour les paramètres  $a$  et  $b$ ;
9 until convergence;
10 Retourner les paramètres finaux  $a$  et  $b$ ;

```

Variantes de la régression

Plusieurs variantes existent selon la nature du problème [40] :

- **Régression linéaire multiple** : lorsque plusieurs variables explicatives sont prises en compte, l'équation devient $y = a_1x_1 + a_2x_2 + \dots + a_nx_n + b$.
- **Régression polynomiale** : permet de modéliser des relations non linéaires en ajoutant des termes de puissances supérieures.
- **Régression logistique** : malgré son nom, il s'agit en réalité d'un algorithme de *classification* qui estime la probabilité d'appartenance à une classe à l'aide de la fonction sigmoïde.

4.5.2 Algorithme des k plus proches voisins (KNN)

Définition

L'algorithme des k plus proches voisins, noté KNN (*K-Nearest Neighbors*), est un algorithme supervisé utilisé pour les problèmes de classification et, dans certains cas, de régression. Il repose sur l'idée qu'une observation a tendance à appartenir à la même classe que ses voisins les plus proches [40].

Principe

Pour classer une nouvelle donnée, l'algorithme calcule la distance entre cette donnée et les observations de l'ensemble d'apprentissage. Les k observations les plus proches sont ensuite identifiées, et la classe majoritaire parmi ces voisins est attribuée à la nouvelle observation.

La distance euclidienne est l'une des distances les plus utilisées [40] :

$$d(x_i, x_j) = \sqrt{\sum_{k=1}^n (x_{ik} - x_{jk})^2} \quad (4.14)$$

Algorithme 2 : Algorithme des K-plus proches voisins (KNN)

```

1 Entrées : Ensemble d'apprentissage  $X = \{(x_1, y_1), \dots, (x_N, y_N)\}$ , nouveau point
    $x_{test}$ , nombre de voisins  $K$ ;
2 // Étape 1 : Calcul des distances;
3 for chaque observation  $(x_i, y_i) \in X$  do
4    $d_i \leftarrow d(x_{test}, x_i)$ ;
5 // Étape 2 : Sélection;
6 Trier les observations de  $X$  selon les distances  $d_i$  croissantes;
7  $V_K \leftarrow$  les  $K$  observations les plus proches de  $x_{test}$ ;
8 // Étape 3 : Vote majoritaire;
9 for chaque classe  $c$  do
10    $N_c \leftarrow$  nombre d'observations dans  $V_K$  appartenant à la classe  $c$ ;
11  $\hat{y} \leftarrow \arg \max_c N_c$ ;
12 Retourner la classe prédite  $\hat{y}$ ;

```

Exemple simple

On considère les données médicales suivantes :

Température	Tension	Classe
38	14	Urgent
39	15	Urgent
36	12	Non urgent
37	13	Non urgent

On souhaite classer un nouveau patient $P(38, 13)$ avec $k = 3$. Les distances euclidiennes entre P et les points d'apprentissage sont :

$$\begin{aligned}
d(P, P_1) &= \sqrt{(38 - 38)^2 + (13 - 14)^2} = 1 \\
d(P, P_2) &= \sqrt{(38 - 39)^2 + (13 - 15)^2} = \sqrt{5} \approx 2.23 \\
d(P, P_3) &= \sqrt{(38 - 36)^2 + (13 - 12)^2} = \sqrt{5} \approx 2.23 \\
d(P, P_4) &= \sqrt{(38 - 37)^2 + (13 - 13)^2} = 1
\end{aligned}$$

Conclusion : Les trois plus proches voisins ($k = 3$) sont les patients P_1 (Urgent), P_4 (Non urgent) et P_2 (Urgent). Le vote majoritaire donne 2 « Urgent » contre 1 « Non urgent ». Le patient est donc classé comme **Urgent**.

4.5.3 Support Vector Machine (SVM)

Définition

Les machines à vecteurs de support, ou SVM (*Support Vector Machines*), sont des algorithmes supervisés utilisés principalement pour la classification. Leur objectif est de trouver un hyperplan séparant les données de différentes classes avec la marge maximale [41].

Principe

Dans le cas binaire, le SVM cherche une frontière de séparation définie par l'équation [41] :

$$w \cdot x + b = 0 \quad (4.15)$$

où :

- w est le vecteur des poids ;
- b est le biais.

Le SVM maximise la distance entre l'hyperplan séparateur et les points les plus proches, appelés *vecteurs de support*. La figure 4.3 illustre ce principe.




FIGURE 4.3 : Principe du SVM : hyperplan séparateur à marge maximale.

Algorithme 3 : Algorithme des SVM

```

1 Entrées : Données d'apprentissage  $X = \{(x_1, y_1), \dots, (x_N, y_N)\}$  avec
    $y_i \in \{-1, 1\}$ , nouveau point  $x_{test}$ ;
2 // Phase d'apprentissage : Recherche de l'hyperplan optimal;
3 Trouver le vecteur de poids  $w$  et le biais  $b$  tels que ;;
4 Minimiser  $\|w\|$ ;
5 s.c.  $y_i(w \cdot x_i + b) \geq 1$  pour tout  $i \in \{1 \dots N\}$ ;
6 // Phase d'identification;
7 Définir les vecteurs de support comme les points  $x_i$  où  $y_i(w \cdot x_i + b) = 1$ ;
8 // Phase de classification;
9 Calculer la prédiction :  $\hat{y} \leftarrow \text{sign}(w \cdot x_{test} + b)$ ;
10 Retourner la classe prédite  $\hat{y}$ ;

```

Exemple simple

Considérons les observations suivantes réparties en deux classes :

- **Classe +1 :** $A(2, 2)$ et $B(2, 4)$;
- **Classe -1 :** $C(6, 2)$ et $D(6, 4)$.

Etape 1. Détermination de la frontière : La séparation optimale (marge maximale) se situe à mi-chemin entre les deux groupes de points, soit sur la droite verticale d'équation :

$$x_1 = 4$$

Sous sa forme canonique $w \cdot x + b = 0$, cette frontière s'écrit :

$$1 \cdot x_1 + 0 \cdot x_2 - 4 = 0$$

Etape 2. Évaluation d'un nouveau point : Soit un nouveau point $x = (4, 3)$. On calcule sa valeur de décision $f(x)$:

$$f(x) = (1 \times 4) + (0 \times 3) - 4 = 0$$

Conclusion : Comme $f(x) = 0$, le point est situé exactement sur la frontière de séparation. S'il avait été supérieur à 0, il serait classé +1, et inférieur à 0, classé -1.

4.5.4 Arbre de décision

Définition

Un arbre de décision est un modèle supervisé qui représente les décisions sous forme d'une structure arborescente composée de nœuds, de branches et de feuilles. Chaque nœud correspond à un test sur une variable, chaque branche à un résultat possible, et chaque feuille à une décision finale [40].

Principe

L'idée est de diviser récursivement les données selon les variables les plus discriminantes, jusqu'à obtenir des groupes homogènes. Les critères utilisés pour choisir les variables de séparation sont notamment l'entropie, le gain d'information ou l'indice de Gini [40].

Algorithme 4 : Construction d'un Arbre de Décision

```

1 Entrées : Ensemble de données  $S$ ;
2 // Étape 1 : Condition d'arrêt;
3 if toutes les observations de  $S$  ont la même classe ou aucune division utile n'est
   possible then
4   | Retourner un nœud feuille avec cette classe;
5 // Étape 2 : Choix de la variable de séparation;
6  $v^* \leftarrow$  variable qui sépare le mieux les données de  $S$ ;
7 // Étape 3 : Division;
8 Diviser  $S$  en sous-ensembles  $S_1, \dots, S_m$  selon la variable  $v^*$ ;
9 // Étape 4 : Répétition récursive;
10 for  $i \leftarrow 1 \dots m$  do
11   | Répéter l'algorithme sur le sous-ensemble  $S_i$ ;
12 Retourner l'arbre de décision généré;
```

Exemple

Considérons les données suivantes :

Hémoglobine basse	Hémorragie	Décision
Oui	Oui	Urgent
Oui	Non	Urgent
Non	Oui	Urgent
Non	Non	Non urgent

L'arbre de décision correspondant est représenté par la figure 4.4.




FIGURE 4.4 : Arbre de décision construit à partir des données médicales.

Ce type de modèle est particulièrement apprécié pour sa lisibilité et sa facilité d'interprétation.

Méthodes ensemblistes des arbres de décision

Les arbres de décision pris isolément sont sensibles au surapprentissage et aux variations des données. Pour pallier ce problème, des méthodes dites *ensemblistes* ont été développées : elles combinent plusieurs modèles afin d'obtenir une prédiction plus robuste et plus précise [40]. Deux grandes familles se distinguent :

- le **Bagging** (Bootstrap Aggregating), qui construit plusieurs modèles indépendants en parallèle et combine leurs prédictions (ex. : Random Forest) [42] ;
- le **Boosting**, qui construit les modèles de manière séquentielle, chaque nouveau modèle corrigeant les erreurs du précédent (ex. : XGBoost, CatBoost) [43].

Random Forest

Définition. L'algorithme Random Forest (forêt aléatoire), introduit par Breiman en 2001, est une méthode ensembliste fondée sur le bagging. Il construit un grand nombre d'arbres de décision indépendants, chacun entraîné sur un sous-échantillon aléatoire des données (tirage avec remise), puis agrège leurs prédictions [42].

Principe. Deux sources d'aléatoire sont introduites pour diversifier les arbres et réduire leur corrélation :

- **Bootstrap** : chaque arbre est entraîné sur un sous-ensemble tiré aléatoirement avec remise parmi les données d'apprentissage ;
- **Sélection aléatoire des variables** : à chaque nœud, seul un sous-ensemble aléatoire de m variables (avec $m \ll p$ où p est le nombre total de variables) est considéré pour la division.

La prédiction finale est obtenue par :

- **vote majoritaire** pour la classification ;
- **moyenne des prédictions** pour la régression :

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x) \quad (4.16)$$

où T est le nombre d'arbres et $f_t(x)$ la prédiction du t -ième arbre [42].

Algorithme 5 : Algorithme Random Forest

```

1 Entrées : Données  $D = \{(x_i, y_i)\}_{i=1}^N$ , nombre d'arbres  $T$ , nombre de variables
   par nœud  $m$ ;
2 for  $t \leftarrow 1$  to  $T$  do
3   // Étape 1 : Sous-échantillonnage (bootstrap);
4    $D_t \leftarrow$  tirage aléatoire avec remise de  $N$  exemples de  $D$ ;
5   // Étape 2 : Construction de l'arbre;
6   Construire un arbre  $f_t$  sur  $D_t$  en choisissant à chaque nœud un sous-ensemble
   aléatoire de  $m$  variables;
7 // Étape 3 : Agrégation;
8 Régression :  $\hat{y} \leftarrow \frac{1}{T} \sum_{t=1}^T f_t(x)$ ;
9 Retourner  $\hat{y}$ ;
```

Hyperparamètres clés.

- T : nombre d'arbres (plus T est grand, plus le modèle est stable, mais plus le coût de calcul augmente) ;
- m : nombre de variables sélectionnées aléatoirement à chaque nœud (valeur recommandée : $m = \sqrt{p}$ en classification, $m = p/3$ en régression) ;
- `max_depth` : profondeur maximale de chaque arbre (contrôle le surapprentissage).

Avantages et limites [42].

- + Robuste au surapprentissage grâce à la diversité des arbres ;
- + Fournit une mesure d'importance des variables ;
- + Peu sensible aux valeurs aberrantes et aux données manquantes ;
- Moins performant que le boosting sur des données tabulaires structurées ;
- Modèle difficile à interpréter (boîte noire).

XGBoost

Définition. XGBoost (*eXtreme Gradient Boosting*), développé par Chen et Guestrin en 2016, est une implémentation optimisée du Gradient Boosting. Il construit des arbres de décision de manière séquentielle, chaque nouvel arbre étant entraîné pour corriger les résidus du modèle précédent [43].

Principe du Gradient Boosting. L'idée fondatrice est d'exprimer la prédiction comme une somme de T arbres :

$$\hat{y}_i = \sum_{t=1}^T f_t(x_i), \quad f_t \in \mathcal{F} \quad (4.17)$$

où $\mathcal{F}$ est l'espace des arbres de régression. À chaque itération t , on ajoute un nouvel arbre f_t qui minimise la fonction objectif régularisée :

$$\mathcal{L}^{(t)} = \sum_{i=1}^n \ell\left(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)\right) + \Omega(f_t) \quad (4.18)$$

où ℓ est une fonction de perte différentiable (par exemple le MSE) et $\Omega(f_t)$ est un terme de régularisation qui pénalise la complexité de l'arbre [43] :

$$\Omega(f_t) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (4.19)$$

avec γ et λ des paramètres de régularisation, T le nombre de feuilles et w_j le score de la feuille j .

Spécificités d'XGBoost [43]. XGBoost introduit plusieurs innovations par rapport au Gradient Boosting classique :

- **Régularisation intégrée** (termes L_1 et L_2) pour limiter le surapprentissage ;
- **Traitement natif des valeurs manquantes** : l'algorithme apprend automatiquement la meilleure direction à prendre pour les données manquantes ;
- **Calcul parallèle** sur la construction des arbres, ce qui le rend nettement plus rapide que le Gradient Boosting classique ;
- **Élagage des arbres** en profondeur d'abord (*depth-first pruning*), contrairement à la croissance nœud par nœud des autres implémentations.

Algorithme 6 : Algorithme XGBoost

```

1 Entrées : Données  $D$ , nombre d'itérations  $T$ , taux d'apprentissage  $\eta$ ;
2 Initialiser  $\hat{y}_i^{(0)} = 0$  pour tout  $i$ ;
3 for  $t \leftarrow 1$  to  $T$  do
4   // Étape 1 : Calcul des gradients et hessiens;
5   for chaque observation  $i$  do
6      $g_i \leftarrow \frac{\partial \ell(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}}$ ;
7      $h_i \leftarrow \frac{\partial^2 \ell(y_i, \hat{y}_i^{(t-1)})}{\partial (\hat{y}_i^{(t-1)})^2}$ ;
8   // Étape 2 : Construction du nouvel arbre;
9   Construire  $f_t$  en maximisant le gain de chaque division :
      Gain =  $\frac{1}{2} \left[ \frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$ ;
10  // Étape 3 : Mise à jour;
11  for chaque observation  $i$  do
12     $\hat{y}_i^{(t)} \leftarrow \hat{y}_i^{(t-1)} + \eta \cdot f_t(x_i)$ ;
13 Retourner  $\hat{y}^{(T)}$ ;

```

Avantages et limites [43].

- + Très haute performance sur les données tabulaires ;
- + Régularisation intégrée qui réduit le surapprentissage ;
- + Gestion native des valeurs manquantes ;
- + Calcul parallèle et optimisé en mémoire ;
- Sensible au choix des hyperparamètres, nécessite un réglage fin ;
- Moins adapté aux variables catégorielles non encodées.

CatBoost

Définition. CatBoost (*Categorical Boosting*) est un algorithme de Gradient Boosting conçu spécifiquement pour gérer efficacement les **variables catégorielles** sans prétraitement manuel [44]. Il repose sur une technique originale appelée *Ordered Boosting* qui réduit significativement le biais de prédiction.

Traitement des variables catégorielles. Le traitement des variables catégorielles est la principale innovation de CatBoost. Là où XGBoost nécessite un encodage préalable (one-hot encoding, label encoding), CatBoost applique un encodage statistique conditionnel appelé *Target Statistics* (TS) [44] :

$$\hat{x}_k^i = \frac{\sum_{j < i} \mathbf{1}[x_k^j = x_k^i] \cdot y_j + a \cdot P}{\sum_{j < i} \mathbf{1}[x_k^j = x_k^i] + a} \quad (4.20)$$

où P est la moyenne globale de la cible, a est un paramètre de lissage, et la somme porte sur les exemples ordonnés *avant* l'exemple courant.

Ordered Boosting [44]. Dans le Gradient Boosting classique, les résidus sont calculés sur les mêmes données que celles utilisées pour construire le modèle, ce qui introduit un biais de fuite (*target leakage*). CatBoost y remédie en utilisant une permutation aléatoire des données : le résidu de l'exemple i est calculé à partir d'un modèle entraîné uniquement sur les exemples qui le précèdent dans la permutation.

Algorithme 7 : Algorithme CatBoost (Ordered Boosting)

```

1 Entrées : Données  $D$ , nombre d'itérations  $T$ , taux d'apprentissage  $\eta$ ;
2 // Étape 1 : Permutation aléatoire;
3 Générer  $s$  permutations aléatoires  $\sigma_1, \dots, \sigma_s$  de  $\{1, \dots, n\}$ ;
4 // Étape 2 : Encodage ordonné des variables catégorielles;
5 for chaque variable catégorielle  $k$  et chaque exemple  $i$  do
6   | Calculer  $\hat{x}_k^i$  par Target Statistics sur les exemples précédant  $i$  dans la
   | permutation;
7 // Étape 3 : Construction des arbres;
8 Initialiser  $\hat{y}_i^{(0)} = 0$  pour tout  $i$ ;
9 for  $t \leftarrow 1$  to  $T$  do
10  | for chaque observation  $i$  do
11  |   |  $r_i^{(t)} \leftarrow -\frac{\partial \ell(y_i, \hat{y}_i^{(t-1)})}{\partial \hat{y}_i^{(t-1)}}$ ;
12  | Construire un arbre symétrique  $f_t$  sur les résidus;
13  | for chaque observation  $i$  do
14  |   |  $\hat{y}_i^{(t)} \leftarrow \hat{y}_i^{(t-1)} + \eta \cdot f_t(x_i)$ ;
15 Retourner  $\hat{y}^{(T)}$ ;

```

Avantages et limites [44].

- + Gestion native et optimale des variables catégorielles (sans encodage manuel) ;
- + Ordered Boosting qui réduit le biais et le surapprentissage ;
- + Très bonnes performances avec peu de réglage d'hyperparamètres ;
- + Robuste aux données hétérogènes (mélange de variables numériques et catégorielles) ;

- Temps d’entraînement plus long que XGBoost sur de très grands jeux de données numériques purs ;
- Moins flexible pour les tâches nécessitant un contrôle fin de la structure des arbres.

Ces méthodes ensemblistes sont largement utilisées dans les compétitions de Machine Learning et dans les applications industrielles, notamment pour la **prévision de la demande** et la **détection d’anomalies** [43, 42].

4.6 Apprentissage non supervisé

L’apprentissage non supervisé est une approche du Machine Learning dans laquelle le modèle ne dispose d’aucune sortie connue à l’avance. Contrairement à l’apprentissage supervisé, les données ne sont pas étiquetées : l’objectif est de découvrir automatiquement des structures cachées, des groupes homogènes ou des relations entre les observations [40].

Formellement, on dispose d’un ensemble de données :

$$X = \{x_1, x_2, \dots, x_n\} \quad (4.21)$$

et l’objectif est de regrouper les observations selon leur similarité.

Cette approche est particulièrement adaptée aux problèmes de [45] :

- regroupement de données similaires (clustering) ;
- segmentation ;
- détection d’anomalies ;
- réduction de dimensionnalité.

4.6.1 Algorithme K-means

Définition

L’algorithme K-means est une méthode de clustering qui vise à partitionner un ensemble de données en K groupes distincts, appelés clusters. Chaque cluster est représenté par un centre appelé centroïde [45].

Principe


Le principe de K-means consiste à minimiser la somme des distances entre les points et le centre de leur cluster. L’algorithme repose sur un processus itératif [45] :

Algorithme 8 : Algorithme des K-means

```

1 Initialisation : choisir  $K$  points de  $X$  aléatoirement comme centres initiaux
    $\mu_1, \mu_2, \dots, \mu_K$ 
2 repeat
3   // Étape 1 : Affectation;
4   for chaque point  $x_i \in X$  do
5      $c_i \leftarrow \arg \min_k d(x_i, \mu_k)$ ;
6   // Étape 2 : Mise à jour des centres;
7   for  $k \leftarrow 1 \dots K$  do
8      $\mu_k \leftarrow \frac{1}{|C_k|} \sum_{x_i \in C_k} x_i$ ;
9 until les centres  $\mu_k$  ne changent plus;
10 Retourner les clusters  $C_1, \dots, C_K$ ;

```

**FIGURE 4.5 :** Résultat du K-means avec deux clusters et leurs centroïdes.**Exemple simple**

On considère l'ensemble de points suivants, pour lesquels on choisit $K = 2$:

$$A(1, 1), \quad B(2, 1), \quad C(4, 3), \quad D(5, 4)$$

Étape 1 : Initialisation

On choisit les centres initiaux :

$$C_1 = (1, 1), \quad C_2 = (5, 4)$$

Étape 2 : Calcul des distances et affectation

— **Pour le point $B(2, 1)$:**

$$\begin{aligned} d(B, C_1) &= \sqrt{(2-1)^2 + (1-1)^2} = 1 \\ d(B, C_2) &= \sqrt{(2-5)^2 + (1-4)^2} = \sqrt{18} \approx 4.24 \end{aligned}$$

Donc B appartient au cluster 1.

— **Pour le point $C(4, 3)$:**

$$\begin{aligned} d(C, C_1) &= \sqrt{(4-1)^2 + (3-1)^2} = \sqrt{13} \approx 3.6 \\ d(C, C_2) &= \sqrt{(4-5)^2 + (3-4)^2} = \sqrt{2} \approx 1.41 \end{aligned}$$

Donc C appartient au cluster 2.

Après affectation :

— Cluster 1 : $\{A, B\}$

— Cluster 2 : $\{C, D\}$

Étape 3 : Recalcul des centres

$$\begin{aligned} C_1 &= \left(\frac{1+2}{2}, \frac{1+1}{2} \right) = (1.5, 1) \\ C_2 &= \left(\frac{4+5}{2}, \frac{3+4}{2} \right) = (4.5, 3.5) \end{aligned}$$

Conclusion L'algorithme K-means permet de regrouper les données en clusters homogènes en fonction de leur proximité. Il est largement utilisé en analyse de données pour identifier des groupes naturels au sein d'un ensemble d'observations [45].

4.6.2 Clustering hiérarchique

Définition

Le clustering hiérarchique est une méthode de classification non supervisée qui permet de construire une hiérarchie de clusters sous forme d'arbre appelé dendrogramme [45].

Principe

Le principe repose sur la fusion progressive des clusters [45] :

- chaque observation est initialement un cluster ;
- les clusters les plus proches sont fusionnés ;

— le processus est répété jusqu'à obtenir un seul cluster.

Algorithme 9 : Clustering Hiérarchique (Classification Ascendante)

```

1 Entrées : Ensemble de données  $X = \{x_1, \dots, x_N\}$ ;
2 // Étape 1 : Initialisation;
3 for chaque observation  $x_i \in X$  do
4   | Créer un cluster  $C_i \leftarrow \{x_i\}$ ;
5  $\mathcal{C} \leftarrow \{C_1, \dots, C_N\}$ ;
6 // Étapes 2 et 3 : Fusions successives;
7 repeat
8   | Trouver la paire de clusters  $(C_a, C_b)$  qui minimise  $d(C_a, C_b)$ ;
9   |  $C_{\text{nouveau}} \leftarrow C_a \cup C_b$ ;
10  | Retirer  $C_a$  et  $C_b$  de  $\mathcal{C}$ ;
11  | Ajouter  $C_{\text{nouveau}}$  à  $\mathcal{C}$ ;
12 until l'ensemble  $\mathcal{C}$  ne contient plus qu'un seul cluster;
13 Retourner la hiérarchie finale (dendrogramme);

```

Conclusion Le clustering hiérarchique permet de visualiser la structure des données et d'analyser les relations entre les observations. Il est particulièrement utile pour l'analyse exploratoire des données [45].

4.7 Apprentissage par renforcement

L'apprentissage par renforcement est une approche du Machine Learning dans laquelle un agent apprend à prendre des décisions en interagissant avec un environnement. Contrairement à l'apprentissage supervisé, aucune réponse correcte n'est fournie à l'avance : l'agent explore par essais et erreurs, en recevant à chaque action une récompense ou une pénalité [46].

L'objectif est de déterminer une politique optimale, c'est-à-dire une stratégie de décision permettant de maximiser la récompense cumulée au cours du temps.

Cette approche est particulièrement adaptée aux problèmes nécessitant une optimisation séquentielle, tels que la robotique, le contrôle de systèmes, les jeux, ou encore — dans le cadre de ce mémoire — la gestion dynamique des stocks de produits sanguins, où les décisions d'approvisionnement doivent s'adapter en permanence à l'évolution de la demande [46].

4.7.1 Principe général

L'apprentissage par renforcement repose sur trois éléments principaux [46] :

- **l'agent** : le système qui prend des décisions ;
- **l'environnement** : le contexte dans lequel évolue l'agent ;
- **la récompense** : le signal permettant d'évaluer l'action effectuée.

À chaque étape, l'agent observe un état s , choisit une action a , et reçoit une récompense r . Le processus peut être représenté comme suit :

$$(s, a) \rightarrow r \rightarrow s' \quad (4.22)$$

où s' est le nouvel état après l'action. La figure 4.6 illustre cette boucle d'interaction.




FIGURE 4.6 : Boucle d'interaction agent-environnement en apprentissage par renforcement.

4.7.2 Fonction de valeur

L'objectif de l'agent est de maximiser la récompense cumulée, appelée retour. Celui-ci est défini par [46] :

$$G_t = r_t + \gamma r_{t+1} + \gamma^2 r_{t+2} + \dots \quad (4.23)$$

où :

- r_t est la récompense à l'instant t ,
- $\gamma \in [0, 1]$ est le facteur d'actualisation.

4.7.3 Algorithme Q-learning

L'un des algorithmes les plus utilisés en apprentissage par renforcement est le Q-learning [46].

Principe

Le Q-learning consiste à apprendre une fonction $Q(s, a)$ qui estime la qualité d'une action dans un état donné.

La mise à jour de cette fonction est donnée par [46] :

$$Q(s, a) = Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)] \quad (4.24)$$

où :

- α est le taux d'apprentissage,
- γ est le facteur de réduction,
- r est la récompense,
- s' est le nouvel état.

Algorithme 10 : Algorithme de Q-Learning

```

1 Entrées : Taux d'apprentissage  $\alpha$ , facteur d'actualisation  $\gamma$ ;
2 // Étape 1 : Initialisation;
3 Initialiser arbitrairement la table  $Q(s, a)$  pour tous les états  $s$  et actions  $a$ ;
4 repeat
5   Observer l'état courant  $s$ ;
6   Choisir une action  $a$  depuis l'état  $s$ ;
7   Exécuter l'action  $a$ , recevoir la récompense  $r$  et observer l'état suivant  $s'$ ;
8    $Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ ;
9    $s \leftarrow s'$ ;
10 until convergence de la table  $Q$ ;
11 Retourner la table optimale  $Q(s, a)$ ;

```

Exemple simple : Gestion de stock de sang

Considérons un système simplifié où un agent doit décider chaque jour de la quantité de sang à stocker.

Configuration du système :

- **États** (s) : {faible, moyen, élevé};
- **Actions** (a) : {augmenter, maintenir, diminuer};
- **Récompenses** (r) : +10 (satisfaction), -5 (rupture), -2 (surplus).

Déroulement d'une étape :

Étape 1. Observation : L'agent identifie l'état initial : s = stock faible.

Étape 2. Décision : Il choisit l'action de réapprovisionnement : a = augmenter.

Étape 3. Transition : L'état devient $s' =$ stock moyen et la récompense reçue est $r = 10$.

Étape 4. Mise à jour : La connaissance de l'agent est actualisée dans la table Q :

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[10 + \gamma \max_{a'} Q(s', a') - Q(s, a) \right]$$

Conclusion

L'agent apprend progressivement à choisir les actions qui maximisent la satisfaction de la demande tout en minimisant les pertes. Ce type d'approche est particulièrement adapté aux systèmes dynamiques et évolutifs [46].

4.8 Deep Learning

Le Deep Learning, ou apprentissage profond, est une sous-branche du Machine Learning basée sur l'utilisation de réseaux de neurones artificiels composés de plusieurs couches. Contrairement aux méthodes classiques, ces modèles permettent d'extraire automatiquement des caractéristiques complexes à partir des données [47, 39].

4.8.1 Réseaux de neurones artificiels (RNA)

Définition

Un réseau de neurones artificiels est un modèle inspiré du fonctionnement du cerveau humain, composé de neurones organisés en couches (entrée, cachées, sortie) [39]. La figure 4.7 illustre l'architecture générale d'un réseau multicouche.




FIGURE 4.7 : Architecture d'un réseau de neurones multicouche.

Principe

Chaque neurone effectue un calcul [39] :

$$y = f \left(\sum_{i=1}^n w_i x_i + b \right) \quad (4.25)$$

où f est une fonction d'activation. La structure interne d'un neurone est représentée par la figure 4.8.




FIGURE 4.8 : Structure interne d'un neurone artificiel.

Fonctions d'activation

La fonction d'activation introduit la non-linéarité indispensable pour modéliser des relations complexes [39]. Les principales fonctions sont :

- **Sigmoïde** : $\sigma(x) = \frac{1}{1 + e^{-x}}$, à valeurs dans $]0, 1[$, utile pour estimer une probabilité.
- **Tangente hyperbolique (tanh)** : $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$, à valeurs dans $] -1, 1[$.
- **ReLU (Rectified Linear Unit)** : $f(x) = \max(0, x)$, la fonction la plus utilisée dans les réseaux profonds en raison de sa simplicité et de son efficacité.
- **Softmax** : utilisée en sortie pour la classification multi-classe, elle transforme un vecteur de scores en probabilités.

Apprentissage par descente de gradient

L'apprentissage d'un réseau de neurones consiste à ajuster les poids et les biais afin de minimiser une fonction de coût. La méthode utilisée est la **descente de gradient** [39], qui met à jour les paramètres dans la direction opposée au gradient de la fonction de coût :

$$w \leftarrow w - \eta \frac{\partial L}{\partial w} \quad (4.26)$$

où η est le taux d'apprentissage et L la fonction de coût. Pour les réseaux profonds, l'algorithme de **rétropropagation du gradient** (*backpropagation*) permet de calculer efficacement ces gradients couche par couche.

Exemple illustratif : Calcul d'un neurone

Considérons un neurone artificiel avec les paramètres suivants :

- **Entrées** (x) : $x_1 = 2$, $x_2 = 3$

- **Poids** (w) : $w_1 = 0,5$, $w_2 = 1$
- **Biais** (b) : $b = 1$

Étape 1. Sommation pondérée (z) :

$$z = (w_1 \times x_1) + (w_2 \times x_2) + b = (0,5 \times 2) + (1 \times 3) + 1 = 5$$

Étape 2. Fonction d'activation (ReLU) :

$$f(z) = \max(0, 5) = 5$$

Interprétation : Le neurone combine les informations en entrée pour produire une valeur de sortie. Dans un réseau complet, cette sortie sera transmise aux neurones de la couche suivante si elle est positive.

4.8.2 Réseaux de neurones convolutifs (CNN)

Définition

Les CNN sont des réseaux spécialisés dans le traitement des données sous forme de matrices, notamment les images [47].

Principe

Le CNN applique une opération de convolution [47] :

$$S = X * K \tag{4.27}$$

L'opération de convolution est illustrée par la figure 4.9.

Image X		Filtre K		Résultat S									
<table border="1" style="border-collapse: collapse; width: 60px; height: 60px;"> <tr><td style="padding: 5px; text-align: center;">1</td><td style="padding: 5px; text-align: center;">2</td></tr> <tr><td style="padding: 5px; text-align: center;">0</td><td style="padding: 5px; text-align: center;">1</td></tr> </table>	1	2	0	1	*	<table border="1" style="border-collapse: collapse; width: 60px; height: 60px;"> <tr><td style="padding: 5px; text-align: center;">1</td><td style="padding: 5px; text-align: center;">0</td></tr> <tr><td style="padding: 5px; text-align: center;">0</td><td style="padding: 5px; text-align: center;">-1</td></tr> </table>	1	0	0	-1	=	<table border="1" style="border-collapse: collapse; width: 40px; height: 40px;"> <tr><td style="padding: 5px; text-align: center;">0</td></tr> </table>	0
1	2												
0	1												
1	0												
0	-1												
0													

FIGURE 4.9 : Illustration de l'opération de convolution appliquée à une image 2×2 .

Exemple illustratif : Opération de convolution

On considère une petite région d'une image X et un noyau de convolution (filtre) K :

$$X = \begin{bmatrix} 1 & 2 \\ 0 & 1 \end{bmatrix}, \quad K = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Calcul du produit de convolution (S) :

$$S = (1 \times 1) + (2 \times 0) + (0 \times 0) + (1 \times -1) = 0$$

Interprétation : La valeur obtenue (0) représente l'activation de ce filtre pour cette zone précise de l'image. En faisant glisser ce filtre K sur toute l'image, on obtient une **carte de caractéristiques** (*feature map*) qui met en évidence des structures spécifiques, comme des contours ou des textures.

4.8.3 Réseaux de neurones récurrents (RNN)

Définition

Les RNN sont des réseaux adaptés aux données séquentielles, capables de mémoriser l'information passée [39]. Contrairement aux réseaux classiques, ils possèdent une boucle de rétroaction qui leur permet de conserver une information d'un instant à l'autre. Le déroulement temporel d'un RNN est représenté par la figure 4.10.




FIGURE 4.10 : Déroulement temporel d'un réseau de neurones récurrent (RNN).

Principe

$$h_t = Wx_t + Uh_{t-1} + b \quad (4.28)$$

Exemple illustratif : Calcul de l'état caché (RNN)

Considérons un neurone récurrent simple avec les paramètres suivants :

- **Entrée actuelle** : $x_t = 2$

- **État caché précédent (mémoire)** : $h_{t-1} = 1$
- **Poids et biais** : $W = 1, \quad U = 0,5, \quad b = 0$

Calcul de l'état caché actuel (h_t) :

$$h_t = (1 \times 2) + (0,5 \times 1) + 0 = 2,5$$

Interprétation : La valeur obtenue (2,5) représente le nouvel état caché. Contrairement à un réseau classique, le RNN utilise cette information (h_t) pour influencer le calcul à l'instant suivant ($t + 1$). Cette boucle de rétroaction permet au modèle de conserver une forme de « mémoire » des séquences passées pour améliorer ses prédictions.

4.8.4 Réseaux LSTM et GRU

Définition

Les RNN classiques souffrent d'une limitation importante : ils ont des difficultés à apprendre des dépendances à long terme en raison du phénomène de *disparition du gradient*. Pour pallier ce problème, des architectures plus avancées ont été proposées, parmi lesquelles les **LSTM** (*Long Short-Term Memory*) [48] et les **GRU** (*Gated Recurrent Unit*) [49].

Principe des LSTM

Une cellule LSTM intègre un mécanisme de *portes* (*gates*) qui régulent le flux d'information [48] :

- **Porte d'oubli** (*forget gate*) : décide quelle information de l'état précédent doit être oubliée ;
- **Porte d'entrée** (*input gate*) : contrôle quelle nouvelle information doit être ajoutée à l'état de la cellule ;
- **Porte de sortie** (*output gate*) : détermine la sortie à transmettre à l'instant suivant.

Grâce à ce mécanisme, les LSTM peuvent conserver des informations pertinentes sur de longues séquences temporelles, ce qui les rend particulièrement adaptés à la prévision de séries temporelles, à la traduction automatique ou à la reconnaissance vocale [48].

Principe des GRU

Les GRU constituent une simplification des LSTM, avec seulement deux portes (porte de mise à jour et porte de réinitialisation) [49]. Ils offrent des performances comparables aux LSTM dans de nombreux cas, avec un coût de calcul plus faible.

Application à la prévision de la demande

Dans le cadre de la gestion des stocks de produits sanguins, les LSTM constituent un outil particulièrement pertinent [48]. Ils permettent en effet d’exploiter l’historique de la demande, en tenant compte des dépendances temporelles (saisonnalité, tendances, événements ponctuels) pour produire des prévisions précises. Ces prévisions peuvent ensuite être utilisées en entrée d’un système de gestion intelligente des stocks, afin d’anticiper les besoins et de réduire à la fois les ruptures et les pertes par péremption .

Conclusion du chapitre

Dans ce chapitre, nous avons présenté les notions fondamentales du Machine Learning et du Deep Learning [39, 47]. Après avoir défini le Machine Learning et introduit les principaux concepts liés à la généralisation, à la préparation des données et à l’évaluation des modèles, nous avons exploré les trois grandes familles d’apprentissage : supervisé, non supervisé et par renforcement. Nous avons ensuite détaillé les algorithmes les plus représentatifs de chaque famille, en illustrant leur fonctionnement par des exemples simples adaptés au contexte médical et à la gestion des stocks. Enfin, nous avons abordé le Deep Learning et ses architectures principales [48, 49], en mettant en évidence leur intérêt pour la prévision de la demande de produits sanguins .

Ces concepts théoriques constituent la base nécessaire pour la mise en œuvre des modèles présentée dans les chapitres suivants, où nous appliquerons ces techniques à un cas concret de gestion des stocks dans une banque de sang.

CHAPITRE 5

Analyse d'un système de gestion de stock des produits sanguins via les RdPSG et machine learning

Introduction

La gestion des stocks de produits sanguins constitue un défi opérationnel majeur dans les établissements de santé : ces produits sont à la fois vitaux, périssables et soumis à une demande variable et difficilement prévisible. Toute rupture de stock expose directement les patients à un risque transfusionnel, tandis qu'un sur-stockage entraîne des pertes par péremption, avec des conséquences humaines et économiques considérables.

Ce chapitre propose une approche double pour analyser et améliorer ce système. Dans un premier temps, un modèle de Réseau de Petri Stochastique Généralisé (RdPSG) est construit afin de représenter formellement le flux des produits sanguins de l'arrivée des donneurs jusqu'à la livraison ou la péremption des poches et d'en déduire, via la résolution de la chaîne de Markov associée, les indicateurs de performance en régime permanent. Dans un second temps, des modèles d'apprentissage automatique (CatBoost, XGBoost, Random Forest) sont appliqués à des données historiques réelles afin de prédire la demande mensuelle en Concentrés Érythrocytaires (CE), en Concentrés Plaquettaires Standard (CPS) et en Plasma frais congelé (PFC), fournissant ainsi un outil d'aide à la décision pour le réapprovisionnement.

Ces deux approches sont complémentaires : le RdPSG offre une analyse structurale du système et identifie ses vulnérabilités, tandis que le machine learning permet d'anticiper la demande future à partir des tendances observées.

5.1 Modèle RdPSG associé au système étudié

Le modèle de Réseau de Petri Stochastique Généralisé (RdPSG) associé au système de gestion de stock des produits sanguins est représenté à la figure 5.1. Ce modèle comprend six places, quatre transitions (dont une immédiate) et deux arcs inhibiteurs qui contrôlent les conditions d'activation des transitions.




FIGURE 5.1 : Modèle RdPSG du système de gestion de stock des produits sanguins.

5.1.1 Description des places

Le modèle comporte les places suivantes :

- P_{fatt} : File d'attente des donneurs de sang, capacité maximale N .
- $P_{analyse}$: C'est la place où on détermine si le donneur est apte ou inapte en se basant sur les analyses.
- $P_{remplissage}$: C'est la place où la pochette du produit sanguin est remplie et prête pour la séparation.
- P_{CE} : C'est la place où on stocke les Concentrés d'Érythrocytes.

- P_{PFC} : C'est la place où on stocke le Plasma Fraîchement Congelé.
- P_{CPS} : C'est la place où on stocke les Concentrés de Plaquettes Standard.

5.1.2 Description des transitions

- Les transitions temporisées : $T_{arrivee}$, $T_{accepte}$ et T_{inapte} , représentent respectivement : l'arrivée des donneurs, le donneur est apte à une transfusion, le donneur est inapte à une transfusion.
- Les transitions temporisées : T_{liv} et T_{per} , représentent respectivement : la livraison des produits sanguins et la péremption des produits sanguins. Ces deux transitions renvoient **3 jetons** vers P_{fatt} (un par produit sanguin séparé).
- La transition immédiate : $T_{separation}$, qui représente la séparation de la pochette en 3 produits sanguins.

Le marquage initial de notre RdPSG est donné par :

$$M = (P_{fatt}, P_{analyse}, P_{remplissage}, P_{CE}, P_{PFC}, P_{CPS})$$

avec son marquage initial :

$$M_0 = (N, 0, 0, S, S', S'')$$

avec $N = 4$, $S = S' = S'' = 2$.

- La transition temporisée $T_{arrivee}$ est sensibilisée lorsque la place P_{fatt} contient au moins un jeton et la place $P_{analyse}$ ne contient aucun jeton. Le franchissement de cette transition consiste à détruire un jeton dans P_{fatt} et à créer un jeton dans $P_{analyse}$.
- La transition temporisée $T_{accepte}$ est sensibilisée lorsque la place $P_{analyse}$ contient un jeton et la place $P_{remplissage}$ contient au plus un jeton. Le franchissement de cette transition consiste à détruire un jeton dans $P_{analyse}$ et à créer un jeton dans $P_{remplissage}$.
- La transition temporisée T_{inapte} est sensibilisée lorsque la place $P_{analyse}$ contient un jeton. Son franchissement renvoie le jeton vers P_{fatt} .
- La transition immédiate $T_{separation}$ est sensibilisée lorsque la place $P_{remplissage}$ contient un jeton. Son franchissement détruit un jeton dans $P_{remplissage}$ et crée un jeton dans chacune des places P_{CE} , P_{PFC} et P_{CPS} .
- Les transitions temporisées T_{liv} et T_{per} sont sensibilisées lorsque les places P_{CE} , P_{PFC} et P_{CPS} contiennent des jetons. Leur franchissement détruit un jeton dans chacune de ces trois places et renvoie **3 jetons** vers P_{fatt} .

5.2 Analyse qualitative et quantitative du RdPSG établi

Afin d'évaluer les performances du système modélisé, nous procédons à une analyse qualitative et quantitative du RdPSG établi. Cette analyse s'appuie sur la construction du graphe des marquages accessibles, la détermination de la distribution stationnaire de la chaîne de Markov associée, puis le calcul des indicateurs de performance en régime permanent.

5.2.1 Graphe de marquage accessible du RdPSG établi

L'analyse des systèmes par les RdPSG repose principalement sur l'élaboration du graphe des marquages accessibles, puisqu'il décrit complètement l'ensemble des états du système. À partir du RdPSG, on obtient une arborescence des marquages accessibles permettant une meilleure visualisation de tous les états possibles du système à partir du marquage initial.

Vu la complexité de l'analyse, nous considérons comme exemple :

$$N = 4, \quad S = 2, \quad S' = 2, \quad S'' = 2$$

À partir du RdPSG représenté dans la Figure 5.1, nous obtenons l'arborescence d'accessibilité décrivant l'ensemble des marquages possibles (voir Figure 5.2).

En utilisant la théorie des graphes appliquée à la Figure 5.2, nous déduisons les propriétés suivantes :

- Le réseau est borné ;
- Le réseau est sans blocage ;
- Le réseau est vivant ;
- Le RdPSG obtenu est réinitialisable (il admet M_0 comme état d'accueil).

Puisque le réseau est borné et admet M_0 comme état d'accueil, alors il est ergodique. Par conséquent, la distribution stationnaire π existe et elle est unique. L'évaluation des performances à l'état stationnaire est donc possible.

Pour calculer les différents paramètres de performance du RdPSG correspondant, il est nécessaire de déterminer les probabilités d'état en régime permanent, c'est-à-dire les probabilités de présence dans un marquage donné.




FIGURE 5.2 : Graphe des marquages accessibles du RdPSG

5.2.2 Détermination des états tangibles

Après élimination des états vanescents engendrés par la transition immédiate $T_{separation}$, le graphe des marquages accessibles comporte **13 états tangibles** et **6 états vanescents**. Par symétrie de séparation, on a en tout état $P_{CE} = P_{PFC} = P_{CPS}$, ce qui permet de représenter chaque état tangible par le triplet $M = (P_{fatt}, P_{analyse}, P_{CE})$.

TABLE 5.1 : États tangibles du RdPSG avec $N = 4$, $S = S' = S'' = 2$

État	P_{fatt}	$P_{analyse}$	P_{CE}	P_{PFC}	P_{CPS}
$\mathcal{E}_1$	4	0	2	2	2
$\mathcal{E}_2$	3	1	2	2	2
$\mathcal{E}_3$	3	0	3	3	3
$\mathcal{E}_4$	5	0	1	1	1
$\mathcal{E}_5$	4	1	1	1	1
$\mathcal{E}_6$	2	1	3	3	3
$\mathcal{E}_7$	2	0	4	4	4
$\mathcal{E}_8$	6	0	0	0	0
$\mathcal{E}_9$	5	1	0	0	0
$\mathcal{E}_{10}$	1	1	4	4	4
$\mathcal{E}_{11}$	1	0	5	5	5
$\mathcal{E}_{12}$	0	1	5	5	5
$\mathcal{E}_{13}$	0	0	6	6	6

Les 6 états vanescents correspondent aux marquages où $P_{remplissage} = 1$, c'est-à-dire les états intermédiaires dans lesquels $T_{separation}$ est activée immédiatement et donc éliminés de l'analyse en régime permanent.

5.2.3 Construction de la matrice de transition Q

Puisque le RdPSG est ergodique, il engendre une chaîne de Markov à temps continu (CMTC) dont le comportement en régime permanent est décrit par la matrice de transition infinitésimale Q de dimension 13×13 .

Règles de construction

Les éléments hors-diagonale q_{ij} ($i \neq j$) représentent le taux de passage de l'état $\mathcal{E}_i$ vers $\mathcal{E}_j$, déterminés par :

- $T_{arrivee} : (f, 0, c) \rightarrow (f - 1, 1, c)$, taux = $f \cdot \lambda_{arr}$, si $f \geq 1$ et $P_{analyse} = 0$.
- $T_{inapte} : (f, 1, c) \rightarrow (f + 1, 0, c)$, taux = λ_{ina} .
- $T_{accepte} + T_{separation} \text{ (net)} : (f, 1, c) \rightarrow (f, 0, c + 1)$, taux = λ_{acc} .
- $T_{liv} : (f, a, c) \rightarrow (f + 1, a, c - 1)$, taux = $c \cdot \lambda_{liv}$, si $c \geq 1$.
- $T_{per} : (f, a, c) \rightarrow (f + 1, a, c - 1)$, taux = $c \cdot \lambda_{per}$, si $c \geq 1$.

Les éléments diagonaux sont définis par $q_{ii} = -\sum_{j \neq i} q_{ij}$, de sorte que chaque ligne de Q somme à zéro.

Matrice Q symbolique

[illegible]

5.2.4 Distribution stationnaire π

Systeme d'equations

La distribution stationnaire $\pi = (\pi_1, \pi_2, \dots, \pi_{13})$ est la solution unique du système linéaire :

$$\begin{cases} \pi_Q = 0 \\ \sum_{i=1}^{13} \pi_i = 1 \\ \pi_i \geq 0 \quad \forall i \end{cases}$$

Ce système est résolu en remplaçant la dernière équation de $\pi Q = \mathbf{0}$ par la condition de normalisation $\sum_i \pi_i = 1$, ce qui donne un système de Cramer admettant une solution unique (le réseau étant ergodique).

Résultats numériques

Pour $\lambda_{arr} = \lambda_{acc} = \lambda_{ina} = \lambda_{liv} = \lambda_{per} = 0,1$, la résolution du système donne les probabilités stationnaires du Tableau 5.2.

TABLE 5.2 : Distribution stationnaire π du RdPSG

État	Marquage (P_{fatt} , P_{ana} , P_{CE})	π_i	Pourcentage
$\mathcal{E}_1$	(4, 0, 2)	0,023610	2,3610 %
$\mathcal{E}_2$	(3, 1, 2)	0,016501	1,6501 %
$\mathcal{E}_3$	(3, 0, 3)	0,001989	0,1989 %
$\mathcal{E}_4$	(5, 0, 1)	0,115154	11,5154 %
$\mathcal{E}_5$	(4, 1, 1)	0,160444	16,0444 %
$\mathcal{E}_6$	(2, 1, 3)	0,000762	0,0762 %
$\mathcal{E}_7$	(2, 0, 4)	0,000079	0,0079 %
$\mathcal{E}_8$	(6, 0, 0)	0,130250	13,0250 %
$\mathcal{E}_9$	(5, 1, 0)	0,551195	55,1195 %
$\mathcal{E}_{10}$	(1, 1, 4)	0,000016	0,0016 %
$\mathcal{E}_{11}$	(1, 0, 5)	0,0000015	0,00015 %
$\mathcal{E}_{12}$	(0, 1, 5)	0,00000012	0,000012 %
$\mathcal{E}_{13}$	(0, 0, 6)	≈ 0	≈ 0 %
Total		1,000000	100 %

L'état $\mathcal{E}_9 = (5, 1, 0)$ est dominant avec 55,12 % de probabilité, ce qui signifie que le système se trouve le plus souvent dans une situation où le stock est **vide** et un donneur est en cours d'analyse. Les états $\mathcal{E}_{10}$ à $\mathcal{E}_{13}$ (stocks élevés) sont pratiquement inaccessibles en régime permanent.

5.2.5 Calcul des indicateurs de performance

Les indicateurs de performance en régime permanent sont calculés à partir de π .

Nombre moyen de jetons par place

Par symétrie de séparation, les trois produits ont le même niveau moyen :

$$\mathbb{E}[P_{CE}] = \mathbb{E}[P_{PFC}] = \mathbb{E}[P_{CPS}] = \sum_{i=1}^{13} \pi_i \cdot ce_i = \mathbf{0,3645} \text{ unités}$$

$$\mathbb{E}[P_{fatt}] = \sum_{i=1}^{13} \pi_i \cdot fatt_i = \mathbf{4,9066} \text{ donneurs} \quad \mathbb{E}[P_{analyse}] = \sum_{i=1}^{13} \pi_i \cdot ana_i = \mathbf{0,7289}$$

Probabilité de rupture de stock

$$P(\text{rupture}) = \sum_{\{i: ce_i=0\}} \pi_i = \pi_8 + \pi_9 = 0,1303 + 0,5512 = \mathbf{68,14 \%}$$

Débit de livraison et taux de péremption

$$D_{liv} = \sum_{i=1}^{13} \pi_i \cdot ce_i \cdot \lambda_{liv} = \mathbf{0,03645} \text{ livraisons/ut} \quad D_{per} = \sum_{i=1}^{13} \pi_i \cdot ce_i \cdot \lambda_{per} = \mathbf{0,03645} \text{ péremptions/ut}$$

On remarque $D_{liv} = D_{per}$ car $\lambda_{liv} = \lambda_{per}$ dans ce scénario symétrique.

Efficacité du stock et taux de service

$$\eta = \frac{D_{liv}}{D_{liv} + D_{per}} = \frac{0,03645}{0,07290} = \mathbf{50,00 \%} \quad \tau_{service} = 1 - P(\text{rupture}) = \mathbf{31,86 \%}$$

TABLE 5.3 : Récapitulatif des indicateurs de performance

Indicateur	Formule	Valeur
Stock moyen $\mathbb{E}[P_{CE}]$	$\sum \pi_i \cdot ce_i$	0,3645 unités
Donneurs en attente $\mathbb{E}[P_{fatt}]$	$\sum \pi_i \cdot fatt_i$	4,9066 donneurs
Dons en analyse $\mathbb{E}[P_{analyse}]$	$\sum \pi_i \cdot ana_i$	0,7289
Probabilité de rupture	$\sum_{ce_i=0} \pi_i$	68,14 %
Débit de livraison D_{liv}	$\sum \pi_i \cdot ce_i \cdot \lambda_{liv}$	0,03645 /ut
Taux de péremption D_{per}	$\sum \pi_i \cdot ce_i \cdot \lambda_{per}$	0,03645 /ut
Efficacité du stock η	$D_{liv} / (D_{liv} + D_{per})$	50,00 %
Taux de service $\tau_{service}$	$1 - P(\text{rupture})$	31,86 %

5.2.6 Analyse de sensibilité et interprétation des résultats

Interprétation générale

L'analyse des indicateurs met en évidence plusieurs observations importantes :

- **Forte probabilité de rupture de stock (68,14 %).** Le système passe la majorité du temps dans les états $\mathcal{E}_8$ et $\mathcal{E}_9$ où le stock est vide. Ceci s'explique par le fait que les taux λ_{liv} et λ_{per} sont élevés par rapport au taux de collecte effectif, entraînant un épuisement rapide des produits stockés.
- **Stock moyen très faible (0,3645 unités).** Le niveau moyen de chaque produit sanguin est très bas, confirmant que le stock est rarement disponible en quantité suffisante.

- **Taux de service insuffisant** (31,86 %). Moins d'un tiers du temps, le système est en mesure de livrer des produits sanguins, soulignant la nécessité d'une révision des paramètres opérationnels.
- **File d'attente saturée** ($\mathbb{E}[P_{fatt}] \approx 4,91$). La file d'attente est presque constamment proche de sa capacité maximale $N = 4$, voire au-delà, ce qui indique que la phase d'analyse constitue le goulot d'étranglement du système.

Analyse de sensibilité

Le Tableau 5.4 présente l'impact de la variation des taux de transition sur les indicateurs clés pour différents scénarios.

TABLE 5.4 : Analyse de sensibilité — impact des taux sur les indicateurs

Scénario	λ_{arr}	λ_{acc}	λ_{liv}	λ_{per}	$\mathbb{E}[P_{CE}]$	$P(\text{rupture})$	$\tau_{service}$
Référence	0,1	0,1	0,1	0,1	0,365	68,14 %	31,86 %
Collecte accrue	0,3	0,1	0,1	0,1	0,455	54,20 %	45,80 %
Analyse rapide	0,1	0,3	0,1	0,1	0,480	51,30 %	48,70 %
Péremption faible	0,1	0,1	0,1	0,02	0,712	43,50 %	56,50 %
Péremption élevée	0,1	0,1	0,1	0,3	0,180	82,10 %	17,90 %
Optimal combiné	0,3	0,3	0,1	0,02	1,120	18,70 %	81,30 %

Recommandations

À partir des résultats obtenus, nous formulons les recommandations suivantes :

1. **Réduire le taux de péremption λ_{per} .** C'est le levier le plus efficace : passer λ_{per} de 0,1 à 0,02 fait chuter la probabilité de rupture de 68,14 % à 43,50 % et double presque le stock moyen. Cela passe par l'amélioration des conditions de conservation (chaîne du froid, conteneurs adaptés).
2. **Accélérer la phase d'analyse λ_{acc} .** Réduire le temps d'analyse biologique permet de faire transiter plus rapidement les donneurs vers le remplissage, augmentant ainsi la fréquence de séparation et le taux de service.
3. **Augmenter le flux d'arrivée λ_{arr} .** Des campagnes de sensibilisation au don du sang permettent d'augmenter λ_{arr} , réduisant la probabilité de rupture. Cet effet reste toutefois limité tant que λ_{per} demeure élevé.
4. **Approche combinée.** La combinaison collecte accrue ($\lambda_{arr} = 0,3$), analyse rapide ($\lambda_{acc} = 0,3$) et meilleure conservation ($\lambda_{per} = 0,02$) permet d'atteindre un taux de service de **81,30 %**, soit une amélioration de près de 150 % par rapport au scénario de référence.

Conclusion

Le modèle RdPSG développé dans ce chapitre permet une analyse quantitative complète du système de gestion des produits sanguins. La résolution de la chaîne de Markov associée révèle que, dans les conditions nominales, le système souffre d'un **taux de rupture élevé** (68,14 %) et d'une **efficacité de stock limitée** (50 %), principalement due à la péremption des produits et au déséquilibre entre les flux de collecte et de consommation. L'analyse de sensibilité confirme que les actions prioritaires doivent porter sur **la réduction de la péremption** et **l'accélération des analyses biologiques**, leviers les plus efficaces pour améliorer la disponibilité des produits sanguins et garantir la sécurité transfusionnelle.

5.3 Machine learning

Dans cette section, nous appliquons des méthodes d'apprentissage automatique pour prédire la demande mensuelle en produits sanguins à partir des données historiques réelles du centre de transfusion. Trois algorithmes ensemblistes sont comparés — CatBoost, XGBoost et Random Forest — et évalués sur trois types de produits : les Concentrés Érythrocytaires (CE), les Concentrés Plaquettaires Standard (CPS) et le Plasma Fraîchement Congelé (PFC)

5.4 Prédiction de la Demande des Concentrés Érythrocytaires (CE)

Les Concentrés Érythrocytaires constituent le produit sanguin le plus fréquemment transfusé. Cette section présente la construction du modèle de prédiction de leur demande mensuelle, depuis la préparation des données jusqu'à l'évaluation des performances et les prévisions pour le premier semestre 2026.

5.4.1 Source et Préparation des Données

Les données sont extraites du fichier de gestion du stock des CE, dans lequel chaque enregistrement correspond à une poche individuelle. Un premier filtre est appliqué sur la variable **statu** : seules les poches dont le statut est « **distribuer** » sont conservées, représentant **35 518 poches** effectivement délivrées aux patients. La variable temporelle retenue est la **date de sortie**, qui reflète la demande réelle. Une agrégation mensuelle est ensuite réalisée : pour chaque mois, on comptabilise le nombre de poches distribuées. Après exclusion du premier et du dernier mois incomplets, la série couvre **47 points mensuels** de **février 2022** à **décembre 2025**.

La répartition chronologique retenue est présentée dans le tableau 5.5.

TABLE 5.5 : Répartition chronologique des données — CE

Ensemble	Période	Nb. de mois
Entraînement	Février 2022 — Janvier 2025	37
Test	Février 2025 — Décembre 2025	11

Ce découpage respecte strictement la **causalité temporelle** : les modèles sont entraînés uniquement sur des données passées et évalués sur une période future qu'ils n'ont jamais observée, reproduisant ainsi un contexte opérationnel réel.

5.4.2 Variable Cible et Variables Explicatives

Variable cible. La variable à prédire est le **nombre mensuel de poches de CE distribuées**, notée D_t pour le mois t .

Variables explicatives. Seize variables ont été construites à partir de la série temporelle afin de capturer ses différentes composantes dynamiques (tableau 5.6).

TABLE 5.6 : Description des variables explicatives utilisées — CE

Catégorie	Variable(s)	Description
Retards (<i>lags</i>)	lag_1, lag_2, lag_3	Demande des 1, 2 et 3 mois précédents
	lag_6	Demande du mois $t - 6$
Statistiques mobiles	roll3_mean	Moyenne glissante sur les 3 derniers mois
	roll6_mean	Moyenne glissante sur les 6 derniers mois
	roll3_std	Écart-type glissant sur 3 mois
Différenciation	demand_diff1	Variation mensuelle $D_{t-1} - D_{t-2}$
Tendance & calendrier	trend, year	Indice linéaire chronologique, année
	month, quarter	Mois (1–12), trimestre
Saisonnalité	is_summer, is_year_end	Indicateurs binaires : été, fin d'année
	month_sin, month_cos	Encodage cyclique $(\sin \frac{2\pi m}{12}, \cos \frac{2\pi m}{12})$

L'encodage cyclique élimine la discontinuité artificielle entre décembre ($m = 12$) et janvier ($m = 1$). Les features lag et moyennes mobiles sont calculées avec un décalage (`shift(1)`) pour éviter toute fuite d'information (*data leakage*).

5.4.3 Résultats et Métriques de Performance

Les trois modèles ont été évalués sur l'ensemble de test à l'aide de trois métriques complémentaires :

- **MAE** (*Mean Absolute Error*) : erreur absolue moyenne en nombre de poches.
- **RMSE** (*Root Mean Squared Error*) : pénalise davantage les grandes erreurs ponctuelles.
- **MAPE** (*Mean Absolute Percentage Error*) : erreur relative en pourcentage :

$$\text{MAPE} = \frac{1}{n} \sum_{t=1}^n \left| \frac{D_t - \hat{D}_t}{D_t} \right| \times 100.$$

TABLE 5.7 : Métriques de performance des trois modèles — CE (ensemble de test)

Modèle	MAE _{train}	MAE _{test}	RMSE _{test}	MAPE _{test} (%)	Rang
CatBoost	1,0	48,0	56,8	5,54	1^{er}
XGBoost	12,1	51,6	61,6	5,96	2 ^e
Random Forest	28,3	52,2	67,6	6,10	3 ^e

MAE et RMSE en nombre de poches. En gras : meilleures valeurs sur le test.

(1) Performances comparatives. Les trois algorithmes affichent des MAPE comprises entre **5,54 %** et **6,10 %**, traduisant une bonne adéquation des modèles malgré les 37 mois d'entraînement seulement.

(2) Sur-apprentissage (*overfitting*). L'écart entre MAE_{train} = 1,0 et MAE_{test} = 48,0 pour CatBoost est inhérent aux méthodes de boosting sur séries courtes. Les performances sur le test restent acceptables : une MAPE inférieure à 10 % est généralement jugée satisfaisante.

5.4.4 Analyse des Résultats Visuels

Les deux figures 5.3 et 5.4 présente la synthèse graphique complète.




FIGURE 5.3 : Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026).

Interprétation — Série temporelle et prédictions

Tendance générale (2022–2024). La courbe noire révèle une **tendance haussière soutenue** sur l'ensemble de la période d'entraînement : la demande mensuelle passe d'environ **200 pochettes** en janvier 2022 à un pic de **1 040 pochettes** en novembre 2024, soit une multiplication par 5 en moins de trois ans. Cette croissance est régulière, avec de légères oscillations saisonnières mais sans rupture structurelle majeure, ce qui indique un marché en expansion continue.

Anomalie de décembre 2025. Un **effondrement brutal** de la demande est observé en décembre 2025 (chute à ≈ 640 pochettes), après un pic de novembre 2025. Aucun des trois modèles n'anticipe cette baisse, ce qui suggère qu'elle est provoquée par un **choc exogène** non capturé par les variables explicatives (rupture d'approvisionnement, événement calendaire atypique, anomalie de saisie). Il convient de vérifier ce point avant toute décision opérationnelle.

Performance sur le jeu de test (Fév–Déc 2025). Les trois modèles suivent correctement le niveau global de la demande (fourchette 750–950 pochettes). Les prédictions ponctuelles restent proches de la courbe réelle, à l'exception du mois de décembre 2025. **Random Forest** présente la meilleure fidélité visuelle sur les mois intermédiaires, tandis que **CatBoost** et **XGBoost** tendent légèrement à sous-estimer sur les mois de forte demande.

Prévisions futures (Jan–Jun 2026). Les trois modèles convergent vers une **demande stable autour de 800–860 pochettes** par mois. L'accord entre les modèles constitue un signal de robustesse : lorsque plusieurs algorithmes indépendants s'alignent sur une même plage, la fiabilité de la prévision est renforcée. Néanmoins, la forte chute de

décembre 2025 crée une incertitude sur le niveau de redémarrage : les prévisions de janvier 2026 (≈ 810 pochettes) doivent être interprétées avec prudence jusqu'à confirmation par les données réelles.




FIGURE 5.4 : Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest).

Interprétation — Importance des variables explicatives

Les trois modèles s'accordent sur les mêmes variables motrices, avec quelques différences notables dans la répartition des poids.

Variables les plus déterminantes. La moyenne glissante sur 6 mois (`roll6_mean`) et la tendance (`trend`) dominent largement : `roll6_mean` atteint **48%** pour **XGBoost**, et `trend` contribue à hauteur de **20%** pour **CatBoost** et **Random Forest**. Cela confirme que la demande est principalement gouvernée par sa **dynamique de long terme** : le niveau récent lissé et la croissance structurelle suffisent à expliquer l'essentiel de la variance. Le lag 1 (`lag_1`, 10–14% pour tous les modèles) traduit en complément une **forte inertie mensuelle**.

Point d'alerte : fragilité de XGBoost. La dépendance quasi exclusive d'XGBoost à `roll6_mean` (48%) est un signal de risque : en cas de rupture de tendance, ce modèle sera le plus exposé. CatBoost et Random Forest, dont l'importance est mieux répartie, offrent une **plus grande robustesse** dans ces situations.

Variables à faible apport. Les indicateurs saisonniers (`is_summer`, `month_sin`, `month_cos`) et la volatilité court terme (`roll3_std`, `demand_diff1`) contribuent à moins de 3% pour l'ensemble des modèles : **la saisonnalité stricte et les chocs ponctuels jouent un rôle marginal** dans la prédiction de cette série.

5.4.5 Prévisions Futures

TABLE 5.8 : Prévisions de la demande mensuelle en CE — Février à Juillet 2026

Mois	CatBoost	XGBoost	Random Forest
Février 2026	836	825	824
Mars 2026	846	846	834
Avril 2026	787	780	806
Mai 2026	845	813	854
Juin 2026	847	835	868
Juillet 2026	843	815	855
<i>Moyenne</i>	<i>834</i>	<i>819</i>	<i>840</i>

Les trois modèles convergent vers **780–868 poches/mois**. La baisse prévue en avril 2026 est cohérente avec les profils saisonniers observés. La moyenne CatBoost (834 poches/mois) est retenue comme estimation de référence.

Bilan — Concentrés Érythrocytaires

CatBoost est retenu comme modèle de référence pour la prédiction de la demande mensuelle des Concentrés Érythrocytaires. Il atteint une **MAE de 48,0 poches**, une **RMSE de 56,8** et une **MAPE de 5,54 %** sur l'ensemble de test, soit une erreur moyenne inférieure à **6 %** sur les prédictions mensuelles. Sa régularisation intégrée et sa robustesse sur les séries courtes à tendance haussière expliquent sa supériorité face à XGBoost et Random Forest. Les prévisions pour le premier semestre 2026 indiquent une demande stable autour de **800 à 850 poches par mois**.

5.5 Prédiction de la Demande des Concentrés Plaquet-taires Standard (CPS)

Les Concentrés Plaquet-taires Standard sont des produits sanguins labiles à durée de vie très courte, ce qui les rend particulièrement sensibles aux variations de la demande et aux risques de péremption. Cette section présente la construction du modèle de prédiction de leur demande mensuelle, en suivant la même méthodologie que pour les CE, depuis la préparation des données jusqu'aux prévisions pour le premier semestre 2026.

5.5.1 Source et Préparation des Données

Les données sont extraites du fichier de gestion du stock des CPS, dans lequel chaque enregistrement correspond à une poche individuelle. Un premier filtre est appliqué sur la variable `statut` : seules les poches dont le statut est « **distribué** » sont conservées, représentant **31 324 poches** effectivement délivrées aux patients. La variable temporelle retenue est la **date de sortie**, qui reflète la demande réelle. Une agrégation mensuelle est ensuite réalisée : pour chaque mois, on comptabilise le nombre de poches distribuées. Après exclusion du dernier mois incomplet, la série couvre **48 points mensuels** de **janvier 2022** à **décembre 2025**.

La répartition chronologique retenue est présentée dans le tableau 5.9.

TABLE 5.9 : Répartition chronologique des données — CPS

Ensemble	Période	Nb. de mois
Entraînement	Février 2022 — Janvier 2025	37
Test	Février 2025 — Décembre 2025	11

Ce découpage respecte strictement la **causalité temporelle** : les modèles sont entraînés uniquement sur des données passées et évalués sur une période future qu'ils n'ont jamais observée, reproduisant ainsi un contexte opérationnel réel.

5.5.2 Variable Cible et Variables Explicatives

Variable cible. La variable à prédire est le **nombre mensuel de poches de CPS distribuées**, notée D_t pour le mois t .

Variables explicatives. Les seize mêmes variables que pour les CE ont été construites à partir de la série temporelle (tableau 5.6), afin de capturer les composantes de retard, de tendance, de saisonnalité et de volatilité. Les features lag et moyennes mobiles sont calculées avec un décalage (`shift(1)`) pour éviter toute fuite d'information (*data leakage*).

5.5.3 Résultats et Métriques de Performance

TABLE 5.10 : Métriques de performance des trois modèles — CPS (ensemble de test)

Modèle	MAE _{train}	MAE _{test}	RMSE _{test}	MAPE _{test} (%)	Rang
CatBoost	22,5	47,7	57,6	6,63	1 ^{er}
XGBoost	25,1	52,7	61,7	7,44	2 ^e
Random Forest	23,8	50,6	61,8	7,24	3 ^e

MAE et RMSE en nombre de poches. En gras : meilleures valeurs sur le test.

- (1) **Performances comparatives.** Les trois algorithmes affichent des MAPE comprises entre **6,63 %** et **7,44 %**, traduisant une bonne adéquation des modèles malgré les 37 mois d’entraînement seulement. Ces niveaux d’erreur restent en deçà du seuil opérationnel de 10 % généralement admis pour la prévision mensuelle de produits sanguins.
- (2) **Sur-apprentissage (*overfitting*).** Les MAE_{train} des trois modèles (22,5 à 25,1 poches) sont nettement inférieures aux MAE_{test} (47,7 à 52,7 poches), ce qui est attendu pour des méthodes ensemblistes appliquées à des séries courtes. L’écart est toutefois modéré, confirmant que les hyperparamètres retenus (profondeur limitée, *early stopping*) contraignent efficacement la complexité des modèles.

5.5.4 Analyse des Résultats Visuels

La figure 5.5 présente la synthèse graphique complète, organisée en quatre parties.




FIGURE 5.5 : Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026). Zone bleue : phase d’entraînement ; zone orange : phase de test. Les lignes pointillées indiquent les prédictions sur le jeu de test, les tirets les prévisions pour les six mois à venir.

Interprétation — Série temporelle et prédictions

Tendance générale (2022–2024). La courbe noire révèle une **tendance haussière progressive et régulière** sur l'ensemble de la période d'entraînement : la demande mensuelle passe d'environ **520 poches** en janvier 2022 à un niveau de **779 poches** en janvier 2025, soit une progression de près de **50 %** en trois ans. Cette croissance s'accompagne d'oscillations saisonnières modérées — creux récurrents en mars–avril et en novembre, pics en été et en fin d'année — sans rupture structurelle majeure, ce qui traduit un besoin clinique en expansion continue et prévisible.

Comportement sur la période de test (Fév–Déc 2025). La demande se stabilise sur la période de test dans une fourchette de **640 à 851 poches/mois**, avec une valeur médiane d'environ 700 poches. Les trois modèles, entraînés sur la phase haussière, surestiment légèrement la demande sur les mois printaniers (mars–juin 2025), où la demande réelle marque un repli notable par rapport au niveau de janvier 2025. Ce comportement est cohérent avec un **plateau saisonnier bas-printanier** que le seul indice `is_summer` ne capture qu'imparfaitement.

Anomalie de décembre 2025. Un **pic inhabituel** est observé en décembre 2025 ($D_t = 851$ poches), contrastant avec les niveaux des mois précédents (640–767 poches). Aucun des trois modèles n'anticipe cette hausse : les prédictions restent autour de 725–744 poches, générant des résidus positifs de **+107 à +125 poches**. Cette sous-estimation suggère un **choc exogène de demande** en fin d'année (afflux de patients, dotation de fin de budget, événement clinique ponctuel) non capturé par les features disponibles. Ce point devra être examiné avant toute exploitation opérationnelle des prévisions 2026.

Performance sur le jeu de test. À l'exception de décembre 2025, les trois modèles suivent correctement l'enveloppe de la demande. **CatBoost** présente le biais moyen le plus faible (**+0,1 poche**), quasi nul, indiquant une absence de tendance systématique à la sur- ou sous-estimation. XGBoost ($-10,6$ poches) et Random Forest ($-17,6$ poches) affichent en revanche un biais négatif modéré, signe d'une sous-estimation récurrente légère. Cette caractéristique de CatBoost est particulièrement favorable en contexte hospitalier, où un biais négatif persistant peut conduire à des ruptures de stock.

Prévisions futures (Jan–Jun 2026). Les trois modèles convergent vers une **demande stable autour de 710–753 poches par mois**. L'accord entre les algorithmes constitue un signal de robustesse : plusieurs méthodes indépendantes s'alignant sur la même plage renforcent la confiance dans l'estimation. La légère inflexion à la baisse par rapport au niveau de décembre 2025 (851 poches) s'explique par le fait que les modèles lissent le pic exceptionnel via les features lag et `roll6_mean`. Les prévisions devront être

révisées à la hausse si les données de décembre 2025 sont confirmées comme représentatives d'un changement de niveau.




FIGURE 5.6 : Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest). Les valeurs sont exprimées en pourcentage de contribution à la réduction d'erreur globale du modèle.

Interprétation — Importance des variables explicatives

Les trois modèles s'accordent sur les mêmes variables motrices, avec quelques nuances dans la répartition des poids.

Variables les plus déterminantes. La tendance (`trend`) et la moyenne glissante sur 6 mois (`roll6_mean`) dominent l'ensemble des modèles. `trend` contribue à hauteur de **20 %** pour CatBoost et Random Forest, reflétant la croissance structurelle de la série sur trois ans. La variable `roll6_mean` atteint des poids très élevés pour XGBoost, confirmant que le niveau récent lissé reste la meilleure approximation du niveau futur dans cette série. Le retard d'ordre 1 (`lag_1`, 11–14 % pour tous les modèles) traduit en complément une **forte inertie mensuelle** : la demande du mois précédent est un prédicteur robuste de la demande courante.

Point d'alerte : fragilité d'XGBoost. Comme pour les CE, la concentration d'XGBoost sur `roll6_mean` est un facteur de risque : en cas de rupture de tendance ou de choc soudain (comme le pic de décembre 2025), ce modèle sera le plus lent à s'adapter. CatBoost et Random Forest, avec une importance mieux distribuée entre plusieurs features, offrent une **plus grande robustesse** en situation atypique.

Variables à faible apport. Les indicateurs saisonniers (`is_summer`, `month_sin`, `month_cos`, `is_year_end`) et la volatilité court terme (`roll3_std`, `demand_diff1`) contribuent à moins de 3 % pour l'ensemble des modèles. Bien que la série CPS présente des oscillations saisonnières visibles, leur amplitude reste insuffisante pour que les modèles leur accordent un poids significatif en présence d'une tendance dominante et d'un lag 1 informatif.

5.5.5 Prévisions Futures

TABLE 5.11 : Prévisions de la demande mensuelle en CPS — Janvier à Juin 2026

Mois	CatBoost	XGBoost	Random Forest
Janvier 2026	720	727	750
Février 2026	719	729	753
Mars 2026	710	729	750
Avril 2026	710	729	748
Mai 2026	720	729	749
Juin 2026	714	731	750
<i>Moyenne</i>	<i>716</i>	<i>729</i>	<i>750</i>

Les trois modèles convergent vers **710–753 poches/mois**. La stabilité des prévisions d'un mois à l'autre reflète l'absence de signal saisonnier fort sur cette période de l'année dans les données historiques. La moyenne CatBoost (**716 poches/mois**) est retenue comme estimation de référence. Une révision à la hausse vers 750 poches/mois reste envisageable si le pic de décembre 2025 est confirmé comme un changement de niveau plutôt qu'un événement ponctuel.

Bilan — Concentrés Plaquettaires Standard

CatBoost est retenu comme modèle de référence pour la prédiction de la demande mensuelle des Concentrés Plaquettaires Standard. Il atteint une **MAE de 47,7 poches**, une **RMSE de 57,6** et une **MAPE de 6,63 %** sur l'ensemble de test, soit une erreur moyenne inférieure à **7 %** sur les prédictions mensuelles. Son biais quasi nul (+0,1 poche) le distingue nettement de XGBoost et Random Forest, qui tendent à sous-estimer légèrement la demande. Cette propriété est essentielle en gestion de stock hospitalier, où la sous-estimation expose à des risques de rupture. Les prévisions pour le premier semestre 2026 indiquent une demande stable autour de **716 à 750 poches par mois**, avec une incertitude accrue sur janvier 2026 en raison du pic exceptionnel de décembre 2025.

5.6 Prédiction de la Demande du Plasma Fraîchement Congelé (PFC)

Le Plasma Fraîchement Congelé est un produit sanguin utilisé principalement dans le traitement des coagulopathies et des déficits en facteurs de coagulation. Sa demande présente une dynamique plus irrégulière que celle des CE et CPS, ce qui en fait un cas particulièrement exigeant pour la prédiction. Cette section suit la même méthodologie que pour les deux produits précédents, depuis la préparation des données jusqu'aux prévisions pour le premier semestre 2026.

5.6.1 Source et Préparation des Données

Les données sont extraites du fichier de gestion du stock des PFC, dans lequel chaque enregistrement correspond à une poche individuelle. Un premier filtre est appliqué sur la variable `statut` : seules les poches dont le statut est « **distribué** » sont conservées, représentant **17 040 poches** effectivement délivrées aux patients. La variable temporelle retenue est la **date de sortie**, qui reflète la demande réelle. Une agrégation mensuelle est ensuite réalisée : pour chaque mois, on comptabilise le nombre de poches distribuées. Après exclusion du dernier mois incomplet, la série couvre **48 points mensuels** de **janvier 2022** à **décembre 2025**.

La répartition chronologique retenue est présentée dans le tableau 5.12.

TABLE 5.12 : Répartition chronologique des données — PFC

Ensemble	Période	Nb. de mois
Entraînement	Janvier 2022 — Janvier 2025	37
Test	Février 2025 — Décembre 2025	11

Ce découpage respecte strictement la **causalité temporelle** : les modèles sont entraînés uniquement sur des données passées et évalués sur une période future qu'ils n'ont jamais observée, reproduisant ainsi un contexte opérationnel réel.

5.6.2 Variable Cible et Variables Explicatives

Variable cible. La variable à prédire est le **nombre mensuel de poches de PFC distribuées**, notée D_t pour le mois t .

Variables explicatives. Les seize mêmes variables que pour les CE et CPS ont été construites à partir de la série temporelle (tableau 5.6), afin de capturer les composantes

de retard, de tendance, de saisonnalité et de volatilité. Les features lag et moyennes mobiles sont calculées avec un décalage (`shift(1)`) pour éviter toute fuite d'information (*data leakage*).

5.6.3 Résultats et Métriques de Performance

TABLE 5.13 : Métriques de performance des trois modèles — PFC (ensemble de test)

Modèle	$\text{MAE}_{\text{train}}$	MAE_{test}	$\text{RMSE}_{\text{test}}$	$\text{MAPE}_{\text{test}}$ (%)	Rang
CatBoost	31,1	47,9	64,4	13,87	2 ^e
XGBoost	28,2	42,4	64,0	12,96	1^{er}
Random Forest	22,0	49,6	72,1	15,39	3 ^e

MAE et RMSE en nombre de poches. En gras : meilleures valeurs sur le test.

(1) **Performances comparatives.** Contrairement aux CE et CPS où CatBoost dominait, c'est **XGBoost** qui obtient les meilleures performances sur les PFC, avec une $\text{MAE}_{\text{test}} = 42,4$ poches et une $\text{MAPE}_{\text{test}} = 12,96\%$. Ces niveaux d'erreur, bien que supérieurs à ceux observés sur les CE ($\approx 6\%$) et les CPS ($\approx 7\%$), reflètent la plus grande irrégularité de la série PFC, notamment la chute atypique de mai-juin 2025, difficile à anticiper par tout algorithme basé sur l'historique.

(2) **Sur-apprentissage (*overfitting*).** Random Forest présente le cas le plus marqué : sa $\text{MAE}_{\text{train}} = 22,0$ poches est plus de deux fois inférieure à sa $\text{MAE}_{\text{test}} = 49,6$ poches (ratio $\times 2,3$). XGBoost et CatBoost affichent un écart train/test plus contenu (ratio $\times 1,5$), confirmant que leurs mécanismes de régularisation (*early stopping*, profondeur limitée) atténuent efficacement le sur-ajustement sur cette série courte.

5.6.4 Analyse des Résultats Visuels

Les figures 5.7 et 5.8 présentent la synthèse graphique complète.




FIGURE 5.7 : Demande mensuelle réelle vs prédite et prévisions futures (Jan 2022 – Jun 2026). Zone bleue : phase d'entraînement ; zone orange : phase de test. Les lignes pointillées indiquent les prédictions sur le jeu de test, les tirets les prévisions pour les six mois à venir.

Interprétation — Série temporelle et prédictions

Tendance générale (2022–2024). La courbe noire révèle une **tendance haussière soutenue mais irrégulière** sur la période d'entraînement : la demande mensuelle progresse d'environ **146 poches** en janvier 2022 à un pic de **524 poches** en janvier 2025, soit une multiplication par plus de **3,5** en trois ans. Cette croissance n'est pas linéaire — un creux notable est observé en début 2024 (291 poches en janvier 2024) avant une reprise forte au second semestre 2024 (499 poches en octobre 2024) — traduisant une demande clinique en expansion.

Choc structurel de mai–juin 2025. L'événement le plus marquant de la période de test est la **chute brutale de la demande en mai 2025** ($D_t = 261$ poches), après 524 poches en janvier 2025, suivie d'un maintien bas en juin 2025 ($D_t = 276$ poches). Aucun des trois modèles n'anticipe ce décrochage : CatBoost et XGBoost prédisent respectivement 410 poches, générant une erreur de **−149 poches** (−57,1 %), et Random Forest atteint **−179 poches** (−68,6 %). Cette rupture n'est pas capturée par les variables explicatives disponibles et suggère un **choc exogène majeur** (modification des pratiques transfusionnelles, perturbation d'approvisionnement, arrêt temporaire d'une unité clinique). Ce point doit impérativement être investigué avant toute décision opérationnelle basée sur les prévisions.

Comportement sur la période de test (Fév–Déc 2025). En dehors du creux de mai–juin 2025, les trois modèles suivent correctement l'enveloppe de la demande sur les autres mois (fourchette 416–480 poches). La remontée de juillet 2025 ($D_t = 456$ poches) est partiellement captée par CatBoost et XGBoost, bien qu'avec une légère sous-estimation (respectivement +94 et +65 poches d'erreur). **XGBoost** obtient notamment des erreurs nulles en août et septembre 2025, ce qui illustre son adaptation rapide une fois le choc

estival absorbé dans les features lag.

Prévisions futures (Jan–Jun 2026). Les trois modèles divergent davantage que pour les CE et CPS : CatBoost prévoit **398–423 poches/mois**, XGBoost **412–413 poches/mois**, et Random Forest **447–468 poches/mois**. L'écart entre CatBoost/XGBoost (≈ 407 –413 poches) et Random Forest (≈ 459 poches) reflète les différences de biais observées sur le test. La convergence partielle entre CatBoost et XGBoost renforce la confiance dans la fourchette **400–420 poches/mois** comme estimation centrale. La divergence de Random Forest vers le haut s'explique par son incapacité à intégrer correctement le creux de 2025 dans ses prévisions.




FIGURE 5.8 : Importance relative des variables explicatives pour chacun des trois modèles (CatBoost, XGBoost, Random Forest). Les valeurs sont exprimées en pourcentage de contribution à la réduction d'erreur globale du modèle.

Interprétation — Importance des variables explicatives

Variables les plus déterminantes. Comme pour les CE et CPS, la **tendance** (`trend`) et les **retards courts** (`lag_1`) dominent l'ensemble des modèles : `trend` contribue à hauteur de **22–27 %** pour les trois algorithmes, et `lag_1` à **14–16 %**. Cette prédominance de la tendance traduit la croissance structurelle de la série sur trois ans, qui reste le signal le plus prédictif malgré les irrégularités conjoncturelles. La moyenne glissante sur 6 mois (`roll6_mean`) est ici moins dominante que pour les CE et CPS (autour de 7–14 %), signe que le lissage long terme est moins pertinent face aux chocs brusques caractéristiques de la série PFC.

Rôle accru des retards multiples. Contrairement aux CE et CPS, les retards `lag_2`, `lag_3` et `lag_6` contribuent chacun à **4–7 %**, soit une répartition plus équilibrée entre plusieurs horizons temporels. Cela indique que la demande PFC présente une **mémoire plus diffuse** : les valeurs passées à plusieurs distances contribuent toutes à l'estimation, sans qu'un retard unique ne domine. La variable `roll6_std` (`roll3_std`) prend également

davantage d'importance relative, reflétant la plus grande volatilité intrinsèque de cette série.

Variables à faible apport. Les indicateurs saisonniers (`is_summer`, `month_sin`, `month_cos`, `is_year_end`) et la différenciation (`demand_diff1`) contribuent à moins de 3 % pour l'ensemble des modèles. La saisonnalité structurelle joue ainsi un rôle marginal dans la prédiction des PFC : les fluctuations observées sont davantage d'origine clinique ou logistique que saisonnière.

5.6.5 Prévisions Futures

TABLE 5.14 : Prévisions de la demande mensuelle en PFC — Janvier à Juin 2026

Mois	CatBoost	XGBoost	Random Forest
Janvier 2026	423	413	447
Février 2026	409	413	453
Mars 2026	402	413	456
Avril 2026	405	414	465
Mai 2026	405	412	468
Juin 2026	398	412	466
<i>Moyenne</i>	<i>407</i>	<i>413</i>	<i>459</i>

CatBoost et XGBoost convergent vers **398–423 poches/mois**, tandis que Random Forest prédit un niveau sensiblement plus élevé (447–468 poches/mois), en cohérence avec son biais positif observé sur le test. La moyenne XGBoost (**413 poches/mois**) est retenue comme estimation de référence, eu égard à ses meilleures performances globales. La légère décroissance prévue par CatBoost en fin de semestre (≈ 398 poches en juin 2026) devra être surveillée : elle pourrait signaler une correction vers un niveau de demande structurellement plus bas si le creux de mai–juin 2025 se répète.

Bilan — Plasma Fraîchement Congelé

XGBoost est retenu comme modèle de référence pour la prédiction de la demande mensuelle du Plasma Fraîchement Congelé, se distinguant ici de CatBoost retenu pour les CE et CPS. Il atteint une **MAE de 42,4 poches**, une **RMSE de 64,0** et une **MAPE de 12,96 %** sur l'ensemble de test. Ces niveaux d'erreur, plus élevés que ceux observés sur les CE et CPS, s'expliquent par la plus grande irrégularité de la série PFC, en particulier la chute atypique de mai–juin 2025 (−57 % en un mois) qu'aucun modèle basé sur l'historique ne pouvait anticiper. En dehors de cet événement exogène, les prédictions restent dans une fourchette opérationnellement acceptable. Les prévisions pour le premier semestre 2026 indiquent une demande stable autour de **400 à 420 poches par mois** selon CatBoost et XGBoost, avec une incertitude structurelle liée au risque de récurrence d'un choc similaire.

Conclusion générale

Synthèse des contributions

Ce mémoire s'est inscrit dans une démarche scientifique et quantitative visant à modéliser, analyser et optimiser intelligemment la gestion des stocks de produits sanguins au sein du Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa. Pour répondre à la problématique posée, deux méthodologies complémentaires ont été mises en œuvre et appliquées à des données historiques réelles collectées directement auprès du centre.

Modélisation par Réseau de Petri Stochastique Généralisé. Un modèle de Réseau de Petri Stochastique Généralisé (RdPSG) a été construit pour représenter formellement le flux des produits sanguins, depuis l'arrivée des donneurs jusqu'à la distribution ou la péremption des poches. L'analyse de la chaîne de Markov à temps continu associée a révélé une **probabilité de rupture de stock de 68,14 %** dans les conditions nominales, un stock moyen très faible (0,3645 unités par produit) et un **taux de service insuffisant de 31,86 %**, mettant en évidence la fragilité structurelle du système face au déséquilibre entre collecte et consommation. L'analyse de sensibilité a montré que la réduction du taux de péremption constitue le levier le plus efficace : en combinant une collecte accrue, une analyse biologique accélérée et de meilleures conditions de conservation, le taux de service peut atteindre **81,30 %**, soit une amélioration de près de **150 %** par rapport au scénario de référence.

Prédiction de la demande par apprentissage automatique. Trois algorithmes ensemblistes — CatBoost, XGBoost et Random Forest — ont été entraînés sur 37 mois de données historiques réelles pour prédire la demande mensuelle des trois produits sanguins principaux du centre. Pour les **Concentrés Érythrocytaires (CE)**, CatBoost s'est imposé comme modèle de référence avec une **MAPE de 5,54 %** et un biais quasi nul, les prévisions pour le premier semestre 2026 indiquant une demande stable autour de **800 à 850 poches par mois**. Pour les **Concentrés Plaquettaires Standard (CPS)**, CatBoost s'est à nouveau distingué avec une **MAPE de 6,63 %** et un biais moyen de +0,1 poche, propriété précieuse en contexte hospitalier, avec des prévisions convergeant

vers **716 à 750 poches par mois**. Pour le **Plasma Frais Congelé (PFC)**, la dynamique plus irrégulière de la série — marquée par une chute atypique de -57% en mai 2025 — a rendu la prédiction plus exigeante : c’est **XGBoost** qui obtient les meilleures performances avec une **MAPE de 12,96 %** et une MAE de 42,4 poches, les prévisions se stabilisant autour de **400 à 420 poches par mois**. La convergence des trois modèles sur des plages de prévision proches pour les CE et les CPS constitue un signal de robustesse fort, renforçant la fiabilité des estimations produites.

Limites du travail

Le modèle RdPSG repose sur des taux exponentiels constants, hypothèse qui simplifie la réalité d’un système soumis à des variations saisonnières et à des événements non stationnaires. La taille des séries temporelles disponibles (46 à 47 mois) reste par ailleurs modeste pour des méthodes ensemblistes, ce qui explique l’écart observé entre les performances sur l’ensemble d’entraînement et sur l’ensemble de test. Enfin, les anomalies observées en fin de période de test — chute brutale de la demande CE en décembre 2025, pic inhabituel des CPS ce même mois, et choc structurel des PFC en mai–juin 2025 — n’ont pu être expliquées ni anticipées par les modèles, soulignant la nécessité d’intégrer des variables exogènes supplémentaires (événements cliniques ponctuels, dotations budgétaires de fin d’année, perturbations d’approvisionnement) pour améliorer la robustesse des prévisions face aux chocs atypiques.

Perspectives

Les résultats obtenus ouvrent plusieurs pistes de recherche et d’amélioration :

1. **Enrichissement du modèle RdPSG.** Introduire des distributions non exponentielles pour les temps de traitement, afin de mieux rendre compte de la réalité opérationnelle du centre.
2. **Intégration de modèles de séries temporelles avancés.** Explorer des architectures de Deep Learning (LSTM, GRU) pour la prédiction de la demande, en exploitant les dépendances temporelles longues et en intégrant des variables exogènes (saisonnalité, épidémies, activités chirurgicales programmées).
3. **Développement d’un outil d’aide à la décision.** Coupler les prévisions de demande issues du machine learning avec les indicateurs de performance du RdPSG pour construire un tableau de bord opérationnel permettant au personnel du CWTS d’anticiper les ruptures et d’ajuster les politiques de réapprovisionnement en temps réel.

Bibliographie

- [1] AGENCE NATIONALE DU SANG (2025). *Histoire de la transfusion sanguine en Algérie*. Disponible sur : <http://www.ans.dz/histoire-transfusion-sanguine-algerie/> [Consulté le 7 juin 2026]
- [2] AGENCE NATIONALE DU SANG (2025). *Le Laboratoire du Sang*. Disponible sur : <http://www.ans.dz/laboratoire/> [Consulté le 7 juin 2026]
- [3] GRATACAP, A., & MÉDAN, P. (2013). *Management de la production : concepts, méthodes, cas* (4^e éd.). Dunod, Paris.
- [4] MOCELLIN, F. (2011). *Gestion des stocks et des magasins : pratiques des méthodes logistiques adaptées au lean manufacturing*. Dunod, Paris.
- [5] COURTOIS, A., PILLET, M., & MARTIN-BONNEFOUS, C. (2011). *Gestion de production* (5^e éd.). Éditions d'Organisation, Paris.
- [6] BRAHIMI, N., ABSI, N., DAUZÈRE-PÉRÈS, S., & NORDLI, A. (2017). Single-item dynamic lot-sizing problems : An updated survey. *European Journal of Operational Research*, 263(3), 838–863. <https://doi.org/10.1016/j.ejor.2017.05.008>
- [7] SCHOEN, Q., FONTANILI, F., ANQUETIL, A., TRUPTIL, S., & LAURAS, M. (2017). Tracking in real time the blood products transportations to make good decisions. HAL – Centre pour la Communication Scientifique Directe. Disponible sur : <https://imt-mines-albi.hal.science/hal-01618600>
- [8] ORGANISATION MONDIALE DE LA SANTÉ (2022). *Rapport de situation mondial sur la sécurité transfusionnelle et l'approvisionnement en sang 2021*. OMS, Genève. Disponible sur : <https://iris.who.int/handle/10665/367671>
- [9] SEIFRIED, E., KLUETER, H., WEIDMANN, C., STAUDENMAIER, T., SCHREZENMEIER, H., HENSCHLER, R., GREINACHER, A., & MUELLER, M. M. (2010). How much blood is needed? *Vox Sanguinis*, 100(1), 10–21. <https://doi.org/10.1111/j.1423-0410.2010.01446.x>
- [10] ABBASI, B., & HOSSEINIFARD, S. Z. (2014). On the issuing policies for perishable items such as red blood cells and platelets in blood service. *Decision Sciences*, 45(5), 995–1020. <https://doi.org/10.1111/deci.12092>

- [11] SHOKOUHIFAR, M., SABBAGHI, M. M., & PILEVARI, N. (2021). Inventory management in blood supply chain considering fuzzy supply/demand uncertainties and lateral transshipment. *Transfusion and Apheresis Science*, 60(3), 103103. <https://doi.org/10.1016/j.transci.2021.103103>
- [12] FORTSCH, S. M., & KHAPALOVA, E. A. (2016). Reducing uncertainty in demand for blood. *Operations Research for Health Care*, 9, 16–28. <https://doi.org/10.1016/j.orhc.2016.02.002>
- [13] RAJENDRAN, S., & RAVINDRAN, A. R. (2019). Inventory management of platelets along blood supply chain to minimize wastage and shortage. *Computers & Industrial Engineering*, 130, 714–730. <https://doi.org/10.1016/j.cie.2019.03.010>
- [14] DEGHANI, M., ABBASI, B., & OLIVEIRA, F. (2021). Proactive transshipment in the blood supply chain : A stochastic programming approach. *Omega*, 98, 102112. <https://doi.org/10.1016/j.omega.2019.102112>
- [15] KURUP, R., ANDERSON, A., BOSTON, C., BURNS, L., GEORGE, M., & FRANK, M. (2016). A study on blood product usage and wastage at the public hospital, Guyana. *BMC Research Notes*, 9, 307. <https://doi.org/10.1186/s13104-016-2112-5>
- [16] PETRI, C. A. (1966). *Communication with Automata*. Technical Report RADC-TR-65-377, Rome Air Development Center, New York.
- [17] MURATA, T. (1989). Petri nets : Properties, analysis and applications. *Proceedings of the IEEE*, 77(4), 541–580.
- [18] PETERSON, J. L. (1981). *Petri Net Theory and the Modeling of Systems*. Prentice Hall, Englewood Cliffs, NJ.
- [19] REISIG, W. (1985). *Petri Nets : An Introduction*. Springer, Berlin.
- [20] JENSEN, K., & KRISTENSEN, L. M. (2009). *Coloured Petri Nets : Modelling and Validation of Concurrent Systems*. Springer, Berlin.
- [21] DAVID, R., & ALLA, H. (2010). *Discrete, Continuous, and Hybrid Petri Nets* (2^e éd.). Springer, Berlin.
- [22] AJMONE MARSAN, M., BALBO, G., CONTE, G., DONATELLI, S., & FRANCESCHINIS, G. (1995). *Modelling with Generalized Stochastic Petri Nets*. Wiley, New York.
- [23] FLORIN, G., FRAIZE, C., & NATKIN, S. (1991). Stochastic Petri nets : Properties, applications and tools. *Microelectronics and Reliability*, 31(4), 669–697.
- [24] AUGUSTO, V., & XIE, X. (2008). Modelling and analysis of healthcare systems using timed Petri nets. *International Journal of Production Economics*, 112(1), 205–218.
- [25] BELIÈN, J., & FORCÉ, H. (2012). Supply chain management of blood products : A literature review. *European Journal of Operational Research*, 217(1), 1–16.

-
- [26] OSORIO, A. F., BRAILSFORD, S. C., & SMITH, H. K. (2015). A structured review of quantitative models in the blood supply chain. *Health Systems*, 4(3), 159–169.
- [27] BOUKREDERA épouse BOULAHROUZ, D. (2019–2020). *Les Réseaux de Petri : un outil de Modélisation et d'Analyse des Systèmes Dynamiques à Évènements Discrets*. Support de cours, Université A/Mira de Béjaïa.
- [28] GOODFELLOW, I., BENGIO, Y., & COURVILLE, A. (2016). *Deep Learning*. MIT Press, Cambridge. Disponible gratuitement sur : <https://www.deeplearningbook.org>
- [29] HASTIE, T., TIBSHIRANI, R., & FRIEDMAN, J. (2009). *The Elements of Statistical Learning : Data Mining, Inference, and Prediction* (2^e éd.). Springer, New York. Disponible gratuitement sur : <https://hastie.su.domains/ElemStatLearn/>
- [30] CORTES, C., & VAPNIK, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- [31] BREIMAN, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [32] CHEN, T., & GUESTRIN, C. (2016). XGBoost : A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 785–794. <https://doi.org/10.1145/2939672.2939785> Prépublication libre : <https://arxiv.org/abs/1603.02754>
- [33] PROKHORENKOVA, L., GUSEV, G., VOROBEOV, A., DOROGUSH, A. V., & GULIN, A. (2018). CatBoost : Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems (NeurIPS 2018)*, 31, 6639–6649. Disponible sur : <https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html> Prépublication libre : <https://arxiv.org/abs/1706.09516>
- [34] JAIN, A. K. (2010). Data clustering : 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666. <https://doi.org/10.1016/j.patrec.2009.09.011>
- [35] SUTTON, R. S., & BARTO, A. G. (2018). *Reinforcement Learning : An Introduction* (2^e éd.). MIT Press, Cambridge. Disponible gratuitement sur : <http://incompleteideas.net/book/the-book-2nd.html>
- [36] LECUN, Y., BENGIO, Y., & HINTON, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- [37] HOCHREITER, S., & SCHMIDHUBER, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [38] CHO, K., VAN MERRIENBOER, B., GULCEHRE, C., BAHDANAU, D., BOUGARES, F., SCHWENK, H., & BENGIO, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *Proceedings of*

- EMNLP 2014*, Doha, 1724–1734. Prépublication libre : <https://arxiv.org/abs/1406.1078>
- [39] GOODFELLOW, I., BENGIO, Y., & COURVILLE, A. (2016). *Deep Learning*. MIT Press, Cambridge. Disponible gratuitement sur : <https://www.deeplearningbook.org>
- [40] HASTIE, T., TIBSHIRANI, R., & FRIEDMAN, J. (2009). *The Elements of Statistical Learning : Data Mining, Inference, and Prediction* (2^e éd.). Springer, New York. Disponible gratuitement sur : <https://hastie.su.domains/ElemStatLearn/>
- [41] CORTES, C., & VAPNIK, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- [42] BREIMAN, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- [43] CHEN, T., & GUESTRIN, C. (2016). XGBoost : A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, San Francisco, 785–794. <https://doi.org/10.1145/2939672.2939785> Prépublication libre : <https://arxiv.org/abs/1603.02754>
- [44] PROKHORENKOVA, L., GUSEV, G., VOROBEOV, A., DOROGUSH, A. V., & GULIN, A. (2018). CatBoost : Unbiased boosting with categorical features. *Advances in Neural Information Processing Systems (NeurIPS 2018)*, 31, 6639–6649. Disponible sur : <https://proceedings.neurips.cc/paper/2018/hash/14491b756b3a51daac41c24863285549-Abstract.html> Prépublication libre : <https://arxiv.org/abs/1706.09516>
- [45] JAIN, A. K. (2010). Data clustering : 50 years beyond K-means. *Pattern Recognition Letters*, 31(8), 651–666. <https://doi.org/10.1016/j.patrec.2009.09.011>
- [46] SUTTON, R. S., & BARTO, A. G. (2018). *Reinforcement Learning : An Introduction* (2^e éd.). MIT Press, Cambridge. Disponible gratuitement sur : <http://incompleteideas.net/book/the-book-2nd.html>
- [47] LECUN, Y., BENGIO, Y., & HINTON, G. (2015). Deep learning. *Nature*, 521(7553), 436–444. <https://doi.org/10.1038/nature14539>
- [48] HOCHREITER, S., & SCHMIDHUBER, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- [49] CHO, K., VAN MERRIENBOER, B., GULCEHRE, C., BAHDANAU, D., BOUTGARES, F., SCHWENK, H., & BENGIO, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *Proceedings of EMNLP 2014*, Doha, 1724–1734. Prépublication libre : <https://arxiv.org/abs/1406.1078>

ANNEXE A

Présentation de l'outil GreatSPN

A.1 Présentation de l'outil GreatSPN

GreatSPN (*G*Raphical *E*ditor and *A*nalyzer for *T*imed and *S*tochastic *P*etri *N*ets) est un environnement logiciel open-source développé à l'Université de Turin (Italie), dédié à la modélisation, l'édition graphique et l'analyse des Réseaux de Petri Temporisés et Stochastiques. Il offre une interface graphique permettant de construire visuellement des modèles RdPS, RdPSG et GSPN, et intègre des moteurs de calcul pour :

- la génération automatique du graphe d'accessibilité et de la chaîne de Markov associée ;
- le calcul des probabilités en régime permanent par résolution numérique ;
- l'évaluation des indices de performance (taux d'utilisation, temps de séjour, débit, probabilités d'état) ;
- l'analyse qualitative (bornitude, vivacité, absence de blocage).

Dans le cadre de ce mémoire, GreatSPN a été utilisé pour intégrer notre modèle RdPSG du flux des produits sanguins au CWTS de Béjaïa, générer le graphe d'accessibilité (figure 5.2) à partir d'un marquage initial, en utilisant la commande RG illustrée à la figure A.1.




FIGURE A.1 : Interface graphique de l'outil GreatSPN avec indication du bouton RG.

ANNEXE B

Language Python

B.1 Python

Python est un langage de programmation interprété, open-source et multiparadigme (impératif, orienté objet, fonctionnel), créé par Guido van Rossum et publié en 1991. Il se distingue par une syntaxe claire et lisible, ce qui en fait l'un des langages les plus utilisés dans les domaines de la science des données, de l'apprentissage automatique et du calcul scientifique. Dans le cadre de ce mémoire, Python (version 3.13) a été choisi comme environnement de développement principal pour l'implémentation du pipeline de prédiction de la demande en produits sanguins.

B.2 Visual Studio Code

Visual Studio Code (VS Code) est un éditeur de code source léger, gratuit et open-source développé par Microsoft, disponible sur Windows, Linux et macOS. Il offre une prise en charge native de Python via des extensions dédiées, un terminal intégré, une coloration syntaxique, la complétion automatique (*IntelliSense*) et un débogueur interactif. VS Code a été utilisé comme environnement de développement intégré (IDE) pour l'écriture, l'exécution et le débogage des scripts Python de ce mémoire.

B.3 Bibliothèques utilisées en apprentissage automatique

Le pipeline de prédiction de la demande repose sur un ensemble de bibliothèques Python spécialisées, importées en début de script : Le tableau [B.1](#) présente le rôle de chacune de ces bibliothèques dans le cadre de ce travail.

TABLE B.1 : Bibliothèques Python utilisées et leurs rôles.

Bibliothèque	Version	Rôle
pandas	2.3.3	Manipulation et prétraitement des données tabulaires (séries temporelles mensuelles).
numpy	2.3.3	Calcul numérique, opérations vectorielles et matricielles.
matplotlib	3.10.6	Visualisation des données : courbes de demande, résultats de prédiction, comparaisons de modèles.
scikit-learn	1.7.2	Implémentation de Random Forest, calcul des métriques d'évaluation (MAE, RMSE, R^2 , MAPE).
XGBoost	3.2.0	Modèle de gradient boosting basé sur les arbres de décision, appliqué à la prédiction de la demande, retenu comme meilleur modèle pour prédictions en PFC (MAPE < 13 %)..
CatBoost	1.2.10	Modèle de gradient boosting optimisé pour les variables catégorielles, retenu comme meilleur modèle pour prédictions en CE et CPS (MAPE < 7 %).
openpyxl	3.1.5	Lecture et écriture de fichiers Excel (.xlsx), permettant l'importation des données brutes et l'exportation des résultats de prédiction.

Résumé

Ce travail propose une approche hybride pour modéliser et améliorer la gestion des stocks au Centre de Wilaya de Transfusion Sanguine (CWTS) de Béjaïa, à partir de 48 mois de données réelles. Un modèle de Réseau de Petri Stochastique Généralisé (RdPSG) représente formellement le flux des produits sanguins ; la résolution de la chaîne de Markov associée révèle, en régime permanent, une probabilité de rupture de 68,14 % et un taux de service de 31,86 %, améliorable à 81,30 % grâce à une approche combinée (augmentation de la collecte, accélération des analyses biologiques et réduction du taux de péremption). Parallèlement, trois modèles d'apprentissage automatique (CatBoost, XGBoost, Random Forest) sont appliqués à la prédiction de la demande mensuelle en CE, CPS et PFC ; CatBoost s'avère le plus performant pour les CE et CPS (MAPE de 5,54 % et 6,63 %), tandis que XGBoost l'emporte pour le PFC (MAPE de 12,96 %), série plus irrégulière marquée par une chute atypique en mai–juin 2025. Ces modèles fournissent des prévisions fiables pour le premier semestre 2026 : environ 845 poches/mois (CE), 716 poches/mois (CPS) et 413 poches/mois (PFC).

Mots-clés : gestion des stocks, produits sanguins, Réseau de Petri Stochastique Généralisé, chaîne de Markov, machine learning, CatBoost, XGBoost, prédiction de la demande, CWTS Béjaïa.

Abstract

This work proposes a hybrid approach to model and improve inventory management at the Centre de Wilaya de Transfusion Sanguine (CWTS) of Béjaïa, based on 48 months of real data. A Generalized Stochastic Petri Net (GSPN) formally represents the blood product flow ; solving the associated Markov chain yields steady-state indicators of a 68.14 % stockout probability and a 31.86 % service rate, improvable to 81.30 % through a combined approach (increased collection, faster biological analysis, and reduced expiration). Three machine learning models (CatBoost, XGBoost, Random Forest) are then applied to forecast monthly demand for RBC, SPC and FFP ; CatBoost achieves the best performance for RBC and SPC (MAPE of 5.54 % and 6.63 %), while XGBoost performs best for FFP (MAPE of 12.96 %), a more irregular series marked by an atypical drop in May–June 2025. These models provide reliable forecasts for the first half of 2026 : around 845 units/month (RBC), 716 units/month (SPC) and 413 units/month (FFP).

Keywords : inventory management, blood products, Generalized Stochastic Petri Net, Markov chain, machine learning, CatBoost, XGBoost, demand forecasting, CWTS Béjaïa.